

Dipartimento di Fisica e Astronomia “Augusto Righi”
Corso di Laurea in Fisica

**Metodi Monte Carlo e Normalizing
Flows per il campionamento di
distribuzioni di Boltzmann multimodali.**

Relatore:
Prof. Cesare Franchini

Presentata da:
Riccardo Pivi

Correlatore:
Dott. Luca Leoni

*A mio fratello e ai miei genitori,
per essere stati il mio faro e il mio porto sicuro.*

Sommario

Qui inserisci il testo del sommario...

Indice

Introduzione	1
1 Probabilità e meccanica statistica	3
1.1 Teoria della probabilità	3
1.1.1 Spazi di probabilità e variabili aleatorie	3
1.1.2 Distribuzioni di probabilità continue	4
1.1.3 Distribuzioni unimodali e multimodali	5
1.1.4 Valori di aspettazione e campionamento	6
1.2 Meccanica statistica	8
1.2.1 Microstato, macrostato e ensemble statistico	8
1.2.2 L'ensemble canonico	9
1.2.3 La distribuzione di Boltzmann	10
1.3 Campionamento: diretto e markoviano	11
2 Metodi Monte Carlo	15
2.1 Cenni storici	15
2.2 Metodo dell'inversa	17
2.3 Markov Chain Monte Carlo	18
2.3.1 Catene di Markov	18
2.3.2 L'Algoritmo di Metropolis-Hastings	21
2.4 Campioni autocorrelati	23
3 Normalizing Flows	27
3.1 Definizione, proprietà ed utilizzo	27
3.1.1 Cambio di variabili e funzioni invertibili	27
3.1.2 Espressività del flow	29
3.1.3 Campionamento e inferenza	30
3.2 Costruire un flow	31
3.2.1 Composizione finita	31
3.2.2 Autoregressive flows	33
3.2.3 Real NVP	35
3.3 Addestramento del flow	38
3.4 Campionamento con NF	39
3.4.1 Campionamento diretto e re-weighting	39
3.4.2 Flow Markov Chain Monte Carlo	42
4 Studio del campionamento	45
4.1 Il potenziale doppio pozzo	45
4.2 Limiti di Markov Chain Monte Carlo	45
4.2.1 Dettagli implementativi	45

4.2.2	Risultati	46
4.3	Confronto dei metodi di campionamento	48
4.3.1	Dettagli implementativi	48
4.3.2	Confronto al variare di T	48
4.3.3	Confronto al variare di N	51
4.3.4	Distribuzioni e traiettorie del camminatore	53
Conclusione		55
A Derivazione della distribuzione di Boltzmann		57
Bibliografia		60
Ringraziamenti		61

Introduzione

CAPITOLO 1

Probabilità e meccanica statistica

In questo capitolo vengono introdotti alcuni concetti fondamentali per la comprensione del problema del campionamento: generare una successione di configurazioni secondo una determinata distribuzione di probabilità. Tale problema assume particolare rilevanza in meccanica statistica, dove le proprietà macroscopiche di un sistema possono essere ricavate a partire dalle configurazioni microscopiche che lo costituiscono.

Nelle prossime pagine si introducono le nozioni di variabile aleatoria e distribuzioni di probabilità e si discute l'importanza del campionamento di una distribuzione (Sezione 1.1). Si introduce poi la meccanica statistica e l'ensemble canonico, con particolare attenzione alla distribuzione di Boltzmann (Sezione 1.2), che rappresenta la distribuzione target dei metodi di campionamento studiati nel seguito di questa tesi. Infine si espone la distinzione fra campionamento diretto e markoviano (Sezione 1.3) necessaria per comprendere le differenze nei vari metodi di campionamento presentati nei capitoli successivi.

1.1 Teoria della probabilità

1.1.1 Spazi di probabilità e variabili aleatorie

In teoria della probabilità ha un ruolo fondamentale la definizione di **spazio di probabilità** $(\Omega, \mathcal{F}, P)$, in cui Ω è l'insieme di tutti i possibili esiti χ , $\mathcal{F}$ è una sigma-algebra su Ω e P è una misura di probabilità su $\mathcal{F}$. Un sottoinsieme $A \subset \Omega$ è chiamato evento e a ognuno di essi è possibile associare un numero reale $P(A) \in [0, 1]$ - ovvero la probabilità di tale evento.

In particolare è necessario che siano soddisfatte $P(\Omega) = 1$, $P(\emptyset) = 0$ e per ogni insieme di eventi numerabili disgiunti $\{A_i\}$ valga:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i). \quad (1.1)$$

Esempio 1.1.1: Tiri di un dado

Quando si tira un dado a sei facce si considera lo spazio degli eventi $\Omega = \{1, 2, \dots, 6\}$ e la misura di probabilità $P(\chi_i) = 1/6$ per ogni $\chi_i \in \Omega$. Un esempio di evento è il caso in cui il risultato del tiro sia pari $A = \{2, 4, 6\} \subset \Omega$ con probabilità calcolabile nel seguente modo: $P(A) = P(2) + P(4) + P(6) = 1/2$.

Una **variabile aleatoria** (reale) X associa ad ogni elemento χ di uno spazio degli esiti Ω un valore x appartenente a uno spazio misurabile $(\mathbb{R})$. Nel caso di una variabile aleatoria reale si ha quindi:

$$X : \Omega \rightarrow \mathbb{R}. \quad (1.2)$$

1.1.2 Distribuzioni di probabilità continue

Data una variabile aleatoria X essa ha associata una funzione **distribuzione cumulativa** $F_X(x)$, definita da:

$$F_X(x) = P(X \leq x). \quad (1.3)$$

Dunque la probabilità che X assuma un valore compreso tra due estremi a e b è data da:

$$P(a < X \leq b) = F_X(b) - F_X(a). \quad (1.4)$$

$F_X(x)$ è una funzione di x monotona, nondecrecente e definita su tutto l'asse reale con le proprietà:

$$\lim_{x \rightarrow -\infty} F_X(x) = 0, \quad \lim_{x \rightarrow +\infty} F_X(x) = 1. \quad (1.5)$$

Per una variabile aleatoria continua, la funzione di distribuzione cumulativa può essere espressa come integrale di una densità di probabilità

$$F_X(x) = \int_{-\infty}^x p_X(y) dy, \quad p_X(x) = \frac{d F_X(x)}{dx} \quad (1.6)$$

La densità di probabilità deve inoltre soddisfare la condizione di normalizzazione ed essere non negativa per ogni valore della variabile aleatoria:

$$\int_{-\infty}^{+\infty} p_X(x) dx = 1, \quad p_X(x) \geq 0 \quad \forall x \in \mathbb{R}. \quad (1.7)$$

È importante sottolineare che la densità di probabilità per una variabile aleatoria continua non rappresenta direttamente la probabilità che assuma un determinato valore: infatti la probabilità di assumere esattamente un valore x_0 è nulla. La densità di probabilità permette invece di calcolare la probabilità che la variabile aleatoria assuma un valore appartenente a un determinato intervallo. In particolare, la probabilità che X appartenga all'intervallo $[a, b]$ è data da

$$P(a \leq X \leq b) = \int_a^b p_X(x) dx. \quad (1.8)$$

La distribuzione di probabilità può quindi essere interpretata geometricamente: la probabilità associata a un intervallo corrisponde all'area sottesa dalla densità di probabilità nell'intervallo considerato. Una maggiore densità di probabilità in una determinata regione indica quindi una maggiore probabilità di osservare valori della variabile in quella regione [1].

Esempio 1.1.2: Variabile aleatoria uniforme

La variabile aleatoria uniforme U su (a, b) , con $a < b$, ha funzione di densità di probabilità $p_U(x) = \begin{cases} \frac{1}{b-a} & \text{se } a \leq x \leq b \\ 0 & \text{altrimenti} \end{cases}$

Nel seguito sarà particolarmente utile considerare variabili aleatorie multi-dimensionali. Una configurazione microscopica di un sistema fisico può infatti essere rappresentata mediante un vettore:

$$\mathbf{x} = (x_1, x_2, \dots, x_D) \in \mathbb{R}^D, \quad (1.9)$$

dove D rappresenta il numero di gradi di libertà del sistema. In questo caso la distribuzione di probabilità è descritta da una densità $p(\mathbf{x})$, normalizzata sulla totalità dello spazio delle configurazioni $\mathbb{R}^D$:

$$\int_{\mathbb{R}^D} p(\mathbf{x}) d\mathbf{x} = 1. \quad (1.10)$$

La densità $p(\mathbf{x})$ permette di determinare la probabilità che una configurazione appartenga a una determinata regione $\mathcal{A}$ dello spazio delle configurazioni:

$$P(\mathbf{x} \in \mathcal{A}) = \int_{\mathcal{A}} p(\mathbf{x}) d\mathbf{x}. \quad (1.11)$$

1.1.3 Distribuzioni unimodali e multimodali

Una distribuzione di probabilità può presentare una struttura caratterizzata dalla presenza di uno o più massimi locali. In particolare, si definisce distribuzione **unimodale** una distribuzione caratterizzata da un'unica regione di massima probabilità detta **modo**. Un esempio tipico è rappresentato dalla distribuzione gaussiana, che presenta un unico massimo in corrispondenza del suo valore medio.

Una distribuzione **multimodale**, invece, presenta più regioni distinte di alta probabilità, associate a più massimi locali della densità. In questo caso, ciascun massimo identifica un modo della distribuzione. Le diverse regioni ad alta probabilità possono essere separate da regioni caratterizzate da una densità molto più bassa. Il caso particolare in cui vi siano due massimi locali è detto distribuzione **bimodale**. La differenza qualitativa tra le due tipologie di distribuzioni è illustrata in Figura 1.1.




Figura 1.1: Confronto tra una distribuzione unimodale (gaussiana) e una distribuzione multimodale (bimodale).

La distinzione tra distribuzioni unimodali e multimodali è particolarmente importante nel problema del campionamento. Nel caso di una distribuzione unimodale, un metodo di campionamento che esplori efficacemente la regione attorno al massimo della distribuzione può ottenere un campione rappresentativo dell'intera distribuzione. Nel caso multimodale, invece, il campionamento può risultare più complesso, poiché è necessario esplorare tutte le regioni rilevanti dello spazio delle configurazioni e riprodurre correttamente la probabilità associata a ciascun modo e non esclusivamente a quello di maggiore densità.

Se le diverse regioni ad alta probabilità sono separate da zone di bassa probabilità, un metodo di campionamento locale può infatti rimanere confinato per lungo tempo all'interno di uno dei modi, esplorando con difficoltà gli altri. Il fenomeno è chiamato **intrappolamento in un modo** ed è una delle principali difficoltà associate al campionamento di distribuzioni multimodali, nonché una delle principali cause di inefficienza dei metodi di campionamento locali. In questi casi, è necessario adottare strategie più sofisticate per garantire un campionamento efficace e rappresentativo dell'intera distribuzione.

1.1.4 Valori di aspettazione e campionamento

Sia $p(\mathbf{x})$ la densità di probabilità della variabile aleatoria e $O(\mathbf{x})$ una funzione della variabile aleatoria, il valore di aspettazione di $O(\mathbf{x})$ è calcolabile tramite il seguente integrale:

$$\langle O(\mathbf{x}) \rangle = \int_{\mathbb{R}^D} O(\mathbf{x}) p(\mathbf{x}) d\mathbf{x}. \quad (1.12)$$

La convergenza dell'integrale non è affatto garantita e dipende dall'andamento della funzione $O(\mathbf{x})$ e da $p(\mathbf{x})$, inoltre questo integrale non è sempre facilmente risolvibile analiticamente o numericamente. Un approccio diretto al calcolo di $\langle O(\mathbf{x}) \rangle$ potrebbe basarsi su metodi di quadratura numerica [2], che discretizzano lo spazio delle configurazioni su una griglia e approssimano l'integrale come somma pesata sui punti della griglia.

Esempio 1.1.3: Metodo del trapezio

Nel caso unidimensionale il metodo di quadratura approssima l'integrale di una funzione $f(x)$ su un intervallo $[a, b]$ mediante la formula:

$$\int_a^b f(x) dx \approx \sum_i^N \int_{x_i-\epsilon}^{x_i+\epsilon} f(x) dx \quad (1.13)$$

dove x_i sono i punti della griglia e ϵ è la metà della distanza tra due punti consecutivi. Il metodo del trapezio approssima ciascun integrale locale con l'area di un trapezio, sostituendo l'integrale con:

$$\int_{x_i-\epsilon}^{x_i+\epsilon} f(x) dx \approx \frac{f(x_i - \epsilon) + f(x_i + \epsilon)}{2} \cdot 2\epsilon \quad (1.14)$$

Se lo spazio delle configurazioni ha dimensione D e si utilizzano N punti per ciascuna direzione, il numero totale di valutazioni della funzione integranda cresce come N^D . Per sistemi con un numero elevato di gradi di libertà, come tipicamente accade in meccanica statistica, questa crescita esponenziale rende i metodi di quadratura del tutto inapplicabili. In questi casi, il problema del calcolo di valori di aspettazione può essere affrontato in maniera più efficiente mediante metodi di campionamento, che permettono di stimare l'integrale senza la necessità di discretizzare lo spazio delle configurazioni.

L'idea alla base dei metodi di campionamento consiste - anziché valutare la funzione integranda su una griglia deterministica - nel generare un insieme di configurazioni $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ distribuite secondo la densità di probabilità $p(\mathbf{x})$, e nello stimare i valori di aspettazione mediante la media aritmetica:

$$\langle O(\mathbf{x}) \rangle \approx \frac{1}{N} \sum_{i=1}^N O(\mathbf{x}_i). \quad (1.15)$$

Per la legge dei grandi numeri la stima converge, per $N \rightarrow \infty$, al valore di aspettazione esatto $\langle O(\mathbf{x}) \rangle$, a patto che le configurazioni campionate $\mathbf{x}_i$ siano effettivamente distribuite secondo $p(\mathbf{x})$. Un aspetto cruciale di questo approccio è che, se le configurazioni sono indipendenti, l'errore statistico associato allo stimatore decresce col numero di campioni N come:

$$\sigma_{\langle O \rangle} \sim \frac{\sigma_O}{\sqrt{N}}, \quad (1.16)$$

dove σ_O è la deviazione standard di $O(\mathbf{x})$ rispetto a $p(\mathbf{x})$.

Diversamente dai metodi di quadratura, questo risultato non dipende esplicitamente dalla dimensione D dello spazio delle configurazioni: è questa caratteristica a rendere i metodi di campionamento lo strumento privilegiato per lo studio di sistemi ad alta dimensionalità. Il problema è dunque generare un insieme di configurazioni distribuite secondo $p(\mathbf{x})$ di modo da poter stimare i valori di aspettazione. I metodi con cui è possibile generare questi campioni saranno oggetto dei capitoli successivi

1.2 Meccanica statistica

1.2.1 Microstato, macrostato e ensemble statistico

Noi esseri umani percepiamo il mondo circostante ad un livello macroscopico, adoperiamo oggetti composti da atomi, ma ne ignoriamo i dettagli microscopici, ovvero lo stato specifico di ciascuno di essi. Se volessimo descrivere il sistema microscopicamente in modo completo, dovremmo tenere conto delle variabili dinamiche di tutte le particelle che lo compongono. Per un sistema macroscopico, il numero di gradi di libertà è enorme e una descrizione microscopica completa risulta quindi impraticabile. Un tipico esempio è la descrizione di un gas: in una mole di gas vi sono $\sim 10^{23}$ particelle e per seguire l'evoluzione temporale di ogni atomo o molecola sarebbe necessario risolvere l'equazione di Schrödinger per ciascuna di esse. Ovviamente il problema appena descritto è inaffrontabile e soprattutto inutile dal punto di vista pratico: si è interessati a descrivere il comportamento macroscopico di un sistema e non il moto di molte singole particelle. La meccanica statistica fornisce un formalismo per descrivere il comportamento macroscopico di un sistema a partire dalle proprietà microscopiche dei singoli elementi che lo costituiscono. In particolare, si concentra sullo studio di sistemi composti da un numero elevato di particelle, come gas, liquidi o solidi, e mira a derivare le leggi della termodinamica a partire dalle leggi della meccanica classica o quantistica [3].

In meccanica statistica, un **microstato** rappresenta una configurazione specifica del sistema, descritta da tutte le variabili microscopiche necessarie per caratterizzarlo completamente. Ad esempio, per un gas ideale, un microstato può essere definito dalle posizioni e dai momenti di tutte le particelle che lo compongono. Un **macrostato**, invece, è una descrizione più generale del sistema, caratterizzata da grandezze macroscopiche come energia, numero di particelle e volume. Un macrostato può corrispondere a molti microstati diversi: ad esempio, due configurazioni microscopiche diverse di un gas possono avere la stessa temperatura e pressione.




Figura 1.2: Rappresentazione schematica della relazione tra microstati e macrostato. Un macrostato può corrispondere a molteplici microstati, ognuno dei quali rappresenta una configurazione specifica del sistema.

Josiah Willard Gibbs (1839-1903) introdusse il concetto di **ensemble statistico**, che rappresenta un insieme di copie del sistema di interesse, ciascuna delle quali può trovarsi in uno dei possibili microstati compatibili con un dato macrostato. Se l'ensemble è sufficientemente grande, allora la probabilità di trovare il sistema in un particolare microstato è la frazione di copie dell'ensemble che si trovano in quel microstato. Vi sono diversi tipi di ensemble statistici, ognuno dei quali è adatto a descrivere sistemi con diversi vincoli. I principali ensemble sono:

- **Ensemble microcanonico:** Descrive un sistema isolato con energia, volume e numero di particelle costanti. Tutti i microstati compatibili con questi vincoli hanno la stessa probabilità.
- **Ensemble canonico:** Descrive un sistema a contatto termico con un serbatoio a temperatura fissa, in cui l'energia può fluttuare ma il numero di particelle è costante. La probabilità di un microstato è data dalla distribuzione di Boltzmann.
- **Ensemble grand-canonico:** Descrive un sistema a contatto con un serbatoio che può scambiare sia energia che particelle. La probabilità di un microstato è data dalla distribuzione Grand Canonica.

Per comprendere il comportamento di un sistema fisico, è fondamentale scegliere l'ensemble statistico appropriato in base alle condizioni sperimentali e ai vincoli imposti sul sistema. Questa tesi ha l'obiettivo di presentare metodi di campionamento per la distribuzione di Boltzmann, dunque nelle prossime sezioni si discuterà più nel dettaglio l'ensemble canonico e la relativa distribuzione.

1.2.2 L'ensemble canonico

Consideriamo un sistema fisico descritto da una hamiltoniana $\mathcal{H}(\mathbf{x})$, dove $\mathbf{x}$ rappresenta collettivamente i gradi di libertà del sistema, quali posizioni, impulsi o, più in generale, tutte le variabili necessarie a identificarne uno stato microscopico, ovvero una configurazione del sistema.

Supponiamo che il sistema sia posto a contatto con un **serbatoio termico** (o bagno termico), cioè un sistema macroscopico molto più grande del sistema in esame. I due sistemi possono scambiare energia, mentre il numero di particelle rimane costante. Una rappresentazione grafica della situazione fisica è la Figura 1.3. Grazie alle dimensioni macroscopiche del serbatoio, gli scambi di energia producono variazioni trascurabili del suo stato, cosicché esso può essere considerato in equilibrio ad una temperatura costante T .




Figura 1.3: Rappresentazione schematica dell'ensemble canonico: sistema (System), serbatoio termico (Bath) e flusso di calore fra i due sistemi (Heat Flow).

In queste condizioni l'energia del sistema può quindi fluttuare a causa degli scambi con il serbatoio, mentre il suo valore medio è fissato dalla temperatura del bagno termico. L'insieme di copie ideali del sistema, tutte caratterizzate dallo stesso numero di particelle e dalla medesima temperatura, prende il nome di **ensemble canonico**.

L'obiettivo della meccanica statistica è determinare la probabilità che il sistema si trovi in un determinato stato microscopico $\mathbf{x}$ di energia $\mathcal{H}(\mathbf{x})$. Tale probabilità è descritta dalla **distribuzione di Boltzmann** ricavabile tramite il principio di massima entropia, come mostrato nell'Appendice A.

1.2.3 La distribuzione di Boltzmann

La distribuzione di Boltzmann descrive la probabilità di osservare il sistema in una configurazione microscopica quando esso si trova all'equilibrio termico con un serbatoio a temperatura T fissata.

Dalla massimizzazione dell'entropia, soggetta ai vincoli di normalizzazione della distribuzione e di valore medio dell'energia costante, si ottiene

$$p(\mathbf{x}, T) = \frac{1}{Z(\beta)} e^{-\beta \mathcal{H}(\mathbf{x})}, \quad Z(\beta) = \int_{\mathbb{R}^D} e^{-\beta \mathcal{H}(\mathbf{x})} d\mathbf{x} \quad (1.17)$$

dove $\beta = \frac{1}{k_B T}$ e $Z(\beta)$ è la funzione di partizione.

Il prodotto $\beta \mathcal{H}(\mathbf{x})$ determina il peso relativo delle configurazioni nella distribuzione. Si può facilmente comprendere come all'aumentare della temperatura sono probabilisticamente permessi una gamma più ampia di stati; al diminuire della temperatura, invece, la probabilità si concentra progressivamente negli stati di energia minima. Inoltre, la funzione di partizione svolge un ruolo centrale,

poiché garantisce la normalizzazione della distribuzione e da essa possono essere ricavate le principali grandezze termodinamiche del sistema.

L'energia libera di Helmholtz è

$$F = -k_B T \ln Z. \quad (1.18)$$

L'energia media è

$$\langle E \rangle = -\frac{\partial \ln Z}{\partial \beta}. \quad (1.19)$$

La capacità termica a volume costante è

$$C_V = \frac{\partial \langle E \rangle}{\partial T} = k_B \beta^2 (\langle E^2 \rangle - \langle E \rangle^2), \quad (1.20)$$

mentre l'entropia è

$$S = -\left(\frac{\partial F}{\partial T}\right)_V = k_B (\ln Z + \beta \langle E \rangle). \quad (1.21)$$

Nella maggior parte dei sistemi di interesse fisico la funzione di partizione non può essere calcolata in forma chiusa. Essa richiede infatti l'integrazione della quantità:

$$e^{-\beta \mathcal{H}(\mathbf{x})} \quad (1.22)$$

su tutto lo spazio delle configurazioni, che è uno spazio multidimensionale di dimensione pari al numero di gradi di libertà del sistema. Per sistemi costituiti da molte particelle il calcolo diretto dell'integrale è proibitivo: basti pensare ad un gas ideale con un numero di Avogadro ($\sim 10^{23}$) di particelle.

Di conseguenza, anche il valore della densità di probabilità normalizzata non è generalmente noto, poiché dipende dalla funzione di partizione. Tuttavia è possibile valutare il rapporto tra le densità di probabilità di due configurazioni

$$\frac{p(\mathbf{x}_2, T)}{p(\mathbf{x}_1, T)} = e^{-\beta [\mathcal{H}(\mathbf{x}_2) - \mathcal{H}(\mathbf{x}_1)]}, \quad (1.23)$$

nel quale il fattore di normalizzazione $Z(\beta)$ si semplifica. Questa osservazione è importante per i capitoli successivi, poiché per poter campionare la distribuzione di Boltzmann è necessario disporre di metodi in grado di generare configurazioni distribuite secondo la distribuzione target anche quando questa è nota soltanto a meno della costante di normalizzazione.

1.3 Campionamento: diretto e markoviano

Il problema centrale di questa tesi - generare configurazioni distribuite secondo la distribuzione di Boltzmann - non ammette un'unica strategia algoritmica. Prima di addentrarci nei metodi concreti, è utile costruire una mappa concettuale delle possibili strategie, in modo che le differenze fra i metodi presentati nei capitoli successivi risultino chiare fin da subito.

Diretto vs Markov La prima distinzione riguarda *come* viene prodotta una configurazione. Si parla di **campionamento diretto** quando è possibile generare direttamente campioni indipendenti distribuiti secondo $p(\mathbf{x})$. Il prezzo che viene richiesto è di conoscere analiticamente la distribuzione target: nel Capitolo 2 si mostra un metodo efficace per distribuzioni unidimensionali semplici, ovvero il metodo dell'inversa (Sezione 2.2), che è un metodo esatto di campionamento diretto.

Quando il campionamento diretto non è una scelta possibile per il problema che si vuole affrontare, si può ricorrere a una strategia alternativa: costruire una successione di configurazioni in cui ciascuna dipenda *solo* dalla precedente. Una successione con questa proprietà è una **catena di Markov**, ed è alla base dei metodi **Markov Chain Monte Carlo (MCMC)**, presentati nella Sezione 2.3. La catena non produce istantaneamente un campione dalla distribuzione corretta: è necessario *iterare* finché la catena non abbia raggiunto la propria distribuzione stazionaria, una fase detta **termalizzazione**. Inoltre ogni configurazione dipende da quella precedente, le configurazioni generate non sono statisticamente indipendenti ma **correlate**: due passi successivi tendono a essere più simili di due configurazioni estratte direttamente, il che riduce l'informazione statistica effettivamente contenuta in N passi della catena rispetto a N campioni indipendenti.

Il vantaggio decisivo dell'approccio markoviano, che ne spiega la centralità in fisica statistica, è che la catena può essere costruita conoscendo $p(\mathbf{x})$ anche a meno della costante di normalizzazione, condizione tipicamente verificata per la distribuzione di Boltzmann, la cui funzione di partizione $Z(\beta)$ non è in generale calcolabile.

Passo locale e globale Una seconda distinzione, interna al campionamento markoviano, riguarda la natura della configurazione candidata proposta a ogni passo della catena. Si parla di **passo locale** quando la configurazione proposta è ottenuta perturbando quella corrente con uno spostamento di ampiezza limitata: è questo il caso dell'algoritmo di Metropolis-Hastings (Sezione 2.3.2). Un passo locale è una scelta semplice ed economica, ma la sua efficacia dipende criticamente dalla struttura di $p(\mathbf{x})$: se la distribuzione è multimodale e i modi sono separati da regioni di bassa probabilità, una successione di piccoli spostamenti può impiegare un tempo computazionale enorme per attraversare la regione a bassa densità che separa due modi, rimanendo di fatto *intrappolata in un modo*. Si parla invece di **passo globale** quando la configurazione candidata può discostarsi significativamente da quella corrente, fino al caso limite in cui è generata indipendentemente da essa, attingendo a un'intera distribuzione di proposta definita su tutto lo spazio delle configurazioni. Una catena costruita in questo modo non soffre per costruzione dell'intrappolamento nei modi, poiché ogni proposta esplora potenzialmente l'intero spazio indipendentemente da dove si trovi la catena. La sua efficienza dipende però interamente dalla qualità della distribuzione di proposta: se questa è troppo diversa dalla distribuzione target, la probabilità che una proposta venga accettata può essere troppo bassa, vanificando il vantaggio teorico del passo globale. La Figura 1.4 illustra qualitativamente la differenza

fra passo locale e passo globale su una distribuzione bimodale: nel primo caso il camminatore esplora un modo alla volta, nel secondo può spostarsi direttamente da un modo all'altro.




Figura 1.4: Rappresentazione della differenza fra passo locale e globale per un MCMC con obiettivo il campionamento di una mistura di due gaussiane. L'immagine in alto mostra in blu cinque passi locali, mentre l'immagine in basso mostra in verde lo stesso numero di passi globali.

Le due strategie discusse in questa sezione possono non essere alternative e diventare complementari. Un **Normalizing Flow (NF)** (Capitolo 3) addestrato ad approssimare $p(\mathbf{x})$ costituisce infatti un candidato naturale come **distribuzione di proposta** per un MCMC: pur non fornendo un campionamento diretto esatto, il flow può fungere da motore per mosse globali all'interno di una catena di Markov. Il metodo ibrido così ottenuto - **Flow-MCMC**, discusso nella Sezione ?? - combina la correttezza asintotica garantita dalla struttura markoviana con la capacità di esplorazione globale offerta dal flow.

Nei seguenti capitoli si utilizza la seguente notazione

$$\mathbf{x} \sim p(\mathbf{x}), \quad (1.24)$$

per indicare il campionamento di una configurazione $\mathbf{x}$ estratta dalla distribuzione di probabilità $p(\mathbf{x})$.

I tre metodi confrontati in questa tesi si collocano dunque rispettivamente nel campionamento markoviano a mosse locali (MCMC, Sezione 2.3), nel campionamento diretto approssimato (Normalizing Flow, Sezione 3.1), e nel campionamento markoviano a mosse globali (Flow-MCMC, Sezione ??).




Figura 1.5: Mappa concettuale dei vari metodi di campionamento e quali sono presentati in questa tesi ed in che capitoli.

CAPITOLO 2

Metodi Monte Carlo

I metodi Monte Carlo rappresentano una classe di tecniche numeriche che permettono di stimare quantità altrimenti inaccessibili per via analitica, sostituendo il calcolo esatto con una stima statistica basata sul campionamento casuale. In fisica statistica questo approccio è particolarmente prezioso: il calcolo di valori di aspettazione rispetto alla distribuzione di Boltzmann richiede in generale la valutazione di integrali in uno spazio delle configurazioni ad altissima dimensionalità, per cui le tecniche di quadratura deterministica diventano rapidamente inapplicabili. L'idea alla base del metodo — sostituire il calcolo esatto con una stima ottenuta da un numero sufficiente di "prove" — nacque in un contesto scientifico unico a livello storico, per poi diventare uno degli strumenti computazionali più importanti del Novecento.

In questo capitolo vengono introdotti i concetti e gli algoritmi più importanti dei metodi Monte Carlo. Si introdurrà il contesto storico in cui è nato il metodo (Sezione 2.1), per poi discutere un metodo Monte Carlo di campionamento diretto (Sezione 2.2) e uno markoviano (Sezione 2.3), presentando prima le catene di Markov. Infine si discuterà di un aspetto cruciale per Markov Chain Monte Carlo, ovvero la presenza di correlazione tra i campioni generati, che rende necessaria un'attenta analisi statistica per una corretta stima degli errori (Sezione 2.4).

2.1 Cenni storici

L'idea che un processo casuale possa essere utilizzato per stimare una quantità analitica non è nuova al Novecento. Il primo esempio documentato risale al 1777, quando Georges-Louis Leclerc, conte di Buffon, propose il celebre esperimento dell'ago [4]: un ago di lunghezza L viene lanciato a caso su un piano rigato da linee parallele distanti $d > L$, e si chiede la probabilità che l'ago intersechi una delle linee. Buffon non solo condusse l'esperimento fisicamente, lanciando l'ago numerose volte, ma ne derivò anche la soluzione analitica


$$P = \frac{2L}{\pi d}. \quad (2.1)$$

Alcuni anni dopo, Laplace osservò che questa stessa relazione poteva essere invertita per stimare π a partire dalla frequenza empirica delle intersezioni: un primo esempio, seppur rudimentale e a convergenza lenta, di determinazione stocastica di una costante analitica a partire da un esperimento casuale [5].


Fu tuttavia solo nel XX secolo, con l'avvento dei primi calcolatori elettronici, che questa intuizione si trasformò in un metodo computazionale sistematico. Il metodo Monte Carlo, nella forma in cui lo intendiamo oggi, nacque da un'idea

di Stanisław Ulam (Figura 2.1a) - fisico e matematico polacco naturalizzato statunitense - durante una partita di solitario. La frustrazione del matematico nel cercare di calcolare analiticamente la probabilità di vincere una partita lo portò a realizzare che una buona stima di quest'ultima sarebbe stata possibile evitando completamente i calcoli. Ulam capì che, se avesse giocato un numero sufficiente di partite, avrebbe potuto stimarla segnandosi quante di queste prove avrebbe vinto o perso. L'idea dal semplice gioco si spostò poi alla risoluzione di problemi di matematica e fisica: con i primi computer elettronici sarebbe stato possibile simulare un sistema generando campioni virtuali dello stesso così da ottenere stime accurate delle quantità ricercate. All'epoca Ulam lavorava assieme a John von Neumann (Figura 2.1b) presso il Los Alamos National Laboratory, che durante la seconda guerra mondiale era un centro di ricerca segreto per lo sviluppo della prima bomba nucleare. Qui era stato costruito l'ENIAC (Electronic Numerical Integrator And Computer) uno dei primi computer elettronici digitali general purpose della storia. I due scienziati lavorarono ad una procedura stocastica basata sull'idea del matematico polacco per simulare il trasporto dei neutroni attraverso un materiale fissile. Il nome "Monte Carlo" fu proposto nel 1947 da un altro celebre fisico del gruppo, Nicholas Constantine Metropolis [6]. La scelta del nome, ispirata al celebre casinò situato nel Principato di Monaco, nacque per canzonare Ulam, il quale aveva uno zio con il vizio del gioco d'azzardo.


Vi è inoltre un precursore del metodo: Enrico Fermi (Figura 2.1c). Metropolis parlando con Emilio Segrè scoprì che Fermi aveva già ideato, in modo del tutto indipendente, un metodo basato sul campionamento statistico quindici anni prima di loro. Lo stesso Fermi infatti partecipando al progetto Manhattan (1942-1946) aiutò nello studio del trasporto dei neutroni costruendo insieme a Percy King il FERMIAC. Noto anche con il nome *Il carrello Monte Carlo*, il FERMIAC era un computer analogico che permetteva di sviluppare genealogie di neutroni in due dimensioni, o modelli di comportamento di neutroni individuali, comprendenti ciascuno collisioni, diffusione e fissioni. In ogni fase venivano usati numeri pseudo-casuali per ricavare le decisioni che influenzano il comportamento di ciascun neutrone.



(a) Stanisław Ulam e il FERMIAC.



(b) Von Neumann.



(c) Enrico Fermi.

Figura 2.1: I pionieri del metodo Monte Carlo.

2.2 Metodo dell'inversa

Il metodo dell'inversa (o *inverse transform sampling*) è una tecnica di campionamento *diretto*: essa consente di generare campioni distribuiti secondo una generica densità di probabilità unidimensionale $p_X(x)$ a partire da una variabile aleatoria distribuita uniformemente nell'intervallo $[0, 1]$ [7].

Sia X una variabile aleatoria continua con funzione di distribuzione cumulativa $F_X(x) = P(X \leq x)$ strettamente monotona e continua, tale da ammettere una funzione inversa $F_X^{-1} : (0, 1) \rightarrow \mathbb{R}$. Sia inoltre $U \sim \mathcal{U}(0, 1)$ una variabile aleatoria uniforme sull'intervallo $(0, 1)$.

Si consideri la variabile aleatoria definita dalla trasformazione inversa:

$$Y = F_X^{-1}(U). \quad (2.2)$$

Per definizione di funzione di distribuzione cumulativa:

$$F_Y(y) = P(Y \leq y) = P(F_X^{-1}(U) \leq y). \quad (2.3)$$

Poiché $F_X(x)$ è per ipotesi strettamente monotona crescente, $F_X(x)$ preserva il verso delle disuguaglianze: applicando F_X ad entrambi i membri della disuguaglianza $F_X^{-1}(U) \leq y$ si ottiene una disuguaglianza equivalente,

$$F_X^{-1}(U) \leq y \iff F_X(F_X^{-1}(U)) \leq F_X(y). \quad (2.4)$$

Per definizione di funzione inversa, $F_X(F_X^{-1}(U)) = U$; sostituendo questa identità nella probabilità si ha dunque:

$$F_Y(y) = P(F_X^{-1}(U) \leq y) = P(U \leq F_X(y)). \quad (2.5)$$

Ricordando che per una variabile aleatoria uniforme $U \sim \mathcal{U}(0, 1)$ vale la proprietà $P(U \leq u) = u \quad \forall u \in [0, 1]$, e osservando che $F_X(y) \in [0, 1]$ per definizione di funzione di distribuzione cumulativa, si ha direttamente:

$$P(U \leq F_X(y)) = F_X(y), \quad (2.6)$$

e dunque

$$F_Y(y) = F_X(y). \quad (2.7)$$

Pertanto Y e X hanno la stessa distribuzione.

L'applicazione pratica del metodo dell'inversa per la generazione di N campioni indipendenti è sintetizzata nel seguente Algoritmo 1:

Algorithm 1: Metodo dell'Inversa (Inverse Transform Sampling)

Input: Numero di campioni N ; funzione di distribuzione cumulativa inversa $F_X^{-1}(u)$.

Inizializza l'insieme dei campioni $\mathcal{S} = \emptyset$;

for $i = 1$ **to** N **do**

 Genera $u_i \sim \mathcal{U}(0, 1)$;

 Calcola $x_i = F_X^{-1}(u_i)$;

 Aggiungi x_i all'insieme $\mathcal{S}$;

end

Output: Insieme di campioni $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ distribuiti secondo $p_X(x)$.

Si mostra un esempio pratico di applicazione del metodo dell'inversa per il campionamento della distribuzione esponenziale, che illustra chiaramente i passaggi descritti nell'algoritmo precedente.

Esempio 2.2.1: Campionamento della distribuzione esponenziale

Si consideri la distribuzione esponenziale con parametro $\lambda > 0$:

$$p_X(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x \geq 0, \\ 0 & \text{se } x < 0. \end{cases} \quad (2.8)$$

La relativa funzione di distribuzione cumulativa per $x \geq 0$ è data da:

$$F_X(x) = \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}. \quad (2.9)$$

Uguagliando $F_X(x)$ a una variabile uniforme $u \in (0, 1)$ e invertendo la relazione:

$$u = 1 - e^{-\lambda x} \implies 1 - u = e^{-\lambda x} \implies x = -\frac{1}{\lambda} \ln(1 - u). \quad (2.10)$$

Poiché se $u \sim \mathcal{U}(0, 1)$ anche $(1 - u) \sim \mathcal{U}(0, 1)$, la formula generatrice si semplifica spesso in:

$$x = -\frac{1}{\lambda} \ln(u). \quad (2.11)$$

Il principale vantaggio del metodo dell'inversa risiede nella sua efficienza e semplicità: ciascun campione generato è perfettamente indipendente dagli altri e non vi è alcuna probabilità di rifiuto (a differenza dei metodi di Acceptance-Rejection o dei metodi Markov Chain Monte Carlo).

Tuttavia, il metodo presenta forti limitazioni pratiche, che ne riducono l'applicabilità a distribuzioni di probabilità complesse o multidimensionali:

- **Invertibilità analitica:** Richiede che la funzione di distribuzione cumulativa $F_X(x)$ sia invertibile in forma chiusa (o approssimabile numericamente con elevata precisione).
- **Costante di normalizzazione:** È applicabile solo se la densità di probabilità $p_X(x)$ è perfettamente normalizzata.
- **Dimensionalità:** Risulta di difficile estensione a distribuzioni ad alta dimensionalità $D \gg 1$, rendendolo generalmente impraticabile per il campionamento diretto della distribuzione di Boltzmann di sistemi ad alta dimensionalità.

2.3 Markov Chain Monte Carlo

2.3.1 Catene di Markov

Sia $\{X_1, \dots, X_N\}$ una sequenza di variabili aleatorie in $\mathbb{R}^D$, questa sequenza è una catena di Markov se la probabilità condizionata di ogni X_i soddisfa:

$$P(X_i|X_{i-1}, \dots, X_1) = P(X_i|X_{i-1}). \quad (2.12)$$

Dunque la probabilità di ottenere un certo valore di X_i dipende solo dalla variabile aleatoria precedente della catena e non dalle altre, questa richiesta equivale a dire che le catene di Markov sono catene *senza memoria*, ovvero che solo l'ultimo stato della catena influenza il prossimo stato [8]. Considerando il caso che la variabile aleatoria X_i possa assumere un numero discreto di valori, ovvero che $X_i \in \{\mathbf{x}_1, \dots, \mathbf{x}_j, \dots\}$, in questo modo possiamo descrivere la distribuzione di probabilità e le probabilità condizionate di tali variabili utilizzando un vettore e una matrice rispettivamente:

$$P(X_i) = p_j^{(i)} = \begin{pmatrix} p^{(i)}(\mathbf{x}_1) \\ \vdots \\ p^{(i)}(\mathbf{x}_j) \\ \vdots \end{pmatrix}, \quad P(X_i|X_j) = P_{ij} = \begin{pmatrix} P(\mathbf{x}_1|\mathbf{x}_1) & \cdots & P(\mathbf{x}_1|\mathbf{x}_j) & \cdots \\ P(\mathbf{x}_2|\mathbf{x}_1) & \cdots & P(\mathbf{x}_2|\mathbf{x}_j) & \cdots \\ \vdots & \ddots & \vdots & \\ P(\mathbf{x}_i|\mathbf{x}_1) & \cdots & P(\mathbf{x}_i|\mathbf{x}_j) & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix} \quad (2.13)$$

La matrice P_{ij} rappresenta la probabilità di transizione dallo stato j allo stato i . Inoltre possiamo notare alcune proprietà interessanti sia per $p_j^{(i)}$ che per P_{ij} , esse soddisfano:

$$\sum_j p_j^{(i)} = 1 \quad \forall i, \quad \sum_i P_{ij} = 1 \quad \forall j. \quad (2.14)$$

Data una distribuzione iniziale $p_i^{(0)}$ e la matrice stocastica P_{ij} detta **matrice di transizione**, si può evolvere la distribuzione in modo ricorsivo:

$$p_i^{(k+1)} = \sum_j P_{ij} p_j^{(k)} \quad \text{con } k \in \mathbb{N}. \quad (2.15)$$

Questa evoluzione della distribuzione di probabilità della catena conserva la normalizzazione della distribuzione, infatti:

$$\sum_i p_i^{(k+1)} = \sum_i \sum_j P_{ij} p_j^{(k)} = \sum_j p_j^{(k)} \sum_i P_{ij} = \sum_j p_j^{(k)} = 1. \quad (2.16)$$

Inoltre considerando una matrice di transizione ergodica (ovvero irriducibile e aperiodica) è assicurato che a prescindere dalla distribuzione iniziale $p_i^{(0)}$ - iterando il procedimento di evoluzione - si converge ad una **distribuzione stazionaria** p_i tale che:

$$p_i = \sum_j P_{ij} p_j. \quad (2.17)$$

Ovvero una distribuzione di probabilità che non viene più modificata iterando il procedimento (per questo detta stazionaria), inoltre essa è l'autovettore della matrice di transizione P_{ij} con autovalore unitario. L'obiettivo di Markov Chain Monte Carlo è quello di costruire una catena di Markov che abbia come distribuzione stazionaria la distribuzione target p_i che si vuole campionare. Per fare ciò è necessario costruire una matrice di transizione P_{ij} costruita in un certo modo, garantendo la validità dell'Equazione 2.17. Metropolis et al. (1953) proposero

che fosse possibile ottenere una specifica distribuzione p_i se la P_{ij} soddisfa una certa condizione detta di **bilancio dettagliato** (detailed balance condition):

$$P_{ij}p_j = P_{ji}p_i. \quad (2.18)$$

Sommando entrambi i membri su i e sfruttando la stocasticità delle colonne di P_{ij} (Equazione 2.14), si verifica facilmente che il bilancio dettagliato garantisce la stazionarietà ed è dunque una condizione *sufficiente* ma non *necessaria*.

Esempio 2.3.1: Meteo a tre stati


Consideriamo tre stati possibili: x_1 = Sole, x_2 = Nuvoloso e x_3 = Pioggia; che rappresentano le tre condizioni meteorologiche possibili in un giorno. Sia X_i la variabile aleatoria discreta che descrive la condizione meteorologica osservata al giorno i .

Si assume che la sequenza $X_1, X_2, \dots, X_N$ costituisca una catena di Markov secondo la definizione data in Equazione 2.12: il tempo che farà domani dipende soltanto dal tempo di oggi. Questa è chiaramente un'approssimazione della realtà fisica.

La matrice di transizione, che fornisce la probabilità di osservare lo stato x_i il giorno successivo dato lo stato x_j nel giorno corrente, è data da:

$$P_{ij} = \begin{pmatrix} P(x_1 | x_1) & P(x_1 | x_2) & P(x_1 | x_3) \\ P(x_2 | x_1) & P(x_2 | x_2) & P(x_2 | x_3) \\ P(x_3 | x_1) & P(x_3 | x_2) & P(x_3 | x_3) \end{pmatrix} = \begin{pmatrix} 0.7 & 0.3 & 0.2 \\ 0.2 & 0.4 & 0.3 \\ 0.1 & 0.3 & 0.5 \end{pmatrix}. \quad (2.19)$$

La matrice d'esempio rispetta l'Equazione 2.14, ovvero che ogni colonna somma ad 1. Il grafo delle transizioni è illustrato in Figura 2.3.1.



Se oggi è nuvoloso, la distribuzione iniziale è $p^{(0)} = (0, 1, 0)^T$, e la distribuzione di probabilità sul tempo di domani si ottiene applicando l'Equazione 2.15:

$$p_i^{(1)} = \sum_j P_{ij} p_j^{(0)} = \begin{pmatrix} 0.3 \\ 0.4 \\ 0.3 \end{pmatrix}. \quad (2.20)$$

Il formalismo matematico delle catene di Markov descritto per variabili discrete è estremamente flessibile e può essere generalizzato al caso continuo sostituendo la sommatoria con l'integrazione. Nel caso continuo, la distribuzione di probabilità stazionaria p_i diventa una densità di probabilità

$$p(\mathbf{x}) = \frac{f(\mathbf{x})}{\int_{\mathbb{R}^D} f(\mathbf{x}) d\mathbf{x}}, \quad (2.21)$$

e la matrice di transizione P_{ij} viene sostituita da un kernel di transizione continuo:

$$\pi: \mathbb{R}^D \times \mathbb{R}^D \rightarrow \mathbb{R}^+ \quad (2.22)$$

che definisce la probabilità di transizione tra stati dello spazio continuo [9]. L'evoluzione ricorsiva della distribuzione al passo $(i+1)$ assume quindi la forma:

$$p^{(i+1)}(\mathbf{x}) = \int_{\mathbb{R}^D} d\mathbf{y} \pi(\mathbf{x}, \mathbf{y}) p^{(i)}(\mathbf{y}) \quad (2.23)$$

Per garantire che la catena converga a una specifica distribuzione stazionaria di target $p(\mathbf{x})$, il kernel di transizione deve soddisfare la condizione di bilancio dettagliato:

$$\pi(\mathbf{x}, \mathbf{y}) p(\mathbf{y}) = \pi(\mathbf{y}, \mathbf{x}) p(\mathbf{x}) \quad (2.24)$$

Sotto condizioni di ergodicità, facendo evolvere gli elementi della catena attraverso tale kernel, si ottiene una sequenza di campioni $\{\mathbf{x}_i\}_{i=1}^N$. Dopo un certo tempo t sufficientemente grande, detto *tempo di termalizzazione* (o *burn-in time*), i campioni generati risulteranno distribuiti secondo la distribuzione target $p(\mathbf{x})$:

$$\mathbf{x}_i \sim p(\mathbf{x}) = \frac{f(\mathbf{x})}{\int d\mathbf{x} f(\mathbf{x})} \quad \text{per } i > t \quad (2.25)$$

Nella sezione successiva verrà presentato l'algoritmo di Metropolis-Hastings, che permette di costruire un kernel π che soddisfa la condizione di bilancio dettagliato permettendo di campionare una distribuzione target $p(\mathbf{x})$, conoscendone anche soltanto la forma non normalizzata $f(\mathbf{x})$.

2.3.2 L'Algoritmo di Metropolis-Hastings

Il problema di costruire un opportuno kernel $\pi(\mathbf{x}, \mathbf{y})$ che garantisca la convergenza a una data distribuzione target $p(\mathbf{x})$ è stato studiato da Metropolis [10] e successivamente generalizzato da Hastings [11]. La soluzione generalizzata esprime il kernel di transizione come prodotto di due termini:

$$\pi(\mathbf{x}, \mathbf{y}) = \Gamma(\mathbf{x} \rightarrow \mathbf{y}) \mathcal{A}(\mathbf{x}, \mathbf{y}). \quad (2.26)$$

Il termine $\Gamma(\mathbf{x} \rightarrow \mathbf{y})$ è la **distribuzione di proposta** (*proposal distribution*), che definisce la probabilità di proporre uno spostamento dallo stato $\mathbf{x}$ allo stato $\mathbf{y}$, mentre $\mathcal{A}(\mathbf{x}, \mathbf{y})$ è il **tasso di accettazione** (*acceptance ratio*), definito come:

$$\mathcal{A}(\mathbf{x}, \mathbf{y}) = \min \left\{ 1, \frac{\Gamma(\mathbf{y} \rightarrow \mathbf{x}) f(\mathbf{y})}{\Gamma(\mathbf{x} \rightarrow \mathbf{y}) f(\mathbf{x})} \right\}. \quad (2.27)$$

Assumendo che la distribuzione di proposta sia normalizzata e strettamente positiva:

$$\int \Gamma(\mathbf{x} \rightarrow \mathbf{y}) d\mathbf{y} = 1, \quad \Gamma(\mathbf{x} \rightarrow \mathbf{y}) > 0 \quad (2.28)$$

Si dimostra che il kernel così costruito soddisfa la condizione di bilancio dettagliato:

$$\pi(\mathbf{x}, \mathbf{y}) \frac{f(\mathbf{y})}{\int d\mathbf{x} f(\mathbf{x})} = \pi(\mathbf{y}, \mathbf{x}) \frac{f(\mathbf{x})}{\int d\mathbf{x} f(\mathbf{x})}. \quad (2.29)$$

A livello computazionale, il procedimento per generare lo stato $\mathbf{x}_{i+1}$ a partire dallo stato corrente $\mathbf{x}_i$ segue la procedura descritta nell'Algoritmo 2.

Algorithm 2: Algoritmo di Metropolis-Hastings

Input: Stato corrente $\mathbf{x}_i$; distribuzione target non normalizzata $f(\mathbf{x})$;

distribuzione di proposta $\Gamma(\mathbf{x} \rightarrow \mathbf{y})$.

Genera un candidato $\mathbf{y} \sim \Gamma(\mathbf{x}_i \rightarrow \mathbf{y})$;

Genera $u \sim \mathcal{U}(0, 1)$;

Calcola il tasso di accettazione $\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left(1, \frac{\Gamma(\mathbf{y} \rightarrow \mathbf{x}_i) f(\mathbf{y})}{\Gamma(\mathbf{x}_i \rightarrow \mathbf{y}) f(\mathbf{x}_i)} \right)$;

if $u < \mathcal{A}(\mathbf{x}_i, \mathbf{y})$ **then**

 | Imposta $\mathbf{x}_{i+1} = \mathbf{y}$;

 // Proposta accettata

else

 | Imposta $\mathbf{x}_{i+1} = \mathbf{x}_i$;

 // Proposta rifiutata

end

Output: Nuovo stato $\mathbf{x}_{i+1}$.

L'iterazione di questa operazione, dopo la necessaria termalizzazione, permette di creare la catena di campioni distribuiti secondo la distribuzione target, questo procedimento è rappresentato graficamente in Figura 2.2.




Figura 2.2: Leggendo la figura da sinistra verso destra: si estrae da una distribuzione uniforme il primo campione della catena, successivamente si utilizza l'algoritmo di Metropolis-Hastings di cui si possono vedere i passi locali accettati e rifiutati. Infine i campioni generati seguono la distribuzione stazionaria ricercata.

Un caso comune prevede l'uso di uno spostamento gaussiano simmetrico, in cui :

$$\mathbf{y} = \mathbf{x}_i + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \sigma^2) \quad (2.30)$$

Poiché la proposta è simmetrica ($\Gamma(\mathbf{x} \rightarrow \mathbf{y}) = \Gamma(\mathbf{y} \rightarrow \mathbf{x})$), il tasso di accettazione si semplifica nel rapporto diretto tra le densità di target:

$$\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left\{ 1, \frac{f(\mathbf{y})}{f(\mathbf{x}_i)} \right\} \quad (2.31)$$

È possibile osservare che, nel caso di una distribuzione di proposta simmetrica, il valore di π dipende esclusivamente dal rapporto tra i pesi delle due configurazioni considerate. Essa è quindi indipendente dalla costante di normalizzazione della distribuzione target. Come già espresso nel capitolo precedente, questo è un aspetto cruciale per il campionamento della distribuzione di Boltzmann, in quanto la costante di normalizzazione della distribuzione è proprio la funzione di partizione, di cui non è sempre possibile calcolare analiticamente o numericamente. Sostituendo la distribuzione di Boltzmann come distribuzione target otteniamo un tasso di accettazione della forma:

$$\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left\{ 1, \frac{e^{-\beta \mathcal{H}(\mathbf{y})}}{e^{-\beta \mathcal{H}(\mathbf{x}_i)}} \right\}. \quad (2.32)$$

2.4 Campioni autocorrelati

Autocorrelazione. Essendo MCMC un metodo di campionamento non diretto, i campioni generati sono correlati fra loro. Questo impone una stima dell'errore più complicata del caso semplice di campioni indipendenti. Considerando un osservabile $O(\mathbf{x})$ siamo interessati al valore medio e alla varianza di quest'ultimo:

$$\langle O \rangle = \int_{\mathbb{R}^D} p(\mathbf{x}) O(\mathbf{x}) d\mathbf{x}, \quad \sigma_O^2 = \langle O^2 \rangle - \langle O \rangle^2. \quad (2.33)$$

Possiamo stimare entrambe le quantità - come detto in precedenza - con il campionamento della distribuzione target $p(\mathbf{x})$. Utilizzando come stima la media aritmetica $\bar{O}$ per N campioni estratti:

$$\bar{O} = \frac{1}{N} \sum_{i=1}^N O(\mathbf{x}_i), \quad \sigma_{\bar{O}}^2 = \langle \bar{O}^2 \rangle - \langle \bar{O} \rangle^2 \quad (2.34)$$

Per la legge dei grandi numeri, $\bar{O}$ converge a $\langle O \rangle$ per $N \rightarrow +\infty$. Il calcolo della varianza può essere riscritto, sviluppando il quadrato della media come doppia somma sugli indici i, j e usando la linearità del valore atteso,

$$\sigma_{\bar{O}}^2 = \left\langle \left(\frac{1}{N} \sum_{i=1}^N O(\mathbf{x}_i) \right) \left(\frac{1}{N} \sum_{j=1}^N O(\mathbf{x}_j) \right) \right\rangle - \left(\frac{1}{N} \sum_{i=1}^N \langle O(\mathbf{x}_i) \rangle \right) \left(\frac{1}{N} \sum_{j=1}^N \langle O(\mathbf{x}_j) \rangle \right). \quad (2.35)$$

Sviluppando il quadrato di entrambe le somme come doppie somme sugli indici i, j , e usando la linearità del valore atteso per il primo termine e raccogliendo i due termini sotto lo stesso segno di somma:

$$\sigma_O^2 = \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N (\langle O(\mathbf{x}_i) O(\mathbf{x}_j) \rangle - \langle O(\mathbf{x}_i) \rangle \langle O(\mathbf{x}_j) \rangle). \quad (2.36)$$

Definendo **funzione di correlazione**:

$$\chi_{|i-j|} = \langle O(\mathbf{x}_i) O(\mathbf{x}_j) \rangle - \langle O(\mathbf{x}_i) \rangle \langle O(\mathbf{x}_j) \rangle, \quad (2.37)$$

che per un processo stazionario dipende solo dalla distanza temporale $|i-j|$ (e per cui vale $\chi_0 = \sigma_O^2$), la doppia somma può essere riscritta raggruppando i termini a parità di $k = |i-j|$. Poiché $\forall k \geq 1$ esistono $2(N-k)$ coppie (i, j) con $|i-j| = k$, si ottiene:

$$\sigma_O^2 = \frac{1}{N^2} \left[N\chi_0 + 2 \sum_{k=1}^{N-1} (N-k) \chi_k \right] = \frac{\chi_0}{N} \left[1 + 2 \sum_{k=1}^{N-1} \left(1 - \frac{k}{N} \right) \frac{\chi_k}{\chi_0} \right]. \quad (2.38)$$

Definendo il **tempo di autocorrelazione integrato** $\tau_{int\ O}$ come

$$\tau_{int\ O} = \frac{1}{2} + \sum_{k=1}^{N-1} \left(1 - \frac{k}{N} \right) \frac{\chi_k}{\chi_0}, \quad (2.39)$$

la varianza dello stimatore assume la forma compatta

$$\sigma_O^2 = \frac{\sigma_O^2}{N} (2\tau_{int\ O}). \quad (2.40)$$

Questo risultato è generale e vale anche per campioni correlati, come nel caso di un campionamento markoviano. Se invece il campionamento fosse diretto, i campioni sarebbero statisticamente indipendenti e la funzione di correlazione si annullerebbe per $k \neq 0$:

$$\chi_{|i-j|} = 0 \quad \forall i \neq j \implies \sigma_O^2 = \frac{\sigma_O^2}{N}. \quad (2.41)$$

Il tempo di autocorrelazione integrato permette di quantificare l'inefficienza del metodo di campionamento: per avere la stessa informazione statistica di un insieme di N campioni campionati direttamente è necessario campionarne $N(2\tau_{int\ O})$ per un metodo markoviano.

Rimane tuttavia da affrontare un problema pratico: $\tau_{int\ O}$ non è noto a priori e va stimato a partire dalla stessa serie di campioni di cui si vuole quantificare l'errore. Una stima diretta tramite la formula (Equazione 2.39) è computazionalmente costosa e non sempre efficace, inoltre troncare la somma in modo arbitrario può causare stime sbagliate. Nel seguito si presentano due strategie complementari per affrontare questo problema: la **blocking analysis** di Flyvbjerg e Petersen, che aggira il problema evitando una stima esplicita di $\tau_{int\ O}$, e il **metodo della finestra automatica di Sokal**, che stima $\tau_{int\ O}$ direttamente ma con un criterio di troncamento autoconsistente.

Blocking Analysis. Per comprendere questo metodo di stima dell'errore è utile richiamare alcune proprietà elementari della varianza. Siano O_1 e O_2 due variabili aleatorie indipendenti e a una costante, allora valgono le seguenti proprietà per la varianza:

$$\text{Var}(aO_1) = a^2 \text{Var}(O_1), \quad \text{Var}(O_1 + O_2) = \text{Var}(O_1) + \text{Var}(O_2). \quad (2.42)$$

La media campionaria $\bar{O}$ è essa stessa una variabile aleatoria, la cui varianza può essere riscritta suddividendo la somma sugli N valori $O(\mathbf{x}_i)$ in una somma su N_{blocks} blocchi consecutivi di lunghezza m (con $N = N_{\text{blocks}} m$):

$$\sigma_{\bar{O}}^2 = \text{Var}\left(\frac{1}{N} \sum_{i=1}^N O(\mathbf{x}_i)\right) = \text{Var}\left(\frac{1}{N_{\text{blocks}}} \sum_{j=1}^{N_{\text{blocks}}} \bar{O}_j\right), \quad \bar{O}_j = \frac{1}{m} \sum_{i=(j-1)m+1}^{jm} O(\mathbf{x}_i), \quad (2.43)$$

dove $\bar{O}_j$ è la media del j -esimo blocco.

Applicando le proprietà della varianza (Equazione 2.42):

$$\sigma_{\bar{O}}^2 = \frac{1}{N_{\text{blocks}}^2} \text{Var}\left(\sum_{j=1}^{N_{\text{blocks}}} \bar{O}_j\right). \quad (2.44)$$

Se la lunghezza di blocco m è sufficientemente grande, le medie di blocchi distinti possono essere considerate approssimativamente indipendenti; in questo limite la varianza della somma coincide con la somma delle varianze:

$$\text{Var}(\bar{O}) = \frac{1}{N_{\text{blocks}}} \text{Var}(\bar{O}_{\text{block}}), \quad (2.45)$$

dove $\text{Var}(\bar{O}_{\text{block}})$ è la varianza della media di un singolo blocco, stimabile empiricamente dalla dispersione delle medie di blocco:

$$\text{Var}(\bar{O}_{\text{block}}) \approx \frac{1}{N_{\text{blocks}} - 1} \sum_{j=1}^{N_{\text{blocks}}} (\bar{O}_j - \bar{O})^2. \quad (2.46)$$

Si definisce quindi la funzione di blocking

$$R_O(m) = \frac{m \text{Var}(\bar{O}_{\text{block}})}{\text{Var}(O)}, \quad (2.47)$$

che permette di stimare la varianza della media campionaria come

$$\text{Var}(\bar{O}) = R_O(m^*) \frac{\text{Var}(O)}{N}, \quad (2.48)$$

dove m^* è la lunghezza di blocco oltre la quale i blocchi possono essere considerati approssimativamente indipendenti: in pratica si individua cercando la regione in cui $R_O(m)$ smette di crescere apprezzabilmente al variare di m , ovvero un *plateau*.

Confrontando questa stima con la relazione generale tra varianza della media campionaria e tempo di autocorrelazione integrato, valida per $N \rightarrow \infty$,

$$\text{Var}(\bar{O}) = \frac{2 \tau_{\text{int}}}{N} \text{Var}(O), \quad (2.49)$$

si ottiene la relazione tra il plateau di $R_O(m)$ e il tempo di autocorrelazione integrato:

$$\tau_{\text{int } O} = \frac{1}{2} R_O(m^*). \quad (2.50)$$

Il valore m^* non è mai noto a priori: viene determinato a posteriori individuando il plateau di $R_O(m)$ descritto sopra. Questa procedura costituisce il metodo di blocking di Flyvbjerg e Petersen [12], e ha il vantaggio di fornire una stima di $\tau_{\text{int } O}$ senza richiedere il calcolo esplicito della funzione di correlazione χ_k a ogni ritardo k .

Metodo di Sokal. Una stima diretta di $\tau_{\text{int } O}$ tramite l'Equazione 2.39 richiede il calcolo di χ_k per ogni ritardo k . Possiamo calcolare χ_k tramite il seguente stimatore

$$\chi_k = \frac{1}{N-k} \sum_{i=1}^{N-k} \left(O(\mathbf{x}_i) - \bar{O} \right) \left(O(\mathbf{x}_{i+k}) - \bar{O} \right), \quad (2.51)$$

che ha costo $\mathcal{O}(N^2)$ se calcolata per tutti i ritardi, risultando proibitiva per le lunghezze di catena tipiche di una simulazione Monte Carlo. È tuttavia possibile calcolarla in $\mathcal{O}(N \log N)$ tramite Fast Fourier Transform (FFT), ed è questo l'approccio usato nel codice per stimare χ_k sulle catene generate.

Una volta ottenuta χ_k , è necessario sommare χ_k/χ_0 su tutti i ritardi k come nella definizione di $\tau_{\text{int } O}$ (Equazione 2.39). Questo non è uno stimatore consistente, perché per $k \gg \tau_{\text{int}, O}$ i valori χ_k sono dominati dal rumore statistico piuttosto che dal segnale fisico, e la loro somma su un numero crescente di termini aumenta la varianza dello stimatore [13]. La soluzione consiste nel troncare la somma a un ritardo massimo M :

$$\tau_{\text{int } O}(M) = \frac{1}{2} + \sum_{k=1}^M \left(1 - \frac{k}{N} \right) \frac{\chi_k}{\chi_0}. \quad (2.52)$$

La scelta di M rappresenta un compromesso tra bias e varianza: un valore di M troppo piccolo introduce un bias sistematico (poiché si trascura parte del segnale), mentre un M troppo grande fa esplodere la varianza (includendo troppo rumore). Il metodo della *finestra automatica* di Sokal risolve questo compromesso in modo autoconsistente: si sceglie M come il più piccolo intero tale che

$$M \geq c \tau_{\text{int } O}(M), \quad (2.53)$$

con c una costante tipicamente compresa tra 4 e 10. Questo criterio richiede di calcolare $\tau_{\text{int } O}(M)$ per valori crescenti di M finché la condizione non è soddisfatta, ottenendo così sia una stima di $\tau_{\text{int } O}$ sia il criterio di arresto in un'unica procedura, senza dover fissare arbitrariamente M .

CAPITOLO 3

Normalizing Flows

Nel capitolo precedente si è mostrato come i metodi Monte Carlo basati su catene di Markov, pur essendo generali e asintoticamente esatti, soffrano di limitazioni quando la distribuzione target presenta più modi separati.

In questo capitolo si introducono i **Normalizing Flows**, una classe di modelli generativi basati su trasformazioni invertibili e differenziabili, capaci di mappare una distribuzione base semplice da campionare (come una gaussiana standard) in una distribuzione target arbitrariamente complessa. A differenza di un campionario MCMC, che solitamente esplora lo spazio delle configurazioni in maniera locale, un NF correttamente addestrato permette di generare campioni indipendenti da una distribuzione che approssima la distribuzione target con un singolo passaggio in avanti attraverso la rete.

Il capitolo è organizzato come segue. Nella Sezione 3.1 si formalizza il concetto di NF come cambio di variabile, se ne discute l'espressività teorica e si introducono le due modalità operative di campionamento e inferenza, oltre al problema del loro addestramento. Nella Sezione 3.2 si mostra come costruire flow tramite composizione di trasformazioni semplici, fino a spiegare la costruzione di una **Real NVP**, impiegata successivamente in questo lavoro. Infine, nella Sezione 3.4.2 si presenta lo schema **Flow-MCMC**, che combina un NF pre-addestrato con MCMC in modo da poter avere passi globali e risolvere il problema dell'intrappolamento in un modo, mantenendo la convergenza alla distribuzione target.

3.1 Definizione, proprietà ed utilizzo

3.1.1 Cambio di variabili e funzioni invertibili

Un Normalizing Flow (NF) è una trasformazione T che permette di esprimere una variabile aleatoria attraverso un'altra variabile aleatoria:

$$\mathbf{x} = T(\mathbf{z}), \quad \mathbf{z} \sim p_Z(\mathbf{z}) \quad (3.1)$$

dove si è espresso $\mathbf{x}$ come risultato della trasformazione T su $\mathbf{z}$ campionata da $p_Z(\mathbf{z})$. Chiameremo T **flow**, mentre la variabile $\mathbf{z}$ - con distribuzione **base** (o prior) $p_Z(\mathbf{z})$ - è detta **variabile latente**.

La trasformazione T deve avere alcune proprietà particolari per essere un Normalizing Flow: deve essere un diffeomorfismo, ovvero una funzione invertibile, differenziabile con inversa T^{-1} differenziabile [14]. Questo costringe ad avere $\mathbf{x}$ e $\mathbf{z}$ entrambi D dimensionali. Schematicamente si può scrivere:

$$\mathbf{x} \xrightleftharpoons[T^{-1}]{T} \mathbf{z}, \quad \mathbf{x}, \mathbf{z} \in \mathbb{R}^D. \quad (3.2)$$

In questo modo la distribuzione di probabilità di $\mathbf{x}$ è ben definita e ottenibile tramite il cambio di variabile [15]:

$$p_X(\mathbf{x}) = p_Z(\mathbf{z}) |\det J_T(\mathbf{z})|^{-1} \quad \text{dove } \mathbf{z} = T^{-1}(\mathbf{x}) \quad (3.3)$$

o equivalentemente espressa per $\mathbf{x}$:

$$p_X(\mathbf{x}) = p_Z(T^{-1}(\mathbf{x})) |\det J_{T^{-1}}(\mathbf{x})|. \quad (3.4)$$

Dove con $J_T(\mathbf{z})$ si indica la matrice Jacobiana di T , ovvero la matrice $D \times D$ delle derivate parziali:

$$J_T(\mathbf{z}) = \begin{pmatrix} \frac{\partial T_1}{\partial z_1} & \cdots & \frac{\partial T_1}{\partial z_D} \\ \vdots & \ddots & \vdots \\ \frac{\partial T_D}{\partial z_1} & \cdots & \frac{\partial T_D}{\partial z_D} \end{pmatrix}. \quad (3.5)$$

Si riporta di seguito un esempio concreto dell'utilizzo della formula del cambio di variabile tra due distribuzioni di probabilità.

Esempio 3.1.1: Trasformazione affine unidimensionale

Consideriamo un cambio di variabile unidimensionale definito da una trasformazione affine T :

$$x = T(z) = az + b, \quad (3.6)$$

con parametri del flow $\theta = \{a, b\}$ e $a \neq 0$.


Sia $z \sim \mathcal{N}(0, 1)$ una variabile aleatoria estratta da una distribuzione base gaussiana standard con densità $p_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$.

Applicando la formula del cambio di variabile, la densità di probabilità della variabile trasformata x è data da:

$$p_X(x) = p_Z(T^{-1}(x)) \cdot \left| \frac{dT^{-1}(x)}{dx} \right| = \frac{1}{|a|\sqrt{2\pi}} \exp\left(-\frac{(x-b)^2}{2a^2}\right), \quad (3.7)$$

che corrisponde ancora a una distribuzione gaussiana $\mathcal{N}(b, a^2)$.

In figura è illustrato un esempio pratico con $a = 2$ e $b = 7.5$, mostrando il confronto tra la densità teorica di x e l'istogramma dei campioni trasformati.



3.1.2 Espressività del flow

Una questione di fondamentale importanza è l'*espressività* del flow T . È possibile rappresentare una qualsiasi distribuzione $p_X(\mathbf{x})$, anche se la distribuzione base è semplice? Mostriamo che è possibile sotto certe condizioni rappresentare qualsiasi distribuzione $p_X(\mathbf{x})$ a partire da una distribuzione di base $p_Z(\mathbf{z})$ uniforme nell'insieme $(0, 1)^D$.

Supponiamo che $p_X(\mathbf{x}) > 0$ per ogni $\mathbf{x} \in \mathbb{R}^D$, e assumiamo che tutte le probabilità condizionate $\Pr(x'_i \leq x_i \mid \mathbf{x}_{<i})$ — dove x'_i è la variabile aleatoria a cui questa probabilità fa riferimento — siano differenziabili rispetto a $(x_i, \mathbf{x}_{<i})$. Usando la regola della catena della probabilità, possiamo decomporre $p_X(\mathbf{x})$ in un prodotto di densità condizionate:

$$p_X(\mathbf{x}) = \prod_{i=1}^D p_X(x_i \mid \mathbf{x}_{<i}). \quad (3.8)$$

Poiché $p_X(\mathbf{x})$ è non nulla ovunque, si ha $p_X(x_i \mid \mathbf{x}_{<i}) > 0$ per ogni i e $\mathbf{x}$. Definiamo quindi la trasformazione $F : \mathbf{x} \mapsto \mathbf{z} \in (0, 1)^D$, il cui i -esimo elemento è dato dalla distribuzione cumulativa della i -esima condizionata:

$$z_i = F_i(x_i, \mathbf{x}_{<i}) = \int_{-\infty}^{x_i} p_X(x'_i \mid \mathbf{x}_{<i}) dx'_i = \Pr(x'_i \leq x_i \mid \mathbf{x}_{<i}). \quad (3.9)$$

Poiché ciascuna F_i è differenziabile rispetto ai propri argomenti, F è differenziabile. Inoltre, ciascuna $F_i(\cdot, \mathbf{x}_{<i}) : \mathbb{R} \rightarrow (0, 1)$ è invertibile, dato che la sua derivata $\partial F_i / \partial x_i = p_X(x_i \mid \mathbf{x}_{<i})$ è positiva ovunque. Poiché z_i non dipende da x_j per $j \neq i$, possiamo invertire F , con l'inversa data elemento per elemento da:

$$x_i = (F_i(\cdot, \mathbf{x}_{<i}))^{-1}(z_i) \quad \text{per } i = 1, \dots, D. \quad (3.10)$$

Lo Jacobiano di F è triangolare inferiore, poiché $\partial F_i / \partial x_j = 0$ per $i < j$. Quindi il determinante Jacobiano di F è uguale al prodotto dei suoi elementi diagonali:

$$\det J_F(\mathbf{x}) = \prod_{i=1}^D \frac{\partial F_i}{\partial x_i} = \prod_{i=1}^D p_X(x_i \mid \mathbf{x}_{<i}) = p_X(\mathbf{x}). \quad (3.11)$$

Poiché $p_X(\mathbf{x}) > 0$, il determinante Jacobiano è non nullo ovunque. Esiste dunque l'inversa di $J_F(\mathbf{x})$, ed è uguale allo Jacobiano di F^{-1} ; pertanto F è un diffeomorfismo. Tramite il cambio di variabile, possiamo calcolare la densità di $\mathbf{z}$ nel modo seguente:

$$p_Z(\mathbf{z}) = p_X(\mathbf{x}) |\det J_F(\mathbf{x})|^{-1} = p_X(\mathbf{x}) |p_X(\mathbf{x})|^{-1} = 1, \quad (3.12)$$

il che implica che $\mathbf{z}$ è distribuita uniformemente nel cubo aperto unitario $(0, 1)^D$.

L'argomento sopra riportato mostra che un modello basato su flow può esprimere qualsiasi distribuzione $p_X(\mathbf{x})$ (che soddisfi le condizioni sopra indicate), anche restringendo la distribuzione base a essere uniforme in $(0, 1)^D$. Possiamo estendere questo risultato a qualsiasi distribuzione base $p_U(\mathbf{u})$, trasformando dapprima $\mathbf{u}$ in una $\mathbf{z}$ uniforme in $(0, 1)^D$ come passaggio intermedio. In particolare,

data una qualsiasi $p_U(\mathbf{u})$ che soddisfi le condizioni sopra indicate (analoghe a quelle di $p_X(\mathbf{x})$), definiamo G come la seguente trasformazione:

$$z_i = G_i(u_i, \mathbf{u}_{<i}) = \int_{-\infty}^{u_i} p_U(u'_i | \mathbf{u}_{<i}) du'_i = \Pr(u'_i \leq u_i | \mathbf{u}_{<i}). \quad (3.13)$$

Con lo stesso argomento esposto sopra, G è un diffeomorfismo e $\mathbf{z}$ è distribuita uniformemente in $(0, 1)^D$. Dunque, un flow con trasformazione $T = F^{-1} \circ G$ può trasformare $p_U(\mathbf{u})$ in $p_X(\mathbf{x})$.

Il risultato ottenuto ci garantisce l'esistenza di una trasformazione e ci fornisce un metodo per ottenerla tramite integrazione. Questo metodo però non è praticabile, poiché numericamente difficile in generale. Una soluzione più agevole, come vedremo nella Sezione 3.2 è cercare di approssimare la trasformazione con una rete neurale.

3.1.3 Campionamento e inferenza

Un NF può essere impiegato in due modalità operative distinte, a seconda che si voglia *campionare* dalla distribuzione $p_X(\mathbf{x})$ oppure *valutare* la densità di probabilità di un campione dato. Queste due operazioni corrispondono rispettivamente alla direzione diretta e alla direzione inversa della trasformazione T .

Campionamento. Per generare un campione $\mathbf{x}$ distribuito secondo $p_X(\mathbf{x})$ è sufficiente:

1. campionare $\mathbf{z} \sim p_Z(\mathbf{z})$ dalla distribuzione base, tipicamente semplice da campionare (ad esempio una gaussiana standard);
2. applicare la trasformazione diretta $\mathbf{x} = T(\mathbf{z})$.

Questa procedura richiede unicamente la valutazione di T nella direzione diretta, e non necessita né dell'inversa T^{-1} né del calcolo dello Jacobiano.

Inferenza. Al contrario, per valutare la densità $p_X(\mathbf{x})$ in un punto $\mathbf{x}$ dato è necessario:

1. calcolare $\mathbf{z} = T^{-1}(\mathbf{x})$, ovvero applicare la trasformazione inversa;
2. valutare $p_Z(\mathbf{z})$ e il determinante Jacobiano $|\det J_{T^{-1}}(\mathbf{x})|$, secondo la formula di cambio di variabile già ricavata:

$$p_X(\mathbf{x}) = p_Z(T^{-1}(\mathbf{x})) |\det J_{T^{-1}}(\mathbf{x})|. \quad (3.14)$$

Questa seconda operazione richiede quindi non solo che T^{-1} sia calcolabile esplicitamente, ma anche che il determinante del suo Jacobiano sia efficientemente calcolabile: un requisito tutt'altro che scontato, dato che per una generica matrice $D \times D$ il calcolo del determinante scala come $\mathcal{O}(D^3)$.

Nel contesto di questa tesi, entrambe le direzioni risultano necessarie: il campionamento diretto approssimato è svolto tramite un NF di cui è sufficiente implementare la trasformazione T , mentre la valutazione della densità è indispensabile per il calcolo dei tassi di accettazione nello schema Flow-MCMC (Sez. 3.4.2).

3.2 Costruire un flow

3.2.1 Composizione finita

Una proprietà delle trasformazioni invertibili e differenziabili è che sono *componibili*. Considerando due trasformazioni T_1 e T_2 con tali caratteristiche, la loro composizione $T_2 \circ T_1$ è una trasformazione invertibile e differenziabile.

$$(T_2 \circ T_1)^{-1} = T_1^{-1} \circ T_2^{-1}, \quad \det J_{T_2 \circ T_1}(\mathbf{z}) = \det J_{T_2}(T_1(\mathbf{z})) \det J_{T_1}(\mathbf{z}) \quad (3.15)$$

Questa proprietà non si ferma a sole due trasformazioni, ovviamente $T_2 \circ T_1$ essendo invertibile e differenziabile può essere composta con una terza trasformazione T_3 e così via. Si può dunque creare un flow T più complesso proprio tramite la consecutiva composizione di più trasformazioni. Un esempio è mostrato in Figura 3.1.




Figura 3.1: Esempio di una trasformazione composizione di 4 trasformazioni. Si mostra l'effetto sui campioni: da una gaussiana standard a una distribuzione a forma di croce.

In generale si può creare un flow T come composizione di K trasformazioni invertibili e differenziabili

$$T = T_K \circ \dots \circ T_1. \quad (3.16)$$

Come in Figura 3.2 si indicano con $\mathbf{z}_k = T_k(\mathbf{z}_{k-1})$ per $k = 1, 2, \dots, K$, $\mathbf{z}_0 = \mathbf{z}$ e $\mathbf{z}_K = \mathbf{x} = T(\mathbf{z}_0)$. Il logaritmo del determinante del Jacobiano di T sarà dunque calcolabile come somma di determinanti nel seguente modo:

$$\log |\det J_T(\mathbf{z}_0)| = \sum_{k=1}^K \log |\det J_{T_k}(\mathbf{z}_{k-1})|. \quad (3.17)$$




Figura 3.2: Rappresentazione di un flow composto da K trasformazioni.

Rimane da chiarire quali singole trasformazioni T_k implementare per creare il flow T . Sarebbe desiderabile che ogni T_k avesse le seguenti tre proprietà. La prima è l'invertibilità, una richiesta imprescindibile come mostrato in precedenza, è proprio l'esistenza di T^{-1} a garantire la buona definizione della densità $p_X(\mathbf{x})$ tramite la formula del cambio di variabile, oltre a essere necessaria per l'eventuale fase di inferenza.

Il secondo requisito nasce invece da un vincolo pratico: sebbene ogni trasformazione invertibile e differenziabile ammetta per definizione uno Jacobiano ben definito, per una generica matrice $D \times D$ il calcolo del determinante richiede $\mathcal{O}(D^3)$ operazioni, un costo computazionale proibitivo se va ripetuto ad ogni valutazione della densità, come accade tipicamente a ogni passo dell'addestramento (Sezione 3.3). È dunque necessario progettare trasformazioni il cui Jacobiano abbia una struttura particolare — ad esempio triangolare o diagonale a blocchi — che ne renda il determinante calcolabile in tempo lineare $\mathcal{O}(D)$, anziché cubico.

Infine, l'espressività è utile per poter limitare il numero di calcoli. Infatti anche se è possibile concatenare molte trasformazioni semplici e poco espressive, conviene impiegare un minor numero di trasformazioni che siano il più espressive possibili. Si mostra un esempio nella Figura 3.3.




Figura 3.3: Esempio di espressività di un flow composto. La prima immagine mostra i campioni della distribuzione base gaussiana, mentre le successive mostrano la distribuzione ottenuta applicando progressivamente la trasformazione T_k : dopo 2, 4 e 8 trasformazioni consecutive. Si può osservare come, grazie all'elevata espressività delle singole trasformazioni T_k , già con un numero limitato di trasformazioni sia possibile ottenere distribuzioni qualitativamente molto diverse dalla distribuzione base.

Si discuteranno nelle prossime sezioni gli **autoregressive flows** e un particolare tipo di NF di tale categoria chiamato **Real NVP**.

3.2.2 Autoregressive flows

Gli **autoregressive flows** costituiscono una famiglia di trasformazioni progettate per soddisfare simultaneamente i requisiti di invertibilità e di calcolo efficiente del determinante Jacobiano introdotti nella sezione precedente. L'idea fondamentale consiste nel costruire la trasformazione in modo che ciascuna componente dipenda solo dalle componenti precedenti della variabile di ingresso.

Considerando una flow che trasforma $\mathbf{z}$ in $\mathbf{z}'$

$$z'_i = \tau(z_i; \mathbf{h}_i), \quad \mathbf{h}_i = c_i(\mathbf{z}_{<i}; \boldsymbol{\theta}), \quad i = 1, \dots, D, \quad (3.18)$$

dove τ è detta **trasformatore** e c_i è il **condizionatore** associato alla componente i -esima. Con $\mathbf{z}_{<i} = (z_1, \dots, z_{i-1})$ si indica l'insieme delle componenti precedenti a z_i . Il condizionatore determina quindi i parametri della trasformazione di z_i utilizzando esclusivamente le componenti precedenti.

La struttura autoregressiva impone una particolare struttura allo Jacobiano. Infatti, per $j > i$, la quantità z'_i non dipende da z_j , e pertanto

$$\frac{\partial z'_i}{\partial z_j} = 0, \quad j > i. \quad (3.19)$$

Lo Jacobiano assume quindi la forma triangolare inferiore

$$J_T = \begin{pmatrix} \frac{\partial z'_1}{\partial z_1} & 0 & \cdots & 0 \\ \frac{\partial z'_2}{\partial z_1} & \frac{\partial z'_2}{\partial z_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial z'_D}{\partial z_1} & \frac{\partial z'_D}{\partial z_2} & \cdots & \frac{\partial z'_D}{\partial z_D} \end{pmatrix}. \quad (3.20)$$

Il determinante di una matrice triangolare è dato dal prodotto degli elementi diagonali. Nel caso della trasformazione (3.18) si ottiene dunque

$$\det J_T(\mathbf{z}; \boldsymbol{\theta}) = \prod_{i=1}^D \frac{\partial \tau(z_i; \mathbf{h}_i)}{\partial z_i}, \quad \mathbf{h}_i = c_i(\mathbf{z}_{<i}; \boldsymbol{\theta}). \quad (3.21)$$

Il calcolo del determinante per uno Jacobiano triangolare si riduce alla valutazione dei soli elementi diagonali e scala linearmente con D .

Resta da imporre l'invertibilità della trasformazione, necessaria per essere un NF. Se il trasformatore $\tau(\cdot; \mathbf{h}_i)$ è invertibile rispetto al primo argomento, l'inversione può essere effettuata componente per componente:

$$z_i = \tau^{-1}(z'_i; \mathbf{h}_i). \quad (3.22)$$

La struttura autoregressiva permette quindi di ottenere trasformazioni con un Jacobiano di cui il determinante è facilmente calcolabile. Il prezzo da pagare è però una struttura sequenziale nell'esecuzione della trasformazione inversa. In

particolare, poiché $\mathbf{h}_i$ dipende dalle componenti precedenti, le diverse componenti non possono essere ricostruite simultaneamente. Si mostra in Figura 3.4 lo schema di calcolo per un autoregressive flow.

Un vantaggio molto importante degli autoregressive flow è che le proprietà fondamentali per essere un flow sono a carico di τ , mentre il condizionatore c_i è un elemento di estrema libertà implementativa. Infatti su c_i non vi è alcuna richiesta di invertibilità, questo ci permette di utilizzare una rete neurale (neural network o NN) come condizionatore.




Figura 3.4: Rappresentazione grafica di un T_k autoregressive flow composto dal condizionatore c_i e dal trasformatore τ . A sinistra la trasformazione e a destra la sua inversa.


Si mostra un'esempio di autoregressive flow che non utilizza NN nella sua definizione e composto da otto trasformazioni.

Esempio 3.2.1: Autoregressive flow in 3D senza NN

Consideriamo un autoregressive flow in 3 dimensioni $\mathbf{z} \rightarrow \mathbf{x}$, definito dalla seguente trasformazione:

$$\begin{aligned} x_1 &= z_1 \\ x_2 &= \sin(x_1^2 + 0.5x_1) + e^{0.01x_1}z_2 \\ x_3 &= (0.1x_1 + 0.1x_2) + e^{0.01(x_1-x_2)}z_3. \end{aligned}$$

Applicando una sequenza di $N = 8$ layer di flow autoregressivi consecutivi, la distribuzione gaussiana base $z \sim \mathcal{N}(0, I_3)$ si trasforma in una distribuzione di probabilità complessa. Si mostrano in figura gli istogrammi delle variabili z_i in alto e x_i in basso:



La costruzione di un autoregressive flow dipende dalla scelta del trasformatore e del condizionatore. Si riportano in Tabella 3.1 le possibili scelte di questi elementi.

Autoregressive flows	Trasformatore:	Condizionatore:
	– Affine	– Recurrent
	– Combination-based	– Masked
	– Integration-based	– Coupling layer
	– Spline-based	

Tabella 3.1: Panoramica dei possibili modi di costruire un autoregressive flow, distinti in base al tipo di trasformatore e di condizionatore.

Nella prossima sezione si discuterà una particolare implementazione di questa categoria di NF, ovvero una Real NVP.

3.2.3 Real NVP

Una architettura molto utilizzata per costruire Normalizing Flows è la **Real NVP** (Real-valued Non-Volume Preserving), introdotta da Dinh et al. [16]. L'idea alla base della Real NVP è costruire un autoregressive flow che ha come trasformatore una **trasformazione affine**, i cui parametri sono calcolati da un condizionatore. Il condizionatore ha due caratteristiche principali: è una rete neurale ed ha una struttura di condizionamento chiamata **coupling layer**.

Trasformazione affine. Il *trasformatore* τ impiegato nella Real NVP è una trasformazione di tipo affine: per ogni componente z_i della variabile latente si pone

$$\tau(z_i; s_i, t_i) = z_i \cdot \exp(s_i) + t_i, \quad (3.23)$$

dove s_i (*scale*) e t_i (*translation*) sono i parametri della trasformazione. La presenza del fattore esponenziale $\exp(s_i)$ garantisce che la trasformazione sia sempre invertibile qualunque sia il valore reale assunto da s_i , e l'inversa si scrive semplicemente come

$$\tau^{-1}(z'_i; s_i, t_i) = \frac{z'_i - t_i}{\exp(s_i)}. \quad (3.24)$$

Poiché la trasformazione agisce componente per componente, lo Jacobiano della trasformazione è diagonale, e il suo determinante si riduce al prodotto dei singoli fattori $\exp(s_i)$, ossia $\prod_i \exp(s_i) = \exp(\sum_i s_i)$: la valutazione del log-determinante richiede quindi solo una somma.

Coupling Layer. I parametri s_i, t_i non sono a loro volta parametri liberi, ma sono prodotti da un *condizionatore*: una rete neurale che riceve in ingresso solo una parte delle componenti di $\mathbf{z}$ e restituisce in uscita i parametri della trasformazione affine per le componenti rimanenti. Questa costruzione prende il nome di **coupling layer**.

Sia $\mathbf{z} \in \mathbb{R}^D$ e sia $d < D$ un indice di taglio (tipicamente $d = \lfloor D/2 \rfloor$). Un coupling layer divide $\mathbf{z}$ in due blocchi, $\mathbf{z}_{\leq d} = (z_1, \dots, z_d)$ e $\mathbf{z}_{>d} = (z_{d+1}, \dots, z_D)$, e definisce la trasformazione $\mathbf{z} \rightarrow \mathbf{z}'$ come segue:

$$\mathbf{z}'_{\leq d} = \mathbf{z}_{\leq d}, \quad (3.25)$$

$$\mathbf{z}'_{>d} = \mathbf{z}_{>d} \odot \exp(\mathbf{s}(\mathbf{z}_{\leq d})) + \mathbf{t}(\mathbf{z}_{\leq d}), \quad (3.26)$$

dove $\mathbf{s}(\cdot)$ e $\mathbf{t}(\cdot)$ sono reti neurali arbitrarie (i condizionatori) e $\odot$ indica il prodotto componente per componente.

Il primo blocco $\mathbf{z}_{\leq d}$ viene quindi lasciato *invariato* e funge da input del condizionatore, mentre il secondo blocco $\mathbf{z}_{>d}$ viene trasformato affinementemente in base ai valori del primo. Questa asimmetria è ciò che rende la trasformazione facilmente invertibile: nota $\mathbf{z}'_{\leq d} = \mathbf{z}_{\leq d}$, è possibile ricalcolare $\mathbf{s}(\mathbf{z}_{\leq d})$ e $\mathbf{t}(\mathbf{z}_{\leq d})$ e quindi invertire l'Equazione 3.26 in forma chiusa:

$$\mathbf{z}_{\leq d} = \mathbf{z}'_{\leq d}, \quad (3.27)$$

$$\mathbf{z}_{>d} = (\mathbf{z}'_{>d} - \mathbf{t}(\mathbf{z}_{\leq d})) \odot \exp(-\mathbf{s}(\mathbf{z}_{\leq d})). \quad (3.28)$$

Si noti che, a differenza dei flow autoregressivi generali, l'inversione di un coupling layer non richiede alcuna procedura sequenziale: tutte le componenti di $\mathbf{z}_{>d}$ vengono ricostruite *simultaneamente*, poiché dipendono unicamente dal blocco $\mathbf{z}_{\leq d}$ già disponibile. Per lo stesso motivo, anche la valutazione in avanti (forward) è completamente parallelizzabile: il coupling layer è quindi *computazionalmente simmetrico*, essendo ugualmente efficiente da valutare in entrambe le direzioni (Figura 3.5).




Figura 3.5: Rappresentazione grafica di un T_k per una Real NVP. Possiamo vedere la suddivisione del vettore $\mathbf{z}$ e il calcolo di $\mathbf{s}$ e $\mathbf{t}$ rispettivamente i fattori di scaling e translation. A sinistra la trasformazione e a destra la sua inversa.

Lo Jacobiano della trasformazione Real NVP ha la seguente struttura triangolare inferiore:

$$J_\phi = \begin{pmatrix} \mathbf{I}_d & \mathbf{0} \\ \mathbf{A} & \text{diag}(\exp(\mathbf{s}(\mathbf{z}_{\leq d}))) \end{pmatrix}, \quad (3.29)$$

dove $\mathbf{I}_d$ è la matrice identità $d \times d$, $\mathbf{0}$ è la matrice nulla $d \times (D - d)$, e $\mathbf{A}$ è una matrice $(D - d) \times d$ generica (il cui contenuto dipende dalle derivate di $\mathbf{s}$ e $\mathbf{t}$, ma è irrilevante ai fini del calcolo del determinante). Il determinante si riduce infatti al prodotto degli elementi diagonali del blocco inferiore destro,

$$\det J_\phi = \prod_{i=d+1}^D \exp(s_i(\mathbf{z}_{\leq d})) = \exp\left(\sum_{i=d+1}^D s_i(\mathbf{z}_{\leq d})\right), \quad (3.30)$$

il che conferma che il costo di valutazione del log-determinante è lineare in D , indipendentemente dalla complessità delle reti $\mathbf{s}$ e $\mathbf{t}$.

Un singolo coupling layer, tuttavia, lascia $\mathbf{z}_{\leq d}$ completamente invariato: per ottenere un flow espressivo è quindi necessario *concatenare più coupling layer*, alternando ad ogni passo quale sottoinsieme di componenti viene tenuto fisso. Tipicamente questo è ottenuto *permutando* gli elementi ad ogni passo in modo che ogni componente venga trasformata più volte nel corso del flow, ovviamente è necessario assicurarsi che alla fine di ogni trasformazione ogni componente sia nella sua posizione originale.

Si riporta un semplice esempio bidimensionale di un flow che ha le caratteristiche principali di una Real NVP, tranne l'implementazione di s e t (che in una Real NVP sono delle NN), mentre in questo semplice esempio sono delle funzioni non lineari.

Esempio 3.2.2: Coupling Layer Affine senza NN


Consideriamo un flow bidimensionale definito dalle funzioni

$$s(z_1) = 0.5 \tanh(0.6 z_1^3), \quad t(z_1) = z_1^2,$$

applicate secondo la trasformazione

$$x_1 = z_1, \quad x_2 = z_2 e^{s(z_1)} + t(z_1).$$

Partendo da un campione $\mathbf{z} \in \mathbb{R}^2$ estratto da una gaussiana standard bi-dimensionale, applichiamo la trasformazione ripetutamente. L'immagine mostra l'effetto sulla distribuzione della ripetuta applicazione della trasformazione: la deformazione avviene solo sulla seconda variabile, poichè non si sono svolte permutazioni e dunque la prima variabile è rimasta invariata durante tutte le trasformazioni.



La presenza delle NN nei Real NVP non è un caso, ma è un elemento fondamentale: esse permettono al flow T una maggiore espressività e una dipendenza

da un numero maggiore di parametri θ , conferendo al flow la capacità di apprendere trasformazioni complesse. I parametri delle reti neurali devono essere determinati attraverso una procedura di addestramento. L'obiettivo è scegliere tali parametri in modo che la trasformazione appresa sia in grado di rappresentare in modo efficace la distribuzione di interesse. Nel prossimo capitolo verrà quindi illustrato come viene formulato il problema di addestramento di un NF.

3.3 Addestramento del flow

L'obiettivo dell'addestramento è determinare i parametri θ della trasformazione T_θ in modo che la distribuzione appresa $p_X(\mathbf{x}; \theta)$, ottenuta tramite la formula di cambio di variabile

$$p_X(\mathbf{x}; \theta) = p_Z(T_\theta^{-1}(\mathbf{x})) \left| \det J_{T_\theta^{-1}}(\mathbf{x}) \right|, \quad (3.31)$$

approssimi il più fedelmente possibile una distribuzione target $p_X^*(\mathbf{x})$. Per farlo è necessario innanzitutto scegliere una misura di distanza tra le due distribuzioni. La scelta più comune, che adotteremo anche in questo lavoro, è la **divergenza di Kullback-Leibler** (KL) [17], definita per due densità p e q come

$$D_{\text{KL}}(p \parallel q) = \left\langle \log \frac{p}{q} \right\rangle_p = \int p(\mathbf{x}) \log \frac{p(\mathbf{x})}{q(\mathbf{x})} d\mathbf{x}. \quad (3.32)$$

Sebbene non sia una distanza in senso stretto, poiché non è simmetrica, la divergenza KL gode delle proprietà $D_{\text{KL}}(p \parallel q) \geq 0$ e $D_{\text{KL}}(p \parallel q) = 0 \iff p = q$, il che la rende una funzione di costo adeguata per l'addestramento. Proprio a causa della sua asimmetria, la scelta di quale delle due distribuzioni si pone come primo argomento non è indifferente, e conduce a due strategie di addestramento con proprietà molto diverse tra loro: la KL *forward* e la KL *reverse*. Infatti si utilizza un metodo per poter fare inferenza statistica su dei dati, mentre l'altro per poter campionare una distribuzione nota.

Divergenza KL forward. Se disponiamo di un insieme di campioni $\{\mathbf{x}_n\}_{n=1}^N$ estratti dalla distribuzione target $p_X^*(\mathbf{x})$, ma non siamo necessariamente in grado di valutarne la densità, possiamo minimizzare la divergenza KL forward

$$\mathcal{L}(\theta) = D_{\text{KL}}[p_X^*(\mathbf{x}) \parallel p_X(\mathbf{x}; \theta)] = -\left\langle \log p_X(\mathbf{x}; \theta) \right\rangle_{p_X^*} + \text{cost.} \quad (3.33)$$

Sostituendo l'espressione di $p_X(\mathbf{x}; \theta)$ e approssimando il valore atteso con una media Monte Carlo sui campioni disponibili, si ottiene

$$\mathcal{L}(\theta) \approx -\frac{1}{N} \sum_{n=1}^N \left[\log p_Z(T_\theta^{-1}(\mathbf{x}_n)) + \log \left| \det J_{T_\theta^{-1}}(\mathbf{x}_n) \right| \right] + \text{cost.}, \quad (3.34)$$

La minimizzazione di $\mathcal{L}(\theta)$ si svolge attraverso la discesa del gradiente, calcolando ad ogni iterazione di addestramento la seguente quantità:

$$\nabla_\theta \mathcal{L}(\theta) \approx -\frac{1}{N} \sum_{n=1}^N \nabla_\theta \log p_Z(T_\theta^{-1}(\mathbf{x}_n)) + \nabla_\theta \log \left| \det J_{T_\theta^{-1}}(\mathbf{x}_n) \right|. \quad (3.35)$$

Questo approccio richiede di poter calcolare T_{θ}^{-1} e il relativo determinante Jacobiano, ma non necessita mai di campionare dal modello durante l'addestramento. Si utilizza dunque la KL forward per un NF addestrato per poter fare inferenza statistica su dei dati con distribuzione.

Divergenza KL reverse. Se possiamo valutare la distribuzione target

$$p_X^*(\mathbf{x}) = \frac{\tilde{p}_X(\mathbf{x})}{Z} \quad (3.36)$$

anche a meno della costante Z di normalizzazione, minimizzando la KL reverse siamo in grado di addestrare il flow per poterla campionare. La loss $\mathcal{L}(\theta)$ si scrive

$$\mathcal{L}(\theta) = D_{\text{KL}}[p_X(\mathbf{x}; \theta) \| p_X^*(\mathbf{x})] = \left\langle \log p_X(\mathbf{x}; \theta) - \log p_X^*(\mathbf{x}) \right\rangle_{p_X(\cdot; \theta)}, \quad (3.37)$$

in cui il valore atteso è ora calcolato rispetto al modello stesso, e non rispetto al target. Poiché Z non dipende da θ , il suo contributo a $\mathcal{L}(\theta)$ si riduce a una costante additiva, e possiamo riscrivere la funzione di costo usando esclusivamente $\tilde{p}_X$:

$$\mathcal{L}(\theta) = \left\langle \log p_X(\mathbf{x}; \theta) - \log \tilde{p}_X(\mathbf{x}) \right\rangle_{p_X(\cdot; \theta)} + \text{cost.} \quad (3.38)$$

Il vantaggio cruciale della KL reverse è che il valore atteso può essere riparametrizzato in termini della distribuzione base utilizzando il flow e la formula del cambio di variabile:

$$\mathcal{L}(\theta) = \left\langle \log p_Z(\mathbf{z}) - \log |\det J_{T_{\theta}}(\mathbf{z})| - \log \tilde{p}_X(T_{\theta}(\mathbf{z})) \right\rangle_{p_Z} + \text{cost.}, \quad (3.39)$$

il cui gradiente rispetto a θ è stimabile tramite una media Monte Carlo su campioni $\{\mathbf{z}_n\}_{n=1}^N$ estratti dalla distribuzione base:

$$\nabla_{\theta} \mathcal{L}(\theta) \approx -\frac{1}{N} \sum_{n=1}^N \nabla_{\theta} \left[\log |\det J_{T_{\theta}}(\mathbf{z}_n)| + \log \tilde{p}_X(T_{\theta}(\mathbf{z}_n)) \right]. \quad (3.40)$$

3.4 Campionamento con NF

3.4.1 Campionamento diretto e re-weighting

La minimizzazione della KL reverse richiede quindi di poter calcolare la trasformazione diretta T_{θ} e il determinante del suo Jacobiano, ma non richiede di invertire T_{θ} né di conoscere campioni dal target: è sufficiente poter valutare $\tilde{p}_X$ in un punto qualsiasi. Questa è esattamente la situazione in cui ci troviamo per la distribuzione di Boltzmann:

$$p_X^*(\mathbf{x}) = \frac{1}{Z} e^{-\beta \mathcal{H}(\mathbf{x})} = \frac{\tilde{p}_X(\mathbf{x})}{Z}, \quad (3.41)$$

come detto in precedenza è nota la densità non normalizzata $\tilde{p}_X(\mathbf{x}) = e^{-\beta \mathcal{H}(\mathbf{x})}$, ma non la costante di normalizzazione Z . È questa dunque la strategia di addestramento adottata in questo lavoro: il flow è addestrato per minimizzare

la divergenza KL reverse rispetto alla densità di Boltzmann non normalizzata $\tilde{p}_X(\mathbf{x}) = e^{-\beta\mathcal{H}(\mathbf{x})}$, permettendo così, una volta addestrato, di generare campioni approssimativamente distribuiti secondo $p_X^*(\mathbf{x})$ con un singolo passaggio in avanti attraverso T_θ . I campioni così ottenuti possono essere utilizzati, tramite il **re-weighting**, per stimare gli osservabili di interesse.

Re-weighting. I campioni $\{\mathbf{x}_n\}_{n=1}^N$ - generati tramite campionamento diretto dal flow - sono distribuiti secondo la densità appresa $p_X(\mathbf{x}; \theta)$, che in generale non coincide esattamente con la distribuzione target $p_X^*(\mathbf{x})$. È tuttavia possibile correggere questa discrepanza trattando i campioni del flow come proposte di un campionamento per importanza (*importance sampling*), in cui $p_X(\mathbf{x}; \theta)$ svolge il ruolo di distribuzione ausiliaria e $p_X^*(\mathbf{x})$ quello di distribuzione target.

A ciascun campione $\mathbf{x}_n$ si associa un *peso di importanza*

$$w(\mathbf{x}_n) \equiv \frac{p_X(\mathbf{x}_n)}{Z} \frac{1}{p_X(\mathbf{x}_n; \theta)} = \frac{e^{-\beta\mathcal{H}(\mathbf{x}_n)}}{Z} \frac{1}{p_X(\mathbf{x}_n; \theta)}, \quad (3.42)$$

Il valore atteso di un osservabile $O(\mathbf{x})$ rispetto alla distribuzione target si stima allora tramite lo stimatore auto-normalizzato


$$\langle O \rangle_{p_X^*} \approx \frac{\sum_{n=1}^N w(\mathbf{x}_n) O(\mathbf{x}_n)}{\sum_{n=1}^N w(\mathbf{x}_n)}, \quad (3.43)$$

che è uno stimatore asintoticamente di $\langle O \rangle_{p_X^*}$ per $N \rightarrow \infty$, indipendentemente da quanto bene $p_X(\mathbf{x}; \theta)$ approssimi $p_X^*(\mathbf{x})$. Inoltre i pesi possono essere ridefiniti a meno della costante Z , poiché essa si semplifica nella stima di $\langle O \rangle_{p_X^*}$.


Se il flow approssima bene la distribuzione target, i pesi risultano circa uguali all'unità e ogni campione contribuisce in modo eguale alla stima; se invece il flow sottostima la probabilità di alcune regioni dello spazio delle configurazioni (ad esempio un modo poco rappresentato durante l'addestramento), pochi campioni con peso molto elevato possono dominare la somma.

Il metodo esposto che utilizza NF e re-weighting è un metodo del tutto generale, ma ha avuto un importante impatto per il campionamento della distribuzione di Boltzmann, infatti in letteratura prende anche il nome di **Boltzmann Generator** (Noe et al.[18] - Figura 3.6).

1 Sample Gaussian distribution



2 Generate distribution



3 Re - weight




Figura 3.6: Boltzmann Generator: utilizza NF e re-weighting per campionare la distribuzione di Boltzmann. Nella figura si mostrano i passi di questo metodo e due configurazioni di una proteina rappresentati due modi distinti della distribuzione target.

3.4.2 Flow Markov Chain Monte Carlo

La distribuzione di probabilità $p_X(\mathbf{x}; \boldsymbol{\theta})$ ottenuta attraverso il NF approssima la distribuzione target $p_X^*(\mathbf{x})$. L'utilizzo del flow per il campionamento ha un vantaggio principale: la capacità di produrre campioni tra loro indipendenti e potenzialmente distribuiti su tutti i modi della distribuzione, a differenza di un campionatore MCMC locale (Sezione 2.3), che esplora lo spazio delle configurazioni rischiando l'intrappolamento in un singolo modo.

Lo svantaggio del NF è che la qualità dei campioni generati dipende interamente dalla bontà dell'addestramento: non vi è alcuna garanzia che, per un $T_{\boldsymbol{\theta}}$ addestrato, la distribuzione $p_X(\mathbf{x}; \boldsymbol{\theta})$ coincida esattamente con $p_X^*(\mathbf{x})$, cosa invece garantita dall'algoritmo di Metropolis-Hastings. L'idea alla base di **Flow-MCMC** è creare un metodo di campionamento ibrido, che mantenga le caratteristiche migliori dei due: la convergenza alla distribuzione target di MCMC e la globalità del campionamento di un NF.

Independence sampler Un metodo Metropolis-Hastings si dice *independence sampler* se la distribuzione di proposta $\Gamma(\mathbf{x} \rightarrow \mathbf{y})$ non dipende dallo stato corrente $\mathbf{x}$, ossia $\Gamma(\mathbf{x} \rightarrow \mathbf{y}) = \Gamma(\mathbf{y})$ per ogni $\mathbf{x}$. Ogni candidato $\mathbf{y}$ è dunque un campione indipendente estratto da Γ , accettato o rifiutato secondo il consueto criterio di Metropolis-Hastings.

Utilizzando la distribuzione $p_X(\mathbf{x}; \boldsymbol{\theta})$, ottenuta dall'addestramento di $T_{\boldsymbol{\theta}}$, come distribuzione di proposta $\Gamma(\mathbf{x} \rightarrow \mathbf{y})$ all'interno di una catena di Metropolis-Hastings (Sez. 2.3.2), si ottiene un independence sampler. Infatti a differenza della proposta gaussiana locale, la proposta ottenuta dal flow non dipende dallo stato corrente della catena:

$$\Gamma(\mathbf{x}_i \rightarrow \mathbf{y}) = \Gamma(\mathbf{y}) = p_X(\mathbf{y}; \boldsymbol{\theta}), \quad \mathbf{y} = T_{\boldsymbol{\theta}}(\mathbf{z}), \quad \mathbf{z} \sim p_Z(\mathbf{z}). \quad (3.44)$$

Ricordando il tasso di accettazione generale di Metropolis-Hastings per una catena con distribuzione target non normalizzata $f(\mathbf{x})$ (Sez. 2.3.2),

$$\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left(1, \frac{\Gamma(\mathbf{y} \rightarrow \mathbf{x}_i) f(\mathbf{y})}{\Gamma(\mathbf{x}_i \rightarrow \mathbf{y}) f(\mathbf{x}_i)} \right), \quad (3.45)$$

nel caso dell'independence sampler si ha $\Gamma(\mathbf{y} \rightarrow \mathbf{x}_i) = \Gamma(\mathbf{x}_i)$ e $\Gamma(\mathbf{x}_i \rightarrow \mathbf{y}) = \Gamma(\mathbf{y})$, per cui l'espressione si semplifica in

$$\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left(1, \frac{\Gamma(\mathbf{x}_i) f(\mathbf{y})}{\Gamma(\mathbf{y}) f(\mathbf{x}_i)} \right), \quad (3.46)$$

Poiché $\Gamma(\mathbf{x}) = p_X(\mathbf{x}; \boldsymbol{\theta})$ è valutabile tramite il cambio di variabile

$$\Gamma(\mathbf{y}) = p_Z(\mathbf{z}) \left| \det J_{T_{\boldsymbol{\theta}}}(\mathbf{z}) \right|^{-1}, \quad (3.47)$$

calcolabile con un solo passaggio in avanti, poiché è sufficiente memorizzare $\log \Gamma$ al momento della generazione e riutilizzarlo ai confronti successivi, evitando così l'inversione di $T_{\boldsymbol{\theta}}$.

Si riporta l'algoritmo di Flow-MCMC, basato sulla struttura di Metropolis-Hastings:

Algorithm 3: Flow-MCMC

Input: Flow addestrato T_θ , distribuzione base p_Z , target non normalizzato $f(\mathbf{x})$, numero di passi N

Output: Catena $\{\mathbf{x}_0, \dots, \mathbf{x}_N\}$

Campiona $\mathbf{z}_0 \sim p_Z(\mathbf{z})$; $\mathbf{x}_0 \leftarrow T_\theta(\mathbf{z}_0)$;
 $\log \Gamma(\mathbf{x}_0) \leftarrow \log p_Z(\mathbf{z}_0) - \log |\det J_{T_\theta}(\mathbf{z}_0)|$;
for $i = 0$ **to** $N - 1$ **do**
 Genera un candidato $\mathbf{z} \sim p_Z(\mathbf{z})$; $\mathbf{y} \leftarrow T_\theta(\mathbf{z})$;
 $\Gamma(\mathbf{y}) \leftarrow p_Z(\mathbf{z}) |\det J_{T_\theta}(\mathbf{z})|^{-1}$;
 Genera $u \sim \mathcal{U}(0, 1)$;
 Calcola il tasso di accettazione $\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left(1, \frac{\Gamma(\mathbf{x}_i) f(\mathbf{y})}{\Gamma(\mathbf{y}) f(\mathbf{x}_i)} \right)$;
 if $u < \mathcal{A}(\mathbf{x}_i, \mathbf{y})$ **then**
 | Imposta $\mathbf{x}_{i+1} \leftarrow \mathbf{y}$, $\Gamma(\mathbf{x}_{i+1}) \leftarrow \Gamma(\mathbf{y})$; // Proposta accettata
 else
 | Imposta $\mathbf{x}_{i+1} \leftarrow \mathbf{x}_i$, $\Gamma(\mathbf{x}_{i+1}) \leftarrow \Gamma(\mathbf{x}_i)$; // Proposta rifiutata
 end
end

Si noti che l'algoritmo è formulato per un target non normalizzato $f(\mathbf{x})$ del tutto generico: nel caso della distribuzione di Boltzmann trattata in questo lavoro si ha semplicemente $f(\mathbf{x}) = \tilde{p}_X(\mathbf{x}) = e^{-\beta \mathcal{H}(\mathbf{x})}$, ma lo schema resta valido per qualunque distribuzione target di cui sia nota la densità non normalizzata.

Convergenza ed efficienza La convergenza asintotica a $p_X^*(\mathbf{x})$ non dipende dalla qualità dell'addestramento del flow. La domanda è se l'efficienza di tale convergenza possa dipendere da quanto bene $p_X(\mathbf{x}; \theta)$ approssima la distribuzione target. Infatti per avere un metodo più efficiente possibile vorremmo che ogni proposta fosse accettata, di modo che la catena si muovi liberamente fra i modi. Si può dimostrare la seguente affermazione

$$p_X(\mathbf{x}; \theta) \approx p_X^*(\mathbf{x}) \implies \mathcal{A} \approx 1. \quad (3.48)$$

Partendo dal tasso di accettazione

$$\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left(1, \frac{\Gamma(\mathbf{x}_i) f(\mathbf{y})}{\Gamma(\mathbf{y}) f(\mathbf{x}_i)} \right) = \min \left(1, \frac{p_X(\mathbf{x}_i; \theta) f(\mathbf{y})}{p_X(\mathbf{y}; \theta) f(\mathbf{x}_i)} \right) \quad (3.49)$$

e utilizzando l'ipotesi di buon addestramento e ricordando $p_X^*(\mathbf{x}) = \frac{f(\mathbf{x})}{Z}$, si ottiene:

$$\mathcal{A}(\mathbf{x}_i, \mathbf{y}) \approx \min \left(1, \frac{p_X^*(\mathbf{x}_i) f(\mathbf{y})}{p_X^*(\mathbf{y}) f(\mathbf{x}_i)} \right) = \min(1, 1) = 1 \quad (3.50)$$

CAPITOLO 4

Studio del campionamento

4.1 Il potenziale doppio pozzo

4.2 Limiti di Markov Chain Monte Carlo

4.2.1 Dettagli implementativi




Figura 4.1

4.2.2 Risultati




Figura 4.2




Figura 4.3




Figura 4.4




Figura 4.5

4.3 Confronto dei metodi di campionamento

4.3.1 Dettagli implementativi

4.3.2 Confronto al variare di T




Figura 4.6




Figura 4.7




Figura 4.8




Figura 4.9

4.3.3 Confronto al variare di N







Figura 4.10



(a) Prima




(b) Seconda



(c) Terza


Figura 4.11

4.3.4 Distribuzioni e traiettorie del camminatore



(a) Prima

(b) Seconda



(c) Terza

Figura 4.12





Figura 4.13

Conclusione

APPENDICE A

Derivazione della distribuzione di Boltzmann

Il comportamento del sistema a fissata T è descritto da una distribuzione di probabilità $p(\mathbf{x}, T)$ ottenibile attraverso il principio di massima entropia.

$$\mathcal{S} = - \int_{\mathbb{R}^D} p(\mathbf{x}, T) \ln(p(\mathbf{x}, T)) d\mathbf{x} \quad (\text{A.1})$$

Per massimizzare l'entropia si utilizza il teorema dei moltiplicatori di Lagrange:

$$\mathcal{L}[p] = - \int_{\mathbb{R}^D} p \ln p d\mathbf{x} - \alpha \left(\int_{\mathbb{R}^D} p d\mathbf{x} - 1 \right) - \beta \left(\int_{\mathbb{R}^D} p \mathcal{H} d\mathbf{x} - \langle E \rangle \right), \quad (\text{A.2})$$

dove α e β sono i moltiplicatori di Lagrange associati rispettivamente al vincolo di normalizzazione

$$\int_{\mathbb{R}^D} p(\mathbf{x}, T) d\mathbf{x} = 1, \quad (\text{A.3})$$

e al vincolo sul valore medio dell'energia

$$\int_{\mathbb{R}^D} p(\mathbf{x}, T) \mathcal{H}(\mathbf{x}) d\mathbf{x} = \langle E \rangle. \quad (\text{A.4})$$

La massimizzazione impone $\delta \mathcal{L} / \delta p = 0$ restituendo:

$$-\ln p(\mathbf{x}, T) - 1 - \alpha - \beta \mathcal{H}(\mathbf{x}) = 0 \quad (\text{A.5})$$

che permette di determinare $p(\mathbf{x}, T)$:

$$p(\mathbf{x}, T) = e^{-1-\alpha} e^{-\beta \mathcal{H}(\mathbf{x})}. \quad (\text{A.6})$$

Il moltiplicatore α è fissato dalla condizione di normalizzazione: definendo la **funzione di partizione**

$$Z(\beta) = \int_{\mathbb{R}^D} e^{-\beta \mathcal{H}(\mathbf{x})} d\mathbf{x}, \quad (\text{A.7})$$

si ha $e^{-1-\alpha} = 1/Z(\beta)$, da cui **la distribuzione di Boltzmann**:

$$p(\mathbf{x}, T) = \frac{1}{Z(\beta)} e^{-\beta \mathcal{H}(\mathbf{x})}. \quad (\text{A.8})$$

Dove $\beta = 1/(k_B T)$.

Bibliografia

- [1] Timothy Budd. Monte carlo techniques. Lecture notes for the course NWI-NM042B, Radboud University, 2025.
- [2] Enzo Marinari, Giorgio Parisi, and Luca Leuzzi. *Calcolo delle probabilità. Un trattatello per principianti volenterosi*. Zanichelli, Bologna, 2023.
- [3] Malcolm P. Kennett. *Essential Statistical Physics*. Cambridge University Press, Cambridge, UK, 2020.
- [4] Comte de Buffon, Georges-Louis Leclerc. Essai d’arithmétique morale, 1777. Supplément à l’Histoire Naturelle, vol. 4, Paris: de l’Imprimerie Royale.
- [5] Pierre-Simon de Laplace. *Théorie analytique des probabilités*. L’Académie des Sciences, Paris, 1886. Oeuvres Complètes de Laplace, Vol. 7, Part 2.
- [6] Nicholas Metropolis. The beginning of the monte carlo method. *Los Alamos Science*, Special Issue, 1987.
- [7] Malvin H. Kalos and Paula A. Whitlock. *Monte Carlo Methods*. Wiley-VCH, Weinheim, 2nd edition, 2008.
- [8] James E. Gubernatis, Naoki Kawashima, and Philipp Werner. *Quantum Monte Carlo Methods*. Cambridge University Press, Cambridge, UK, 2016.
- [9] Luca Leoni. Enhancing diagrammatic Monte Carlo via machine learning. Master’s thesis, University of Bologna, Department of Physics and Astronomy, Bologna, Italy, 2023. Supervisor: Prof. Cesare Franchini. Academic Year 2022/2023.
- [10] Nicholas Metropolis, Arianna W. Rosenbluth, Marshall N. Rosenbluth, Augusta H. Teller, and Edward Teller. Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6), 1953.
- [11] W. Keith Hastings. Monte carlo sampling methods using Markov chains and their applications. *Biometrika*, 57(1), 1970.
- [12] H. Flyvbjerg and H. G. Petersen. Error estimates on averages of correlated data. *The Journal of Chemical Physics*, 91(1), 1989.
- [13] Alan D. Sokal. Monte carlo methods in statistical mechanics: Foundations and new algorithms. In *Lectures at the Cargèse Summer School on “Functional Integration: Basics and Applications”*, Cargèse, France, September 1996.

-
- [14] George Papamakarios, Eric Nalisnick, Danilo Jimenez Rezende, Shakir Mohamed, and Balaji Lakshminarayanan. Normalizing flows for probabilistic modeling and inference. *Journal of Machine Learning Research*, 22(57), 2021.
 - [15] Walter Rudin. *Real and Complex Analysis*. Tata McGraw-Hill Education, 2006.
 - [16] Laurent Dinh, Jascha Sohl-Dickstein, and Samy Bengio. Density estimation using real NVP. In *International Conference on Learning Representations*, 2017.
 - [17] Solomon Kullback and Richard A. Leibler. On information and sufficiency. *The Annals of Mathematical Statistics*, 22(1), 1951.
 - [18] Frank Noé, Simon Olsson, Jonas Köhler, and Hao Wu. Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning. *Science*, 365(6457):eaaw1147, 2019.

Ringraziamenti