

ALMA MATER STUDIORUM · UNIVERSITÀ DI BOLOGNA

Dipartimento di Fisica e Astronomia “Augusto Righi”
Corso di Laurea in Fisica

Metodi Monte Carlo e Normalizing Flows per il campionamento di distribuzioni di Boltzmann multimodali.

Relatore:

Prof. Cesare Franchini

Presentata da:

Riccardo Pivi

Correlatore:

Dott. Luca Leoni

Anno Accademico 2025/2026

*A mio fratello e ai miei genitori,
per essere stati il mio faro e il mio porto sicuro.*

Sommario

Qui inserisci il testo del sommario...

Indice

Introduzione	8
1 Probabilità e meccanica statistica	9
1.1 Teoria della probabilità	9
1.1.1 Spazi di probabilità e variabili aleatorie	9
1.1.2 Distribuzioni di probabilità continue	10
1.1.3 Distribuzioni unimodali e multimodali	11
1.1.4 Valori di aspettazione e campionamento	12
1.2 Meccanica statistica	14
1.2.1 Il concetto di ensemble statistico	14
1.2.2 L'ensemble canonico	14
1.2.3 Derivazione della distribuzione di Boltzmann	14
1.2.4 La distribuzione di Boltzmann	15
2 Metodi Monte Carlo	17
2.1 Accenni storici	17
2.2 Monte Carlo diretto	19
2.2.1 Metodo dell'inversa	19
2.3 Markov Chain Monte Carlo	21
2.3.1 Catene di Markov	21
2.3.2 Algoritmo di Metropolis	22
2.4 Campioni autocorrelati	25
2.4.1 Blocking Analysis	25
2.4.2 Metodo di Sokal	25
3 Normalizing Flows	26
3.1 Cambio di variabili e funzioni invertibili	26
3.2 Normalizing Flows	26
3.2.1 Espressività del Flow	26
3.2.2 Campionamento, inferenza ed addestramento	26
3.2.3 Costruire un Flow tramite composizione finita	26
3.2.4 Coupling Flow	26

3.2.5	Trasformazione affine	26
3.2.6	Coupling layers	26
3.2.7	Real NVP	26
3.2.8	Esempi	26
3.3	Flow Markov Chain Monte Carlo	26
4	Studio del campionamento	27
4.1	Il potenziale doppio pozzo	28
4.2	Limiti di Markov Chain Monte Carlo	28
4.2.1	Dettagli implementativi	28
4.2.2	Risultati	29
4.3	Confronto dei metodi di campionamento	33
4.3.1	Dettagli implementativi	33
4.3.2	Confronto al variare di T	33
4.3.3	Confronto al variare di N	38
4.3.4	Distribuzioni e traiettorie del camminatore	41
	Conclusione	43
	Bibliografia	44
	Ringraziamenti	45

Introduzione

CAPITOLO 1

Probabilità e meccanica statistica

In questo capitolo vengono introdotti alcuni concetti fondamentali di probabilità necessari per comprendere il problema del campionamento: esso consiste nel generare una successione di configurazioni secondo una determinata distribuzione di probabilità. Tale problema assume particolare rilevanza in meccanica statistica, dove le proprietà macroscopiche di un sistema possono essere ricavate a partire dalle configurazioni microscopiche che lo costituiscono.

Dopo aver introdotto le nozioni di base relative alle variabili aleatorie e alle distribuzioni di probabilità, si discuterà l'importanza del campionamento di una distribuzione (1.1). Infine, si introdurrà l'ensemble canonico, con particolare attenzione alla distribuzione di Boltzmann (1.2), che rappresenta la distribuzione target dei metodi di campionamento studiati nel seguito di questa tesi.

1.1 Teoria della probabilità

1.1.1 Spazi di probabilità e variabili aleatorie

In teoria della probabilità ha un ruolo fondamentale **lo spazio di probabilità** $(\Omega, \mathcal{A}, P)$: dove Ω è l'insieme di tutti i possibili esiti χ , $\mathcal{A}$ è la sigma-algebra su Ω e P è una misura di probabilità su $\mathcal{A}$. Un sottoinsieme $A \subset \Omega$ è chiamato evento ed ad ognuno di essi è possibile associare un numero reale $P(A) \in [0, 1]$ - ovvero la probabilità di tale evento.

In particolare è necessario che siano soddisfatte $P(\Omega) = 1$, $P(\emptyset) = 0$ e per ogni insieme di eventi numerabili disgiunti A_i valga:

$$P\left(\bigcup_{i=1} A_i\right) = \sum_{i=1} P(A_i). \quad (1.1)$$

Esempio 1.1.1: Tiri di un dado

Quando si tira un dado a sei facce si considera lo spazio degli eventi $\Omega = \{1, 2, \dots, 6\}$ e la misura di probabilità $P(\chi_i) = 1/6$ per ogni $\chi_i \in \Omega$. Un esempio di evento è il caso in cui risultato del tiro sia pari $A = \{2, 4, 6\} \subset \Omega$ con probabilità calcolabile nel seguente modo: $P(A) = P(2) + P(4) + P(6) = 1/2$.

Una **variabile aleatoria** (reale) X associa agli elementi di uno spazio degli esiti Ω valori appartenenti a uno spazio misurabile $(\mathbb{R})$. Una variabile aleatoria X associa a ciascun esito χ un valore x appartenente allo spazio dei valori possibili della variabile. Nel caso di una variabile aleatoria reale si ha quindi:

$$X : \Omega \rightarrow \mathbb{R}. \quad (1.2)$$

1.1.2 Distribuzioni di probabilità continue

Data una variabile aleatoria X essa ha associata una funzione **distribuzione cumulativa** $F_X(x)$, definita da:

$$F_X(x) = P(X \leq x). \quad (1.3)$$

Dunque la probabilità che X assuma un valore compreso tra due estremi a e b è data da:

$$P(a < X \leq b) = F_X(b) - F_X(a). \quad (1.4)$$

$F_X(x)$ è una funzione di x monotona, nondecrecente e definita su tutto l'asse reale con le proprietà: $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$. Se $F_X(x)$ è ovunque differenziabile, la variabile aleatoria X è continua. Dunque una densità di probabilità $p_X(x)$ associata ad X esiste e soddisfa

$$p_X(x) = \frac{d F_X(x)}{dx} \quad (1.5)$$

La densità di probabilità deve inoltre soddisfare la condizione di normalizzazione ed essere non negativa per ogni valore della variabile aleatoria:

$$\int_{-\infty}^{+\infty} p_X(x) dx = 1 \quad (1.6)$$

$$p_X(x) \geq 0 \quad \forall x \in \mathbb{R}. \quad (1.7)$$

È importante sottolineare che la densità di probabilità non rappresenta direttamente la probabilità che la variabile assuma un determinato valore. Infatti, la probabilità di ottenere esattamente un particolare valore x_0 è nulla. La densità di probabilità permette invece di calcolare la probabilità che la variabile aleatoria assuma un valore appartenente

a un determinato intervallo. In particolare, la probabilità che X appartenga all'intervallo $[a, b]$ è data da

$$P(a \leq X \leq b) = \int_a^b p_X(x) dx. \quad (1.8)$$

La distribuzione di probabilità può quindi essere interpretata geometricamente: la probabilità associata a un intervallo corrisponde all'area sottesa dalla densità di probabilità nell'intervallo considerato. Una maggiore densità di probabilità in una determinata regione indica quindi una maggiore probabilità di osservare valori della variabile in quella regione [1].

Esempio 1.1.2: Variabile aleatoria uniforme

La variabile aleatoria uniforme U su (a, b) , con $a < b$, ha funzione di densità di probabilità $f_U(x) = \begin{cases} \frac{1}{b-a} & \text{se } a \leq x \leq b \\ 0 & \text{altrimenti} \end{cases}$

Nel seguito sarà particolarmente utile considerare variabili aleatorie multidimensionali. Una configurazione microscopica di un sistema fisico può infatti essere rappresentata mediante un vettore:

$$\mathbf{x} = (x_1, x_2, \dots, x_D) \in \mathbb{R}^D, \quad (1.9)$$

dove D rappresenta il numero di gradi di libertà del sistema. In questo caso la distribuzione di probabilità è descritta da una densità $p(\mathbf{x})$, normalizzata sulla totalità dello spazio delle configurazioni $\mathbb{R}^D$:

$$\int_{\mathbb{R}^D} p(\mathbf{x}) d\mathbf{x} = 1. \quad (1.10)$$

La densità $p(\mathbf{x})$ permette di determinare la probabilità che una configurazione appartenga a una determinata regione $\mathcal{A}$ dello spazio delle configurazioni:

$$P(\mathbf{x} \in \mathcal{A}) = \int_{\mathcal{A}} p(\mathbf{x}) d\mathbf{x}. \quad (1.11)$$

1.1.3 Distribuzioni unimodali e multimodali

Una distribuzione di probabilità può presentare una struttura caratterizzata dalla presenza di uno o più massimi locali. In particolare, si definisce distribuzione **unimodale** una distribuzione caratterizzata da un'unica regione di massima probabilità detta **modo**. Un esempio tipico è rappresentato dalla distribuzione gaussiana, che presenta un unico massimo in corrispondenza del suo valore medio.

Una distribuzione **multimodale**, invece, presenta più regioni distinte di alta probabilità, associate a più massimi locali della densità. In questo caso, ciascun massimo

identifica un modo della distribuzione. Le diverse regioni ad alta probabilità possono essere separate da regioni caratterizzate da una densità molto più bassa. Il caso particolare in cui vi siano due massimi locali è detto distribuzione **bimodale**. La differenza qualitativa tra le due tipologie di distribuzioni è illustrata in Figura 1.1.




Figura 1.1: Confronto tra una distribuzione unimodale (gaussiana) e una distribuzione multimodale (bimodale).

La distinzione tra distribuzioni unimodali e multimodali è particolarmente importante nel problema del campionamento. Nel caso di una distribuzione unimodale, un metodo di campionamento che esplori efficacemente la regione attorno al massimo della distribuzione può ottenere un campione rappresentativo dell'intera distribuzione. Nel caso multimodale, invece, il campionamento può risultare più complesso, poiché è necessario esplorare tutte le regioni rilevanti dello spazio delle configurazioni e riprodurre correttamente la probabilità associata a ciascun modo e non esclusivamente a quello di maggiore densità.

Se le diverse regioni ad alta probabilità sono separate da zone di bassa probabilità, un metodo di campionamento locale può infatti rimanere confinato per lungo tempo all'interno di uno dei modi, esplorando con difficoltà gli altri. Il fenomeno è chiamato *intrappolamento in un modo* ed è una delle principali difficoltà associate al campionamento di distribuzioni multimodali ed è il motivo dell'inefficienza dei metodi di campionamento locali. In questi casi, è necessario adottare strategie più sofisticate per garantire un campionamento efficace e rappresentativo dell'intera distribuzione.

1.1.4 Valori di aspettazione e campionamento

Sia $p(\mathbf{x})$ la densità di probabilità della variabile aleatoria e $O(\mathbf{x})$ una funzione della variabile aleatoria, il valore di aspettazione di $O(\mathbf{x})$ è calcolabile tramite il seguente

integrale:

$$\langle O(\mathbf{x}) \rangle = \int_{\mathbb{R}^D} O(\mathbf{x}) p(\mathbf{x}) d\mathbf{x}. \quad (1.12)$$

La convergenza dell'integrale non è affatto garantita e dipende dall'andamento della funzione $O(\mathbf{x})$ e da $p(\mathbf{x})$, inoltre questo integrale non è sempre facilmente risolvibile analiticamente o numericamente. Un approccio diretto al calcolo di $\langle O(\mathbf{x}) \rangle$ potrebbe basarsi su metodi di quadratura numerica [2], che discretizzano lo spazio delle configurazioni su una griglia e approssimano l'integrale come somma pesata sui punti della griglia.

Esempio 1.1.3: Metodo del trapezio

Nel caso unidimensionale il metodo di quadratura approssima l'integrale di una funzione $f(x)$ su un intervallo $[a, b]$ mediante la formula:

$$\int_a^b f(x) dx \approx \sum_i^N \int_{x_i-\epsilon}^{x_i+\epsilon} f(x) dx \quad (1.13)$$

dove x_i sono i punti della griglia e ϵ è la metà della distanza tra due punti consecutivi. Il metodo del trapezio approssima ciascun integrale locale con l'area di un trapezio, sostituendo l'integrale con:

$$\int_{x_i-\epsilon}^{x_i+\epsilon} f(x) dx \approx \frac{f(x_i - \epsilon) + f(x_i + \epsilon)}{2} \cdot 2\epsilon \quad (1.14)$$

Se lo spazio delle configurazioni ha dimensione D e si utilizzano N punti per ciascuna direzione, il numero totale di valutazioni della funzione integranda cresce come N^D . Per sistemi con un numero elevato di gradi di libertà, come tipicamente accade in meccanica statistica, questa crescita esponenziale rende i metodi di quadratura del tutto inapplicabili. In questi casi, il problema del calcolo di valori di aspettazione può essere affrontato in maniera più efficiente mediante metodi di campionamento, che permettono di stimare l'integrale senza la necessità di discretizzare lo spazio delle configurazioni.

L'idea alla base dei metodi di campionamento consiste - anziché valutare la funzione integranda su una griglia deterministica - nel generare un insieme di configurazioni $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ distribuite secondo la densità di probabilità $p(\mathbf{x})$, e nello stimare i valori di aspettazione mediante la media aritmetica:

$$\langle O(\mathbf{x}) \rangle \approx \frac{1}{N} \sum_{i=1}^N O(\mathbf{x}_i). \quad (1.15)$$

Per la legge dei grandi numeri la stima converge, per $N \rightarrow \infty$, al valore di aspettazione esatto $\langle O(\mathbf{x}) \rangle$, a patto che le configurazioni campionate $\mathbf{x}_i$ siano effettivamente distribuite

secondo $p(\mathbf{x})$. Un aspetto cruciale di questo approccio è che, se le configurazioni sono indipendenti, l'errore statistico associato allo stimatore decresce col numero di campioni N come:

$$\sigma_{\langle O \rangle} \sim \frac{\sigma_O}{\sqrt{N}}, \quad (1.16)$$

dove σ_O è la deviazione standard di $O(\mathbf{x})$ rispetto a $p(\mathbf{x})$.

Diversamente dai metodi di quadratura, questo risultato non dipende esplicitamente dalla dimensione D dello spazio delle configurazioni: è questa caratteristica a rendere i metodi di campionamento lo strumento privilegiato per lo studio di sistemi ad alta dimensionalità. Il problema è dunque generare un insieme di configurazioni distribuite secondo $p(\mathbf{x})$ di modo da poter stimare i valori di aspettazione. I metodi, per cui sarà possibile creare questi campioni, saranno oggetto dei capitoli successivi.

1.2 Meccanica statistica

1.2.1 Il concetto di ensemble statistico

... [3]

1.2.2 L'ensemble canonico

Consideriamo un sistema fisico descritto da una hamiltoniana $\mathcal{H}(\mathbf{x})$ dove $\mathbf{x}$ rappresenta collettivamente i gradi di libertà del sistema: posizioni, impulsi, o in generale le variabili che definiscono uno stato microscopico. L'ensemble canonico permette di descrivere il comportamento termodinamico di un sistema posto a contatto termico con un *reservoir* a temperatura T fissata, con cui può scambiare energia ma non particelle. L'energia del sistema fluttua attorno a un valore medio $\langle E \rangle$ determinato dall'equilibrio termico con il serbatoio.

...

1.2.3 Derivazione della distribuzione di Boltzmann

Il comportamento del sistema a fissata T è descritto da una distribuzione di probabilità $\rho(\mathbf{x}, T)$ ottenibile attraverso il principio di massima entropia.

$$\mathcal{S} = - \int_{\mathbb{R}^D} \rho(\mathbf{x}, T) \ln(\rho(\mathbf{x}, T)) d\mathbf{x} \quad (1.17)$$

Per massimizzare l'entropia si utilizza il teorema dei moltiplicatori di Lagrange:

$$\mathcal{L}[\rho] = - \int_{\mathbb{R}^D} \rho \ln \rho \, d\mathbf{x} - \alpha \left(\int_{\mathbb{R}^D} \rho \, d\mathbf{x} - 1 \right) - \beta \left(\int_{\mathbb{R}^D} \rho \mathcal{H} \, d\mathbf{x} - \langle E \rangle \right), \quad (1.18)$$

dove α e β sono i moltiplicatori di Lagrange associati rispettivamente al vincolo di normalizzazione

$$\int_{\mathbb{R}^D} \rho(\mathbf{x}, T) \, d\mathbf{x} = 1, \quad (1.19)$$

e al vincolo sul valore medio dell'energia

$$\int_{\mathbb{R}^D} \rho(\mathbf{x}, T) \mathcal{H}(\mathbf{x}) \, d\mathbf{x} = \langle E \rangle. \quad (1.20)$$

La massimizzazione impone $\delta \mathcal{L} / \delta \rho = 0$ restituendo:

$$-\ln \rho(\mathbf{x}, T) - 1 - \alpha - \beta \mathcal{H}(\mathbf{x}) = 0 \quad (1.21)$$

che permette di determinare $\rho(\mathbf{x}, T)$:

$$\rho(\mathbf{x}, T) = e^{-1-\alpha} e^{-\beta \mathcal{H}(\mathbf{x})}. \quad (1.22)$$

Il moltiplicatore α è fissato dalla condizione di normalizzazione: definendo la **funzione di partizione**

$$Z(\beta) = \int_{\mathbb{R}^D} e^{-\beta \mathcal{H}(\mathbf{x})} \, d\mathbf{x}, \quad (1.23)$$

si ha $e^{-1-\alpha} = 1/Z(\beta)$, da cui **la distribuzione di Boltzmann**:

$$\rho(\mathbf{x}, T) = \frac{1}{Z(\beta)} e^{-\beta \mathcal{H}(\mathbf{x})}. \quad (1.24)$$

Dove $\beta = 1/(k_B T)$.

1.2.4 La distribuzione di Boltzmann

La distribuzione di Boltzmann descrive la probabilità di osservare il sistema in una configurazione microscopica quando esso si trova all'equilibrio termico con un serbatoio a temperatura T fissata.

Dalla massimizzazione dell'entropia, soggetta ai vincoli di normalizzazione della distribuzione e di valore medio dell'energia costante, si ottiene

$$\rho(\mathbf{x}, T) = \frac{1}{Z(\beta)} e^{-\beta \mathcal{H}(\mathbf{x})} \quad (1.25)$$

,

dove $\beta = \frac{1}{k_B T}$ e $Z(\beta) = \int_{\mathbb{R}^D} e^{-\beta \mathcal{H}(\mathbf{x})} d\mathbf{x}$ è la funzione di partizione.

Il prodotto $\beta \mathcal{H}(\mathbf{x})$ determina la probabilità di ciascuna configurazione e si può facilmente comprendere come all'aumentare della temperatura sono probabilisticamente permessi una gamma più ampia di stati; al diminuire della temperatura, invece, la probabilità si concentra progressivamente negli stati di energia minima. Inoltre, la funzione di partizione svolge un ruolo centrale, poiché garantisce la normalizzazione della distribuzione e contiene tutta l'informazione termodinamica del sistema. Infatti, una volta nota $Z(\beta)$, è possibile ricavare grandezze quali energia libera, energia media, entropia e capacità termica.

Formule delle osservabili termodinamiche in funzione della funzione di partizione

Nella maggior parte dei sistemi di interesse fisico la funzione di partizione non può essere calcolata in forma chiusa. Essa richiede infatti l'integrazione della quantità:

$$e^{-\beta \mathcal{H}(\mathbf{x})} \quad (1.26)$$

su tutto lo spazio delle configurazioni, che è uno spazio multidimensionale di dimensione pari al numero di gradi di libertà del sistema. Per sistemi costituiti da molte particelle il calcolo diretto dell'integrale è proibitivo: basti pensare ad un gas ideale con un numero di Avogadro ($\sim 10^{23}$) di particelle. Di conseguenza, anche il valore assoluto della distribuzione di Boltzmann non è generalmente noto, poiché dipende dalla funzione di partizione. Tuttavia è possibile valutare il rapporto tra le probabilità di due configurazioni,

$$\frac{\rho(\mathbf{x}_2, T)}{\rho(\mathbf{x}_1, T)} = e^{-\beta[\mathcal{H}(\mathbf{x}_2) - \mathcal{H}(\mathbf{x}_1)]}, \quad (1.27)$$

nel quale il fattore di normalizzazione $Z(\beta)$ si semplifica, oppure è possibile valutare solo il fattore di Boltzmann $e^{-\beta \mathcal{H}(\mathbf{x})}$.

Questa osservazione è importante per i capitoli successivi poiché per poter campionare la distribuzione di Boltzmann sarà necessario avere metodi che possono generare configurazioni distribuite secondo una distribuzione seppur conoscendola a meno della costante di normalizzazione.

CAPITOLO 2

Metodi Monte Carlo

I metodi Monte Carlo rappresentano una classe di tecniche numeriche che permettono di stimare quantità altrimenti inaccessibili per via analitica, sostituendo il calcolo esatto con una stima statistica basata sul campionamento casuale. In fisica statistica questo approccio è particolarmente prezioso: il calcolo di valori di aspettazione rispetto alla distribuzione di Boltzmann richiede in generale la valutazione di integrali in uno spazio delle configurazioni ad altissima dimensionalità, per cui le tecniche di quadratura deterministica diventano rapidamente inapplicabili. L'idea alla base del metodo — sostituire il calcolo esatto con una stima ottenuta da un numero sufficiente di "prove" — nacque in un contesto scientifico unico a livello storico, per poi diventare uno degli strumenti computazionali più importanti del Novecento.

In questo capitolo vengono introdotti i concetti fondamentali dei metodi Monte Carlo. Si parte all'introduzione ai metodi Monte Carlo diretti (2.2), per poi affrontare il campionamento tramite catene di Markov (2.3), e poi verrà presentato l'algoritmo di Metropolis. Infine si discuterà di un aspetto cruciale per Markov Chain Monte Carlo: la presenza di correlazione tra i campioni generati, che rende necessaria un'attenta analisi statistica per una corretta stima degli errori (2.4).


2.1 Accenni storici

Il metodo Monte Carlo si basa su un'idea semplice, ma potente. L'idea nacque da Stanislaw Ulam (2.1a) - fisico e matematico polacco naturalizzato statunitense - durante una partita di solitario. La frustrazione del matematico nel cercare di calcolare analiticamente la probabilità di vincere una partita lo portò a realizzare che una buona stima di quest'ultima sarebbe stata possibile evitando completamente i calcoli.


Ulam capì che, se avesse giocato un numero sufficiente di partite, avrebbe potuto stimarla segnandosi quante di queste prove avrebbe vinto o perso. L'idea dal semplice gioco si spostò poi alla risoluzione di problemi di matematica e fisica: con i primi computer elettronici sarebbe stato possibile simulare un sistema generando campioni virtuali dello stesso così da ottenere stime accurate delle quantità ricercate. All'epoca Ulam lavorava

assieme a Von Neumann (2.1b) presso il Los Alamos National Laboratory, allora centro di ricerca segreto per lo sviluppo della prima bomba nucleare, qui era stato costruito l'ENIAC (Electronic numerical integrator and computer) uno dei primi computer elettronici digitali general purpose della storia. I due scienziati lavorarono ad una procedura stocastica basata sull'idea del matematico polacco per simulare il trasporto dei neutroni attraverso un materiale fissile. Il nome "Monte Carlo" fu proposto nel 1947 da un altro celebre fisico del gruppo, Nicholas Constantine Metropolis [4]. La scelta del nome, ispirata al celebre casinò situato nel Principato di Monaco, nacque per canzonare Ulam, il quale aveva uno zio con il vizio del gioco d'azzardo.


Vi è inoltre un precursore del metodo: Enrico Fermi (2.1c). Metropolis parlando con Emilio Segrè scoprì che Fermi aveva già ideato, in modo del tutto indipendente, un metodo basato sul campionamento statistico quindici anni prima di loro. Lo stesso Fermi infatti partecipando al progetto Manhattan (1942-1946) aiutò nello studio del trasporto dei neutroni costruendo insieme a Percy King il FERMIAC o anche denominato *Il carrello Monte Carlo*: un computer analogico che permetteva - data una distribuzione iniziale di neutroni - di sviluppare genealogie di neutroni in due dimensioni, o modelli di comportamento di neutroni individuali, comprendenti ciascuno collisioni, spargimenti, e fissioni. In ogni fase venivano usati numeri pseudo-casuali per ricavare le decisioni che influenzano il comportamento di ciascun neutrone.



(a) Stanisław Ulam e il FERMIAC.



(b) Von Neumann.



(c) Enrico Fermi.

Figura 2.1: I pionieri del metodo Monte Carlo.

2.2 Monte Carlo diretto

2.2.1 Metodo dell'inversa

Il metodo dell'inversa (o *inverse transform sampling*) è la tecnica di campionamento diretto più utilizzata: essa consente di generare campioni distribuiti secondo una generica densità di probabilità unidimensionale $p_X(x)$ a partire da una variabile aleatoria distribuita uniformemente nell'intervallo $[0, 1]$.

Sia X una variabile aleatoria continua con funzione di distribuzione cumulativa $F_X(x) = P(X \leq x)$ strettamente monotona e continua, tale da ammettere una funzione inversa $F_X^{-1} : (0, 1) \rightarrow \mathbb{R}$. Sia inoltre $U \sim \mathcal{U}(0, 1)$ una variabile aleatoria uniforme sull'intervallo $(0, 1)$.

Si consideri la variabile aleatoria definita dalla trasformazione inversa:

$$Y = F_X^{-1}(U). \quad (2.1)$$

Per determinare la funzione di distribuzione cumulativa di Y , valutiamo $F_Y(y) = P(Y \leq y)$:

$$F_Y(y) = P(F_X^{-1}(U) \leq y). \quad (2.2)$$

Poiché la funzione $F_X(x)$ è monotona strettamente crescente, applicando F_X ad entrambi i membri della disuguaglianza si ottiene:

$$P(F_X^{-1}(U) \leq y) = P(U \leq F_X(y)). \quad (2.3)$$

Ricordando che per una variabile aleatoria uniforme $U \sim \mathcal{U}(0, 1)$ vale la proprietà $P(U \leq u) = u$ per ogni $u \in [0, 1]$, si ha direttamente:

$$F_Y(y) = F_X(y). \quad (2.4)$$

Di conseguenza, la variabile aleatoria Y possiede la medesima distribuzione cumulativa di X e la sua densità di probabilità coincide con $p_X(x)$.

L'applicazione pratica del metodo dell'inversa per la generazione di N campioni indipendenti è sintetizzata nel seguente algoritmo:

Algorithm 1: Metodo dell'Inversa (Inverse Transform Sampling)

Input: Numero di campioni N ; funzione di distribuzione cumulativa inversa $F_X^{-1}(u)$.

Inizializza l'insieme dei campioni $\mathcal{S} = \emptyset$;

for $i = 1$ **to** N **do**

 Genera $u_i \sim \mathcal{U}(0, 1)$;

 Calcola $x_i = F_X^{-1}(u_i)$;

 Aggiungi x_i all'insieme $\mathcal{S}$;

end

Output: Insieme di campioni $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ distribuiti secondo $p_X(x)$.

Si mostra un esempio pratico di applicazione del metodo dell'inversa per il campionamento della distribuzione esponenziale, che illustra chiaramente i passaggi descritti nell'algoritmo precedente.

Esempio 2.2.1: Campionamento della distribuzione esponenziale

Si consideri la distribuzione di probabilità esponenziale con parametro $\lambda > 0$:

$$p_X(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x \geq 0, \\ 0 & \text{se } x < 0. \end{cases} \quad (2.5)$$

La relativa funzione di distribuzione cumulativa per $x \geq 0$ è data da:

$$F_X(x) = \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}. \quad (2.6)$$

Uguagliando $F_X(x)$ a una variabile uniforme $u \in (0, 1)$ ed invertendo la relazione:

$$u = 1 - e^{-\lambda x} \implies 1 - u = e^{-\lambda x} \implies x = -\frac{1}{\lambda} \ln(1 - u). \quad (2.7)$$

Poiché se $U \sim \mathcal{U}(0, 1)$ anche $(1 - U) \sim \mathcal{U}(0, 1)$, la formula generatrice si semplifica spesso in:

$$x = -\frac{1}{\lambda} \ln(u). \quad (2.8)$$

Il principale vantaggio del metodo dell'inversa risiede nella sua efficienza e semplicità: ciascun campione generato è perfettamente indipendente dagli altri e non vi è alcuna probabilità di rifiuto (a differenza dei metodi di Acceptance-Rejection o dei metodi Markov Chain Monte Carlo).

Tuttavia, il metodo presenta forti limitazioni pratiche, che ne riducono l'applicabilità a distribuzioni di probabilità complesse o multidimensionali:

- **Invertibilità analitica:** Richiede che la funzione di distribuzione cumulativa $F_X(x)$ sia integrabile ed invertibile in forma chiusa (o approssimabile numericamente con elevata precisione). Ad esempio, per la distribuzione gaussiana $F_X(x)$ coinvolge la funzione di errore (erf), la cui inversione richiede approssimazioni numeriche.
- **Costante di normalizzazione:** È applicabile solo se la densità di probabilità $p_X(x)$ è perfettamente normalizzata.

- **Dimensionalità:** Risulta di difficile estensione a distribuzioni ad alta dimensionalità $D \gg 1$, rendendolo di fatto inutilizzabile per il campionamento della distribuzione di Boltzmann in fisica statistica.

2.3 Markov Chain Monte Carlo

2.3.1 Catene di Markov

Sia $X_1, \dots, X_N$ una sequenza di variabili aleatorie in $\mathbb{R}^D$, questa sequenza è una catena di Markov se la probabilità condizionata di ogni X_i soddisfa:

$$P(X_i | X_{i-1}, \dots, X_1) = P(X_i | X_{i-1}). \quad (2.9)$$

Dunque la probabilità di ottenere un certo valore di X_i dipende solo dalla variabile aleatoria precedente della catena e non dalle altre, questa richiesta equivale a dire che le catene di Markov sono catene *senza memoria*, ovvero che solo l'ultimo stato della catena influenza il prossimo stato [5]. Considerando il caso che la variabile aleatoria X_i possa assumere un numero discreto di valori, ovvero che $X_i \in \{x_1, \dots, x_j, \dots\}$, in questo modo possiamo descrivere la distribuzione di probabilità e le probabilità condizionate di tali variabili utilizzando un vettore e una matrice rispettivamente:

$$P(X_i) = p_j^{(i)} = \begin{pmatrix} p^{(i)}(x_1) \\ \vdots \\ p^{(i)}(x_j) \\ \vdots \end{pmatrix}, \quad P(X_i | X_j) = P_{ij} = \begin{pmatrix} P(x_1|x_1) & \cdots & P(x_1|x_j) & \cdots \\ P(x_2|x_1) & \cdots & P(x_2|x_j) & \cdots \\ \vdots & \ddots & \vdots & \\ P(x_i|x_1) & \cdots & P(x_i|x_j) & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix} \quad (2.10)$$

La matrice P_{ij} rappresenta la probabilità di transizione dallo stato j allo stato i . Inoltre possiamo notare alcune proprietà interessanti sia per $p_j^{(i)}$ che per P_{ij} , in quanto $\forall i$ esse soddisfano:

$$\sum_j p_j^{(i)} = 1, \quad \sum_i P_{ij} = 1. \quad (2.11)$$

Data una distribuzione iniziale $p_i^{(0)}$ e la matrice stocastica P_{ij} detta **matrice di transizione**, si può evolvere la distribuzione in modo ricorsivo:

$$p_i^{(k+1)} = \sum_j P_{ij} p_j^{(k)} \text{ con } k \in \mathbb{N}. \quad (2.12)$$

Questa evoluzione della distribuzione di probabilità della catena conserva la normalizzazione della distribuzione, infatti:

$$\sum_i p_i^{(k+1)} = \sum_i \sum_j P_{ij} p_j^{(k)} = \sum_j p_j^{(k)} \sum_i P_{ij} = \sum_j p_j^{(k)} = 1. \quad (2.13)$$

Inoltre considerando una matrice di transizione ergodica (ovvero irriducibile e aperiodica) è assicurato che a prescindere dalla distribuzione iniziale $p_i^{(0)}$ iterando il procedimento si raggiunge una **distribuzione stazionaria** p_i tale che:

$$p_i = \sum_j P_{ij} p_j. \quad (2.14)$$

Ovvero si raggiunge una distribuzione di probabilità che non viene più modificata iterando il procedimento (per questo detta stazionaria), inoltre essa è l'autovettore della matrice di transizione P_{ij} con autovalore unitario. L'obiettivo di Markov Chain Monte Carlo è quello di costruire una catena di Markov che abbia come distribuzione stazionaria la distribuzione target p_i che vogliamo campionare. Per fare ciò è necessario costruire una matrice di transizione P_{ij} costruita in un certo modo.

Metropolis et al. (1953) proposero che fosse possibile ottenere una specifica distribuzione p_i se la P_{ij} soddisfa una certa condizione di simmetria detta **bilancio dettagliato**:

$$P_{ij} p_j = P_{ji} p_i. \quad (2.15)$$

Nella sezione successiva verrà presentato l'algoritmo di Metropolis, che permette di costruire una matrice di transizione P_{ij} che soddisfa la condizione di bilancio dettagliato permettendo di campionare una distribuzione target p_i .

2.3.2 Algoritmo di Metropolis

Dunque per poter calcolare le quantità termodinamiche di interesse è necessaria una matrice di transizione che soddisfi il bilancio dettagliato per la distribuzione di Boltzmann.

Metropolis et al. proposero di costruire la matrice di transizione P_{ij} come prodotto di due matrici:

$$P_{ij} = T_{ij} A_{ij}, \quad (2.16)$$

dove T_{ij} è la matrice di proposta, che rappresenta la probabilità di proporre una transizione dallo stato j allo stato i , e A_{ij} è la matrice di accettazione, che rappresenta la probabilità di accettare la transizione proposta. Gli elementi della matrice di proposta T_{ij} devono soddisfare le seguenti condizioni:

$$T_{ij} \geq 0, \quad \sum_i T_{ij} = 1 \quad \forall j, \quad T_{ij} = T_{ji}. \quad (2.17)$$

Mentre gli elementi della matrice di accettazione A_{ij} sono costruiti in modo che:

$$A_{ij} = \min \left(1, \frac{p_i}{p_j} \right). \quad (2.18)$$

Queste condizioni assicurando che la matrice di transizione rispetti il bilancio dettagliato, e quindi che la distribuzione stazionaria della catena di Markov sia la distribuzione target p_i , infatti (assumendo $p_i \leq p_j$ senza perdita di generalità):

$$P_{ij} = T_{ij}A_{ij} = T_{ji}\frac{p_i}{p_j} = P_{ji}\frac{p_i}{p_j} \implies P_{ij}p_j = P_{ji}p_i. \quad (2.19)$$

L'algoritmo di Metropolis è quindi un metodo per costruire una catena di Markov che campiona una distribuzione target p_i senza la necessità di conoscere la costante di normalizzazione della distribuzione, il seguente pseudocodice descrive l'operazione base dell'algoritmo di Metropolis:

Algorithm 2: Operazione base dell'algoritmo di Metropolis

Input: Configurazione $X^{(k)}$; distribuzione target $p(x)$ nota a meno della costante di normalizzazione; distribuzione di proposta simmetrica T .
 Genera uno stato proposto $X' \sim T(X^{(k)})$;
 Calcola la probabilità di accettazione $A = \min(1, \frac{p(X')}{p(X^{(k)})})$;
 Genera $u \sim \mathcal{U}(0, 1)$;
if $u \leq A$ **then**
 | **return** X' ;
else
 | **return** $X^{(k)}$;
end
Output: Configurazione $X^{(k+1)}$.

L'iterazione di questa operazione è l'algoritmo di Metropolis, che è possibile vedere rappresentato graficamente in figura 2.2, dove si osservano i passi del camminatore randomico, una distribuzione proposta (prior), una distribuzione target (posterior) e i campioni generati dal metodo.




Figura 2.2

Dalla definizione della matrice di accettazione A_{ij} è possibile notare che gli elementi di P_{ij} dipendono esclusivamente dal rapporto della probabilità target nelle due configurazioni considerate (attuale e proposta), dunque sono indipendenti dalla costante di normalizzazione della distribuzione target. Come già espresso nel capitolo precedente, questo è un aspetto cruciale per il campionamento della distribuzione di Boltzmann, in quanto la costante di normalizzazione della distribuzione è proprio la funzione di partizione, di cui non è sempre possibile calcolare analiticamente o numericamente.

Infine l'algoritmo di Metropolis trasferisce la responsabilità dell'ergodicità di P_{ij} alla matrice T_{ij} . Se in un numero finito di passi T_{ij} permette di raggiungere tutto lo spazio delle fasi, allora l'algoritmo di Metropolis è ergodico. Questo è un aspetto cruciale per il corretto funzionamento dell'algoritmo, in quanto la catena di Markov deve essere in grado di esplorare tutto lo spazio delle configurazioni per garantire che la distribuzione stazionaria sia effettivamente raggiunta. In altre parole, se la matrice di proposta T_{ij} non consente di visitare tutte le configurazioni possibili, l'algoritmo potrebbe rimanere intrappolato in una regione dello spazio delle fasi, portando a stime errate delle quantità termodinamiche.

2.4 Campioni autocorrelati

2.4.1 Blocking Analysis

2.4.2 Metodo di Sokal

Normalizing Flows

3.1 Cambio di variabili e funzioni invertibili

3.2 Normalizing Flows

3.2.1 Espressività del Flow

3.2.2 Campionamento, inferenza ed addestramento

3.2.3 Costruire un Flow tramite composizione finita

3.2.4 Coupling Flow

3.2.5 Trasformazione affine

3.2.6 Coupling layers

3.2.7 Real NVP

3.2.8 Esempi

3.3 Flow Markov Chain Monte Carlo

CAPITOLO 4

Studio del campionamento

4.1 Il potenziale doppio pozzo

4.2 Limiti di Markov Chain Monte Carlo

4.2.1 Dettagli implementativi




Figura 4.1

4.2.2 Risultati




Figura 4.2




Figura 4.3




Figura 4.4




Figura 4.5

4.3 Confronto dei metodi di campionamento

4.3.1 Dettagli implementativi

4.3.2 Confronto al variare di T




Figura 4.6




Figura 4.7




Figura 4.8




Figura 4.9






Figura 4.10


4.3.3 Confronto al variare di N



(a) Prima




(b) Seconda




(c) Terza


Figura 4.11



(a) Prima




(b) Seconda




(c) Terza

Figura 4.12


4.3.4 Distribuzioni e traiettorie del camminatore



(a) Prima



(b) Seconda




(c) Terza


Figura 4.13
41



(a) Prima



(b) Seconda



(c) Terza

Figura 4.14

Conclusione

Bibliografia

- [1] B. Timothy. *Monte Carlo Techniques*. Radboud University, Nijmegen, The Netherlands, 2025. Lecture notes for the course NWI-NM042B Monte Carlo Techniques.
- [2] L. Leuzzi E. Marinari, G. Parisi. *Calcolo delle probabilità. Un trattatello per principianti volenterosi*. Zanichelli, 2023.
- [3] M. P. Kennett. *Essential Statistical Physics*. Cambridge University Press, 2020.
- [4] N. Metropolis. The beginning of the monte carlo method. *Los Alamos Science*, Special Issue, 1987.
- [5] P. Werner J. E. Gubernatis, N. Kawashima. *Quantum Monte Carlo Methods*. Cambridge University Press, 2016.

Ringraziamenti