

Dipartimento di Fisica e Astronomia “Augusto Righi”
Corso di Laurea in Fisica

Metodi Monte Carlo e Normalizing Flows per il campionamento di distribuzioni di Boltzmann multimodali.

Relatore:
Prof. Cesare Franchini

Presentata da:
Riccardo Pivi

Correlatore:
Dott. Luca Leoni

*A mio fratello e ai miei genitori,
per essere stati il mio faro e il mio porto sicuro.*

Sommario

Qui inserisci il testo del sommario...

Indice

Introduzione	1
1 Probabilità e meccanica statistica	3
1.1 Teoria della probabilità	3
1.1.1 Spazi di probabilità e variabili aleatorie	3
1.1.2 Distribuzioni di probabilità continue	4
1.1.3 Distribuzioni unimodali e multimodali	5
1.1.4 Valori di aspettazione e campionamento	6
1.2 Meccanica statistica	8
1.2.1 Microstato, macrostato e ensemble statistico	8
1.2.2 L'ensemble canonico	9
1.2.3 La distribuzione di Boltzmann	10
1.3 Campionamento: diretto e markoviano	12
2 Metodi Monte Carlo	15
2.1 Cenni storici	15
2.2 Metodo dell'inversa	17
2.3 Markov Chain Monte Carlo	19
2.3.1 Catene di Markov	19
2.3.2 L'Algoritmo di Metropolis-Hastings	21
2.4 Campioni autocorrelati	23
2.4.1 Blocking Analysis	23
2.4.2 Metodo di Sokal	23
3 Normalizing Flows	25
3.1 Cambio di variabili e funzioni invertibili	25
3.2 Normalizing Flows	26
3.2.1 Espressività del Flow	26
3.2.2 Campionamento e inferenza	26
3.2.3 Addestramento del Flow	26
3.3 Costruire un Flow: composizione finita	27
3.3.1 Coupling Flow	27
3.3.2 Trasformazione affine	27
3.3.3 Coupling layers	27
3.3.4 Real NVP	27
3.4 Flow Markov Chain Monte Carlo	28

4	Studio del campionamento	29
4.1	Il potenziale doppio pozzo	29
4.2	Limiti di Markov Chain Monte Carlo	30
4.2.1	Dettagli implementativi	30
4.2.2	Risultati	31
4.3	Confronto dei metodi di campionamento	33
4.3.1	Dettagli implementativi	33
4.3.2	Confronto al variare di T	33
4.3.3	Confronto al variare di N	36
4.3.4	Distribuzioni e traiettorie del camminatore	38
	Conclusione	41
A	Derivazione della distribuzione di Boltzmann	43
	Bibliografia	45
	Ringraziamenti	47

Introduzione

CAPITOLO 1

Probabilità e meccanica statistica

In questo capitolo vengono introdotti alcuni concetti fondamentali di probabilità necessari per comprendere il problema del campionamento: esso consiste nel generare una successione di configurazioni secondo una determinata distribuzione di probabilità. Tale problema assume particolare rilevanza in meccanica statistica, dove le proprietà macroscopiche di un sistema possono essere ricavate a partire dalle configurazioni microscopiche che lo costituiscono.

Dopo aver introdotto le nozioni di base relative alle variabili aleatorie e alle distribuzioni di probabilità, si discuterà l'importanza del campionamento di una distribuzione (Sezione 1.1). Si introdurrà poi l'ensemble canonico, con particolare attenzione alla distribuzione di Boltzmann (Sezione 1.2), che rappresenta la distribuzione target dei metodi di campionamento studiati nel seguito di questa tesi. Infine si introdurrà la distinzione fra campionamento diretto e markoviano (Sezione 1.3) necessaria per comprendere le differenze nei vari metodi di campionamento presentati nei capitoli successivi.

1.1 Teoria della probabilità

1.1.1 Spazi di probabilità e variabili aleatorie

In teoria della probabilità ha un ruolo fondamentale **lo spazio di probabilità** $(\Omega, \mathcal{A}, P)$: dove Ω è l'insieme di tutti i possibili esiti χ , $\mathcal{A}$ è la sigma-algebra su Ω e P è una misura di probabilità su $\mathcal{A}$. Un sottoinsieme $A \subset \Omega$ è chiamato evento ed ad ognuno di essi è possibile associare un numero reale $P(A) \in [0, 1]$ - ovvero la probabilità di tale evento.

In particolare è necessario che siano soddisfatte $P(\Omega) = 1$, $P(\emptyset) = 0$ e per ogni insieme di eventi numerabili disgiunti A_i valga:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i). \quad (1.1)$$

Esempio 1.1.1: Tiri di un dado

Quando si tira un dado a sei facce si considera lo spazio degli eventi $\Omega = \{1, 2, \dots, 6\}$ e la misura di probabilità $P(\chi_i) = 1/6$ per ogni $\chi_i \in \Omega$. Un esempio di evento è il caso in cui risultato del tiro sia pari $A = \{2, 4, 6\} \subset \Omega$ con probabilità calcolabile nel seguente modo: $P(A) = P(2) + P(4) + P(6) = 1/2$.

Una **variabile aleatoria** (reale) X associa agli elementi di uno spazio degli esiti Ω valori appartenenti a uno spazio misurabile $(\mathbb{R})$. Una variabile aleatoria X associa a ciascun esito χ un valore x appartenente allo spazio dei valori possibili della variabile. Nel caso di una variabile aleatoria reale si ha quindi:

$$X : \Omega \rightarrow \mathbb{R}. \quad (1.2)$$

1.1.2 Distribuzioni di probabilità continue

Data una variabile aleatoria X essa ha associata una funzione **distribuzione cumulativa** $F_X(x)$, definita da:

$$F_X(x) = P(X \leq x). \quad (1.3)$$

Dunque la probabilità che X assuma un valore compreso tra due estremi a e b è data da:

$$P(a < X \leq b) = F_X(b) - F_X(a). \quad (1.4)$$

$F_X(x)$ è una funzione di x monotona, nondecrecente e definita su tutto l'asse reale con le proprietà: $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$. Se $F_X(x)$ è ovunque differenziabile, la variabile aleatoria X è continua. Dunque una densità di probabilità $p_X(x)$ associata ad X esiste e soddisfa

$$p_X(x) = \frac{d F_X(x)}{dx} \quad (1.5)$$

La densità di probabilità deve inoltre soddisfare la condizione di normalizzazione ed essere non negativa per ogni valore della variabile aleatoria:

$$\int_{-\infty}^{+\infty} p_X(x) dx = 1 \quad (1.6)$$

$$p_X(x) \geq 0 \quad \forall x \in \mathbb{R}. \quad (1.7)$$

È importante sottolineare che la densità di probabilità non rappresenta direttamente la probabilità che la variabile assuma un determinato valore. Infatti, la probabilità di ottenere esattamente un particolare valore x_0 è nulla. La densità di probabilità permette invece di calcolare la probabilità che la variabile aleatoria assuma un valore appartenente a un determinato intervallo. In particolare, la probabilità che X appartenga all'intervallo $[a, b]$ è data da

$$P(a \leq X \leq b) = \int_a^b p_X(x) dx. \quad (1.8)$$

La distribuzione di probabilità può quindi essere interpretata geometricamente: la probabilità associata a un intervallo corrisponde all'area sottesa dalla densità di probabilità nell'intervallo considerato. Una maggiore densità di probabilità in una determinata regione indica quindi una maggiore probabilità di osservare valori della variabile in quella regione [1].

Esempio 1.1.2: Variabile aleatoria uniforme

La variabile aleatoria uniforme U su (a, b) , con $a < b$, ha funzione di densità di probabilità $f_U(x) = \begin{cases} \frac{1}{b-a} & \text{se } a \leq x \leq b \\ 0 & \text{altrimenti} \end{cases}$

Nel seguito sarà particolarmente utile considerare variabili aleatorie multidimensionali. Una configurazione microscopica di un sistema fisico può infatti essere rappresentata mediante un vettore:

$$\mathbf{x} = (x_1, x_2, \dots, x_D) \in \mathbb{R}^D, \quad (1.9)$$

dove D rappresenta il numero di gradi di libertà del sistema. In questo caso la distribuzione di probabilità è descritta da una densità $p(\mathbf{x})$, normalizzata sulla totalità dello spazio delle configurazioni $\mathbb{R}^D$:

$$\int_{\mathbb{R}^D} p(\mathbf{x}) d\mathbf{x} = 1. \quad (1.10)$$

La densità $p(\mathbf{x})$ permette di determinare la probabilità che una configurazione appartenga a una determinata regione $\mathcal{A}$ dello spazio delle configurazioni:

$$P(\mathbf{x} \in \mathcal{A}) = \int_{\mathcal{A}} p(\mathbf{x}) d\mathbf{x}. \quad (1.11)$$

1.1.3 Distribuzioni unimodali e multimodali

Una distribuzione di probabilità può presentare una struttura caratterizzata dalla presenza di uno o più massimi locali. In particolare, si definisce distribuzione **unimodale** una distribuzione caratterizzata da un'unica regione di massima probabilità detta **modo**. Un esempio tipico è rappresentato dalla distribuzione gaussiana, che presenta un unico massimo in corrispondenza del suo valore medio.

Una distribuzione **multimodale**, invece, presenta più regioni distinte di alta probabilità, associate a più massimi locali della densità. In questo caso, ciascun massimo identifica un modo della distribuzione. Le diverse regioni ad alta probabilità possono essere separate da regioni caratterizzate da una densità molto più bassa. Il caso particolare in cui vi siano due massimi locali è detto distribuzione **bimodale**. La differenza qualitativa tra le due tipologie di distribuzioni è illustrata in Figura 1.1.




Figura 1.1: Confronto tra una distribuzione unimodale (gaussiana) e una distribuzione multimodale (bimodale).

La distinzione tra distribuzioni unimodali e multimodali è particolarmente importante nel problema del campionamento. Nel caso di una distribuzione unimodale, un metodo di campionamento che esplori efficacemente la regione attorno al massimo della distribuzione può ottenere un campione rappresentativo dell'intera distribuzione. Nel caso multimodale, invece, il campionamento può risultare più complesso, poiché è necessario esplorare tutte le regioni rilevanti dello spazio delle configurazioni e riprodurre correttamente la probabilità associata a ciascun modo e non esclusivamente a quello di maggiore densità.

Se le diverse regioni ad alta probabilità sono separate da zone di bassa probabilità, un metodo di campionamento locale può infatti rimanere confinato per lungo tempo all'interno di uno dei modi, esplorando con difficoltà gli altri. Il fenomeno è chiamato *intrappolamento in un modo* ed è una delle principali difficoltà associate al campionamento di distribuzioni multimodali ed è il motivo dell'inefficienza dei metodi di campionamento locali. In questi casi, è necessario adottare strategie più sofisticate per garantire un campionamento efficace e rappresentativo dell'intera distribuzione.

1.1.4 Valori di aspettazione e campionamento

Sia $p(\mathbf{x})$ la densità di probabilità della variabile aleatoria e $O(\mathbf{x})$ una funzione della variabile aleatoria, il valore di aspettazione di $O(\mathbf{x})$ è calcolabile tramite il seguente integrale:

$$\langle O(\mathbf{x}) \rangle = \int_{\mathbb{R}^D} O(\mathbf{x}) p(\mathbf{x}) d\mathbf{x}. \quad (1.12)$$

La convergenza dell'integrale non è affatto garantita e dipende dall'andamento della funzione $O(\mathbf{x})$ e da $p(\mathbf{x})$, inoltre questo integrale non è sempre facilmente risolvibile analiticamente o numericamente. Un approccio diretto al calcolo di $\langle O(\mathbf{x}) \rangle$ potrebbe basarsi su metodi di quadratura numerica [2], che discretizzano lo spazio delle configurazioni su una griglia e approssimano l'integrale come somma pesata sui punti della griglia.

Esempio 1.1.3: Metodo del trapezio

Nel caso unidimensionale il metodo di quadratura approssima l'integrale di una funzione $f(x)$ su un intervallo $[a, b]$ mediante la formula:

$$\int_a^b f(x) dx \approx \sum_i^N \int_{x_i-\epsilon}^{x_i+\epsilon} f(x) dx \quad (1.13)$$

dove x_i sono i punti della griglia e ϵ è la metà della distanza tra due punti consecutivi. Il metodo del trapezio approssima ciascun integrale locale con l'area di un trapezio, sostituendo l'integrale con:

$$\int_{x_i-\epsilon}^{x_i+\epsilon} f(x) dx \approx \frac{f(x_i-\epsilon) + f(x_i+\epsilon)}{2} \cdot 2\epsilon \quad (1.14)$$

Se lo spazio delle configurazioni ha dimensione D e si utilizzano N punti per ciascuna direzione, il numero totale di valutazioni della funzione integranda cresce come N^D . Per sistemi con un numero elevato di gradi di libertà, come tipicamente accade in meccanica statistica, questa crescita esponenziale rende i metodi di quadratura del tutto inapplicabili. In questi casi, il problema del calcolo di valori di aspettazione può essere affrontato in maniera più efficiente mediante metodi di campionamento, che permettono di stimare l'integrale senza la necessità di discretizzare lo spazio delle configurazioni.

L'idea alla base dei metodi di campionamento consiste - anziché valutare la funzione integranda su una griglia deterministica - nel generare un insieme di configurazioni $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ distribuite secondo la densità di probabilità $p(\mathbf{x})$, e nello stimare i valori di aspettazione mediante la media aritmetica:

$$\langle O(\mathbf{x}) \rangle \approx \frac{1}{N} \sum_{i=1}^N O(\mathbf{x}_i). \quad (1.15)$$

Per la legge dei grandi numeri la stima converge, per $N \rightarrow \infty$, al valore di aspettazione esatto $\langle O(\mathbf{x}) \rangle$, a patto che le configurazioni campionate $\mathbf{x}_i$ siano effettivamente distribuite secondo $p(\mathbf{x})$. Un aspetto cruciale di questo approccio è che, se le configurazioni sono indipendenti, l'errore statistico associato allo stimatore decresce col numero di campioni N come:

$$\sigma_{\langle O \rangle} \sim \frac{\sigma_O}{\sqrt{N}}, \quad (1.16)$$

dove σ_O è la deviazione standard di $O(\mathbf{x})$ rispetto a $p(\mathbf{x})$.

Diversamente dai metodi di quadratura, questo risultato non dipende esplicitamente dalla dimensione D dello spazio delle configurazioni: è questa caratteristica a rendere i metodi di campionamento lo strumento privilegiato per lo studio di sistemi ad alta dimensionalità. Il problema è dunque generare un insieme di configurazioni distribuite secondo $p(\mathbf{x})$ di modo da poter stimare i valori di aspettazione. I metodi, per cui sarà possibile creare questi campioni, saranno oggetto dei capitoli successivi.

1.2 Meccanica statistica

1.2.1 Microstato, macrostato e ensemble statistico

Noi esseri umani percepiamo il mondo circostante ad un livello macroscopico, adoperiamo oggetti composti da atomi, ma ne ignoriamo i dettagli microscopici, ovvero lo stato specifico di ciascuno di essi. Se volessimo conoscere il comportamento del sistema in modo completo, sarebbe necessario seguire l'evoluzione temporale di ogni particella, ovvero risolvere l'equazione di Schrödinger per ciascuna di esse ($\sim 10^{23}$ per una mole di gas). Ovviamente il problema appena descritto è inaffrontabile e soprattutto inutile dal punto di vista pratico: si è interessati a descrivere il comportamento macroscopico di un sistema e non il moto di molte singole particelle. La meccanica statistica fornisce un formalismo per descrivere il comportamento macroscopico di un sistema a partire dalle proprietà microscopiche dei singoli elementi che lo costituiscono. In particolare, si concentra sullo studio di sistemi composti da un numero elevato di particelle, come gas, liquidi o solidi, e mira a derivare le leggi della termodinamica a partire dalle leggi della meccanica classica o quantistica [3].

In meccanica statistica, un **microstato** rappresenta una configurazione specifica del sistema, descritta da tutte le variabili microscopiche necessarie per caratterizzarlo completamente. Ad esempio, per un gas ideale, un microstato può essere definito dalle posizioni e dai momenti di tutte le particelle che lo compongono. Un **macrostato**, invece, è una descrizione più generale del sistema, caratterizzata da grandezze macroscopiche come energia, numero di particelle e volume. Un macrostato può corrispondere a molti microstati diversi: ad esempio, due configurazioni microscopiche diverse di un gas possono avere la stessa temperatura e pressione.




Figura 1.2: Rappresentazione schematica della relazione tra microstati e macrostato. Un macrostato può corrispondere a molteplici microstati, ognuno dei quali rappresenta una configurazione specifica del sistema.

Josiah Willard Gibbs (1839-1903) introdusse il concetto di **ensemble statistico**, che rappresenta un insieme di copie del sistema di interesse, ciascuna delle

quali può trovarsi in uno dei possibili microstati compatibili con un dato macrostato. Se l'ensemble è sufficientemente grande, allora la probabilità di trovare il sistema in un particolare microstato è la frazione di copie dell'ensemble che si trovano in quel microstato. Vi sono diversi tipi di ensemble statistici, ognuno dei quali è adatto a descrivere sistemi con diversi vincoli. I principali ensemble sono:

- **Ensemble microcanonico:** Descrive un sistema isolato con energia, volume e numero di particelle costanti. Tutti i microstati compatibili con questi vincoli hanno la stessa probabilità.
- **Ensemble canonico:** Descrive un sistema a contatto termico con un serbatoio a temperatura fissa, in cui l'energia può fluttuare ma il numero di particelle è costante. La probabilità di un microstato è data dalla distribuzione di Boltzmann.
- **Ensemble grand-canonico:** Descrive un sistema a contatto con un serbatoio che può scambiare sia energia che particelle. La probabilità di un microstato è data dalla distribuzione Grand Canonica.

Per comprendere il comportamento di un sistema fisico, è fondamentale scegliere l'ensemble statistico appropriato in base alle condizioni sperimentali e ai vincoli imposti sul sistema. Questa tesi ha l'obiettivo di presentare metodi di campionamento per la distribuzione di Boltzmann, dunque nelle prossime sezioni si discuterà più nel dettaglio l'ensemble canonico e la relativa distribuzione.

1.2.2 L'ensemble canonico

Consideriamo un sistema fisico descritto da una hamiltoniana $\mathcal{H}(\mathbf{x})$, dove $\mathbf{x}$ rappresenta collettivamente i gradi di libertà del sistema, quali posizioni, impulsi o, più in generale, tutte le variabili necessarie a identificarne uno stato microscopico.

Supponiamo che il sistema sia posto a contatto con un **serbatoio termico** (o bagno termico), cioè un sistema macroscopico molto più grande del sistema in esame. I due sistemi possono scambiare energia, mentre il numero di particelle rimane costante. Una rappresentazione grafica della situazione fisica è la Figura 1.3. Grazie alle dimensioni macroscopiche del serbatoio, gli scambi di energia producono variazioni trascurabili del suo stato, cosicché esso può essere considerato in equilibrio ad una temperatura costante T .




Figura 1.3: Rappresentazione schematica dell'ensemble canonico: sistema (System), serbatoio termico (Bath) e flusso di calore fra i due sistemi (Heat Flow).

In queste condizioni il sistema non possiede un'energia fissata: i suoi microstati vengono continuamente modificati dagli scambi di calore con il serbatoio e l'energia assume valori differenti con una certa probabilità, a condizione che l'energia media del sistema sia costante, ovvero una quantità ben definita. L'insieme di copie ideali del sistema, tutte caratterizzate dallo stesso numero di particelle e dalla medesima temperatura, prende il nome di **ensemble canonico**.

L'obiettivo della meccanica statistica è determinare la probabilità che il sistema si trovi in un determinato stato microscopico di energia E . Tale probabilità è descritta dalla **distribuzione di Boltzmann** ricavabile tramite il principio di massima entropia Appendice A.

1.2.3 La distribuzione di Boltzmann

La distribuzione di Boltzmann descrive la probabilità di osservare il sistema in una configurazione microscopica quando esso si trova all'equilibrio termico con un serbatoio a temperatura T fissata.

Dalla massimizzazione dell'entropia, soggetta ai vincoli di normalizzazione della distribuzione e di valore medio dell'energia costante, si ottiene

$$p(\mathbf{x}, T) = \frac{1}{Z(\beta)} e^{-\beta \mathcal{H}(\mathbf{x})} \quad (1.17)$$

dove $\beta = \frac{1}{k_B T}$ e $Z(\beta) = \int_{\mathbb{R}^D} e^{-\beta \mathcal{H}(\mathbf{x})} d\mathbf{x}$ è la funzione di partizione.

Il prodotto $\beta \mathcal{H}(\mathbf{x})$ determina la probabilità di ciascuna configurazione e si può facilmente comprendere come all'aumentare della temperatura sono probabilisticamente permessi una gamma più ampia di stati; al diminuire della temperatura, invece, la probabilità si concentra progressivamente negli stati di energia minima.

Inoltre, la funzione di partizione svolge un ruolo centrale, poiché garantisce la normalizzazione della distribuzione e contiene tutta l'informazione termodinamica del sistema. Infatti, una volta nota $Z(\beta)$, è possibile ricavare grandezze quali energia libera, energia media, entropia e capacità termica.

L'energia libera di Helmholtz è

$$F = -k_B T \ln Z. \quad (1.18)$$

L'energia media è

$$\langle E \rangle = -\frac{\partial \ln Z}{\partial \beta}. \quad (1.19)$$

La capacità termica a volume costante è

$$C_V = \frac{\partial \langle E \rangle}{\partial T} = k_B \beta^2 (\langle E^2 \rangle - \langle E \rangle^2), \quad (1.20)$$

mentre l'entropia è

$$S = -\left(\frac{\partial F}{\partial T}\right)_V = k_B (\ln Z + \beta \langle E \rangle). \quad (1.21)$$

Nella maggior parte dei sistemi di interesse fisico la funzione di partizione non può essere calcolata in forma chiusa. Essa richiede infatti l'integrazione della quantità:

$$e^{-\beta \mathcal{H}(\mathbf{x})} \quad (1.22)$$

su tutto lo spazio delle configurazioni, che è uno spazio multidimensionale di dimensione pari al numero di gradi di libertà del sistema. Per sistemi costituiti da molte particelle il calcolo diretto dell'integrale è proibitivo: basti pensare ad un gas ideale con un numero di Avogadro ($\sim 10^{23}$) di particelle.

Di conseguenza, anche il valore assoluto della distribuzione di Boltzmann non è generalmente noto, poiché dipende dalla funzione di partizione. Tuttavia è possibile valutare il rapporto tra le probabilità di due configurazioni,

$$\frac{p(\mathbf{x}_2, T)}{p(\mathbf{x}_1, T)} = e^{-\beta [\mathcal{H}(\mathbf{x}_2) - \mathcal{H}(\mathbf{x}_1)]}, \quad (1.23)$$

nel quale il fattore di normalizzazione $Z(\beta)$ si semplifica. Questa osservazione è importante per i capitoli successivi, poiché per poter campionare la distribuzione di Boltzmann sarà necessario avere metodi che possono generare configurazioni distribuite secondo una distribuzione seppur conoscendola a meno della costante di normalizzazione.

1.3 Campionamento: diretto e markoviano

Il problema centrale di questa tesi - generare configurazioni distribuite secondo la densità di Boltzmann - non ammette un'unica strategia algoritmica. Prima di addentrarci nei metodi concreti, è utile costruire una mappa concettuale delle possibili strategie, in modo che le differenze fra i metodi presentati nei capitoli successivi risultino chiare fin da subito.

La prima distinzione riguarda *come* viene prodotta una configurazione. Si parla di **campionamento diretto** quando una configurazione distribuita secondo $p(\mathbf{x})$ può essere ottenuta a partire da una variabile aleatoria uniforme. Ogni configurazione così prodotta è per costruzione indipendente dalle altre. Il prezzo che viene richiesto è di conoscere analiticamente la distribuzione target: nel Capitolo 2 si mostrerà un metodo efficace per distribuzioni unidimensionali semplici, ovvero il metodo dell'inversa (Sezione 2.2), che è un metodo esatto di campionamento diretto.

Quando il campionamento diretto non è una scelta possibile per il problema che si vuole affrontare, si può ricorrere a una strategia alternativa: costruire una successione di configurazioni in cui ciascuna dipenda *solo* dalla precedente. Una successione con questa proprietà è una **catena di Markov**, ed è alla base dei metodi **Markov Chain Monte Carlo (MCMC)**, presentati nella Sezione 2.3. La catena non produce istantaneamente un campione dalla distribuzione corretta: è necessario *iterare* finché la catena non abbia raggiunto la propria distribuzione stazionaria, una fase detta **termalizzazione**. Inoltre ogni configurazione dipende da quella precedente, le configurazioni generate non sono statisticamente indipendenti ma **correlate**: due passi successivi tendono a essere più simili di due configurazioni estratte direttamente, il che riduce l'informazione statistica effettivamente contenuta in N passi della catena rispetto a N campioni indipendenti.

Il vantaggio decisivo dell'approccio markoviano, che ne spiega la centralità in fisica statistica, è che la catena può essere costruita conoscendo $p(\mathbf{x})$ anche a meno della costante di normalizzazione, condizione tipicamente verificata per la distribuzione di Boltzmann, la cui funzione di partizione $Z(\beta)$ non è in generale calcolabile.

Una seconda distinzione, interna al campionamento markoviano, riguarda la natura della configurazione candidata proposta a ogni passo della catena. Si parla di **passo locale** quando la configurazione proposta è ottenuta perturbando quella corrente con uno spostamento di ampiezza limitata: è questo il caso dell'algoritmo di Metropolis-Hastings (Sezione 2.3.2). Un passo locale è una scelta semplice ed economica, ma la sua efficacia dipende criticamente dalla struttura di $p(\mathbf{x})$: se la distribuzione è multimodale e i modi sono separati da regioni di bassa probabilità, una successione di piccoli spostamenti può impiegare un tempo computazionale enorme per attraversare la regione a bassa densità che separa due modi, rimanendo di fatto *intrappolata in un modo*.

Si parla invece di **passo globale** quando la configurazione candidata può discostarsi significativamente da quella corrente, fino al caso limite in cui è generata indipendentemente da essa, attingendo a un'intera distribuzione di proposta definita su tutto lo spazio delle configurazioni. Una catena costruita in questo modo

non soffre per costruzione dell'intrappolamento nei modi, poiché ogni proposta esplora potenzialmente l'intero spazio indipendentemente da dove si trovi la catena. La sua efficienza dipende però interamente dalla qualità della distribuzione di proposta: se questa è troppo diversa dalla distribuzione target, la probabilità che una proposta venga accettata può essere troppo bassa, vanificando il vantaggio teorico del passo globale. La Figura 1.4 illustra qualitativamente la differenza fra passo locale e passo globale su una distribuzione bimodale: nel primo caso il camminatore esplora un modo alla volta, nel secondo può spostarsi direttamente da un modo all'altro.




Figura 1.4: Rappresentazione della differenza fra passo locale e globale per un MCMC con obiettivo il campionamento di una mistura di due gaussiane. L'immagine in alto mostra in blu cinque passi locali, mentre l'immagine in basso mostra in verde lo stesso numero di passi globali.

Le due strategie discusse in questa sezione possono non essere alternative e diventare complementari. Un Normalizing Flow (Capitolo 3) addestrato ad approssimare $p(\mathbf{x})$ costituisce infatti una candidata naturale come distribuzione di proposta per un MCMC: pur non fornendo un campionamento diretto esatto, il flow può fungere da motore per mosse globali all'interno di una catena di Markov. Il metodo ibrido così ottenuto - il **Flow-MCMC**, che verrà discusso

nella Sezione 3.4 - combina la correttezza asintotica garantita dalla struttura markoviana con la capacità di esplorazione globale offerta dal flow.

In tutto il lavoro, utilizzeremo la notazione

$$\mathbf{x} \sim p(\mathbf{x}), \quad (1.24)$$

per indicare il campionamento di una configurazione $\mathbf{x}$ estratta dalla distribuzione di probabilità $p(\mathbf{x})$.

I tre metodi confrontati in questa tesi si collocano dunque rispettivamente nel campionamento markoviano a mosse locali (MCMC, Capitolo 2.3), nel campionamento diretto approssimato (Normalizing Flow, Capitolo 3.2), e nel campionamento markoviano a mosse globali (Flow-MCMC, Sezione 3.4).




Figura 1.5: Mappa concettuale dei vari metodi di campionamento e quali sono presentati in questa tesi ed in che capitoli.

CAPITOLO 2

Metodi Monte Carlo

I metodi Monte Carlo rappresentano una classe di tecniche numeriche che permettono di stimare quantità altrimenti inaccessibili per via analitica, sostituendo il calcolo esatto con una stima statistica basata sul campionamento casuale. In fisica statistica questo approccio è particolarmente prezioso: il calcolo di valori di aspettazione rispetto alla distribuzione di Boltzmann richiede in generale la valutazione di integrali in uno spazio delle configurazioni ad altissima dimensionalità, per cui le tecniche di quadratura deterministica diventano rapidamente inapplicabili. L'idea alla base del metodo — sostituire il calcolo esatto con una stima ottenuta da un numero sufficiente di "prove" — nacque in un contesto scientifico unico a livello storico, per poi diventare uno degli strumenti computazionali più importanti del Novecento.


In questo capitolo vengono introdotti i concetti e gli algoritmi più importanti dei metodi Monte Carlo. Si introdurrà il contesto storico in cui è nato il metodo (2.1), per poi discutere un metodo Monte Carlo di campionamento diretto (2.2) e uno markoviano (2.3), presentando prima le catene di Markov. Infine si discuterà di un aspetto cruciale per Markov Chain Monte Carlo, ovvero la presenza di correlazione tra i campioni generati, che rende necessaria un'attenta analisi statistica per una corretta stima degli errori (2.4).

2.1 Cenni storici


Il metodo Monte Carlo si basa su un'idea semplice, ma potente. L'idea nacque da Stanisław Ulam (2.1a) - fisico e matematico polacco naturalizzato statunitense - durante una partita di solitario. La frustrazione del matematico nel cercare di calcolare analiticamente la probabilità di vincere una partita lo portò a realizzare che una buona stima di quest'ultima sarebbe stata possibile evitando completamente i calcoli. Ulam capì che, se avesse giocato un numero sufficiente di partite, avrebbe potuto stimarla segnandosi quante di queste prove avrebbe vinto o perso. L'idea dal semplice gioco si spostò poi alla risoluzione di problemi di matematica e fisica: con i primi computer elettronici sarebbe stato possibile simulare un sistema generando campioni virtuali dello stesso così da ottenere stime accurate delle quantità ricercate. All'epoca Ulam lavorava assieme a Von Neumann (2.1b) presso il Los Alamos National Laboratory, allora centro di ricerca segreto per lo sviluppo della prima bomba nucleare, qui era stato costruito l'ENIAC (Electronic numerical integrator and computer) uno dei primi computer elettronici digitali general purpose della storia. I due scienziati lavorarono ad una procedu-

ra stocastica basata sull'idea del matematico polacco per simulare il trasporto dei neutroni attraverso un materiale fissile. Il nome "Monte Carlo" fu proposto nel 1947 da un altro celebre fisico del gruppo, Nicholas Constantine Metropolis [4]. La scelta del nome, ispirata al celebre casinò situato nel Principato di Monaco, nacque per canzonare Ulam, il quale aveva uno zio con il vizio del gioco d'azzardo.


Vi è inoltre un precursore del metodo: Enrico Fermi (2.1c). Metropolis parlando con Emilio Segrè scoprì che Fermi aveva già ideato, in modo del tutto indipendente, un metodo basato sul campionamento statistico quindici anni prima di loro. Lo stesso Fermi infatti partecipando al progetto Manhattan (1942-1946) aiutò nello studio del trasporto dei neutroni costruendo insieme a Percy King il FERMIAC o anche denominato *Il carrello Monte Carlo*: un computer analogico che permetteva - data una distribuzione iniziale di neutroni - di sviluppare genealogie di neutroni in due dimensioni, o modelli di comportamento di neutroni individuali, comprendenti ciascuno collisioni, spargimenti, e fissioni. In ogni fase venivano usati numeri pseudo-casuali per ricavare le decisioni che influenzano il comportamento di ciascun neutrone.



(a) Stanisław Ulam e il FERMIAC.



(b) Von Neumann.



(c) Enrico Fermi.

Figura 2.1: I pionieri del metodo Monte Carlo.

2.2 Metodo dell'inversa

Il metodo dell'inversa (o *inverse transform sampling*) è la tecnica di campionamento *diretto* più utilizzata: essa consente di generare campioni distribuiti secondo una generica densità di probabilità unidimensionale $p_X(x)$ a partire da una variabile aleatoria distribuita uniformemente nell'intervallo $[0, 1]$.

Sia X una variabile aleatoria continua con funzione di distribuzione cumulativa $F_X(x) = P(X \leq x)$ strettamente monotona e continua, tale da ammettere una funzione inversa $F_X^{-1} : (0, 1) \rightarrow \mathbb{R}$. Sia inoltre $U \sim \mathcal{U}(0, 1)$ una variabile aleatoria uniforme sull'intervallo $(0, 1)$.

Si consideri la variabile aleatoria definita dalla trasformazione inversa:

$$Y = F_X^{-1}(U). \quad (2.1)$$

Per determinare la funzione di distribuzione cumulativa di Y , valutiamo $F_Y(y) = P(Y \leq y)$:

$$F_Y(y) = P(F_X^{-1}(U) \leq y). \quad (2.2)$$

Poiché la funzione $F_X(x)$ è monotona strettamente crescente, applicando F_X ad entrambi i membri della disuguaglianza si ottiene:

$$P(F_X^{-1}(U) \leq y) = P(U \leq F_X(y)). \quad (2.3)$$

Ricordando che per una variabile aleatoria uniforme $U \sim \mathcal{U}(0, 1)$ vale la proprietà $P(U \leq u) = u$ per ogni $u \in [0, 1]$, si ha direttamente:

$$F_Y(y) = F_X(y). \quad (2.4)$$

Di conseguenza, la variabile aleatoria Y possiede la medesima distribuzione cumulativa di X e la sua densità di probabilità coincide con $p_X(x)$.

L'applicazione pratica del metodo dell'inversa per la generazione di N campioni indipendenti è sintetizzata nel seguente algoritmo:

Algorithm 1: Metodo dell'Inversa (Inverse Transform Sampling)

Input: Numero di campioni N ; funzione di distribuzione cumulativa inversa $F_X^{-1}(u)$.

Inizializza l'insieme dei campioni $\mathcal{S} = \emptyset$;

for $i = 1$ **to** N **do**

 Genera $u_i \sim \mathcal{U}(0, 1)$;

 Calcola $x_i = F_X^{-1}(u_i)$;

 Aggiungi x_i all'insieme $\mathcal{S}$;

end

Output: Insieme di campioni $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ distribuiti secondo $p_X(x)$.

Si mostra un esempio pratico di applicazione del metodo dell'inversa per il campionamento della distribuzione esponenziale, che illustra chiaramente i passaggi descritti nell'algoritmo precedente.

Esempio 2.2.1: Campionamento della distribuzione esponenziale

Si consideri la distribuzione di probabilità esponenziale con parametro $\lambda > 0$:

$$p_X(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x \geq 0, \\ 0 & \text{se } x < 0. \end{cases} \quad (2.5)$$

La relativa funzione di distribuzione cumulativa per $x \geq 0$ è data da:

$$F_X(x) = \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}. \quad (2.6)$$

Uguagliando $F_X(x)$ a una variabile uniforme $u \in (0, 1)$ ed invertendo la relazione:

$$u = 1 - e^{-\lambda x} \implies 1 - u = e^{-\lambda x} \implies x = -\frac{1}{\lambda} \ln(1 - u). \quad (2.7)$$

Poiché se $U \sim \mathcal{U}(0, 1)$ anche $(1 - U) \sim \mathcal{U}(0, 1)$, la formula generatrice si semplifica spesso in:

$$x = -\frac{1}{\lambda} \ln(u). \quad (2.8)$$

Il principale vantaggio del metodo dell'inversa risiede nella sua efficienza e semplicità: ciascun campione generato è perfettamente indipendente dagli altri e non vi è alcuna probabilità di rifiuto (a differenza dei metodi di Acceptance-Rejection o dei metodi Markov Chain Monte Carlo).

Tuttavia, il metodo presenta forti limitazioni pratiche, che ne riducono l'applicabilità a distribuzioni di probabilità complesse o multidimensionali:

- **Invertibilità analitica:** Richiede che la funzione di distribuzione cumulativa $F_X(x)$ sia integrabile ed invertibile in forma chiusa (o approssimabile numericamente con elevata precisione).
- **Costante di normalizzazione:** È applicabile solo se la densità di probabilità $p_X(x)$ è perfettamente normalizzata.
- **Dimensionalità:** Risulta di difficile estensione a distribuzioni ad alta dimensionalità $D \gg 1$, rendendolo di fatto inutilizzabile per il campionamento della distribuzione di Boltzmann in fisica statistica.

2.3 Markov Chain Monte Carlo

2.3.1 Catene di Markov

Sia $X_1, \dots, X_N$ una sequenza di variabili aleatorie in $\mathbb{R}^D$, questa sequenza è una catena di Markov se la probabilità condizionata di ogni X_i soddisfa:

$$P(X_i|X_{i-1}, \dots, X_1) = P(X_i|X_{i-1}). \quad (2.9)$$

Dunque la probabilità di ottenere un certo valore di X_i dipende solo dalla variabile aleatoria precedente della catena e non dalle altre, questa richiesta equivale a dire che le catene di Markov sono catene *senza memoria*, ovvero che solo l'ultimo stato della catena influenza il prossimo stato [5]. Considerando il caso che la variabile aleatoria X_i possa assumere un numero discreto di valori, ovvero che $X_i \in \{x_1, \dots, x_j, \dots\}$, in questo modo possiamo descrivere la distribuzione di probabilità e le probabilità condizionate di tali variabili utilizzando un vettore e una matrice rispettivamente:

$$P(X_i) = p_j^{(i)} = \begin{pmatrix} p^{(i)}(x_1) \\ \vdots \\ p^{(i)}(x_j) \\ \vdots \end{pmatrix}, \quad P(X_i|X_j) = P_{ij} = \begin{pmatrix} P(x_1|x_1) & \cdots & P(x_1|x_j) & \cdots \\ P(x_2|x_1) & \cdots & P(x_2|x_j) & \cdots \\ \vdots & \ddots & \vdots & \\ P(x_i|x_1) & \cdots & P(x_i|x_j) & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix} \quad (2.10)$$

La matrice P_{ij} rappresenta la probabilità di transizione dallo stato j allo stato i . Inoltre possiamo notare alcune proprietà interessanti sia per $p_j^{(i)}$ che per P_{ij} , in quanto $\forall i$ esse soddisfano:

$$\sum_j p_j^{(i)} = 1, \quad \sum_i P_{ij} = 1. \quad (2.11)$$

Data una distribuzione iniziale $p_i^{(0)}$ e la matrice stocastica P_{ij} detta **matrice di transizione**, si può evolvere la distribuzione in modo ricorsivo:

$$p_i^{(k+1)} = \sum_j P_{ij} p_j^{(k)} \quad \text{con } k \in \mathbb{N}. \quad (2.12)$$

Questa evoluzione della distribuzione di probabilità della catena conserva la normalizzazione della distribuzione, infatti:

$$\sum_i p_i^{(k+1)} = \sum_i \sum_j P_{ij} p_j^{(k)} = \sum_j p_j^{(k)} \sum_i P_{ij} = \sum_j p_j^{(k)} = 1. \quad (2.13)$$

Inoltre considerando una matrice di transizione ergodica (ovvero irriducibile e aperiodica) è assicurato che a prescindere dalla distribuzione iniziale $p_i^{(0)}$ iterando il procedimento si raggiunge un **distribuzione stazionaria** p_i tale che:

$$p_i = \sum_j P_{ij} p_j. \quad (2.14)$$

Ovvero si raggiunge una distribuzione di probabilità che non viene più modificata iterando il procedimento (per questo detta stazionaria), inoltre essa è l'autovettore della matrice di transizione P_{ij} con autovalore unitario. L'obiettivo di Markov Chain Monte Carlo è quello di costruire una catena di Markov che abbia come distribuzione stazionaria la distribuzione target p_i che vogliamo campionare. Per fare ciò è necessario costruire una matrice di transizione P_{ij} costruita in un certo modo.

Metropolis et al. (1953) proposero che fosse possibile ottenere una specifica distribuzione p_i se la P_{ij} soddisfa una certa condizione di simmetria detta **bilancio dettagliato**:

$$P_{ij}p_j = P_{ji}p_i. \quad (2.15)$$

Il formalismo matematico delle Catene di Markov descritto per variabili discrete è estremamente flessibile e può essere generalizzato al caso continuo sostituendo la sommatoria con l'integrazione. Nel caso continuo, la distribuzione di probabilità stazionaria p_i diventa una densità di probabilità

$$p(\mathbf{x}) = \frac{f(\mathbf{x})}{\int_{\mathbb{R}^D} f(\mathbf{x}) d\mathbf{x}}, \quad (2.16)$$

e la matrice di transizione P_{ij} viene sostituita da un kernel di transizione continuo:

$$\pi: \mathbb{R}^N \times \mathbb{R}^N \rightarrow \mathbb{R}^+ \quad (2.17)$$

che definisce la probabilità di transizione tra stati dello spazio continuo [6]. L'evoluzione ricorsiva della distribuzione al passo $(i+1)$ assume quindi la forma:

$$p^{(i+1)}(\mathbf{x}) = \int_{\mathbb{R}^N} d\mathbf{y} \pi(\mathbf{x}, \mathbf{y}) p^{(i)}(\mathbf{y}) \quad (2.18)$$

Per garantire che la catena converga a una specifica distribuzione stazionaria di target $p(\mathbf{x})$, il kernel di transizione deve soddisfare la *condizione di bilancio dettagliato* (detailed balance condition):

$$\pi(\mathbf{x}, \mathbf{y})p(\mathbf{y}) = \pi(\mathbf{y}, \mathbf{x})p(\mathbf{x}) \quad (2.19)$$

Sotto condizioni di ergodicità, facendo evolvere gli elementi della catena attraverso tale kernel, si ottiene una sequenza di campioni $\{\mathbf{x}_i\}_{i=1}^N$. Dopo un certo tempo t sufficientemente grande, detto *tempo di termalizzazione* (o *burn-in time*), i campioni generati risulteranno distribuiti secondo la distribuzione target $p(\mathbf{x})$:

$$\mathbf{x}_i \sim p(\mathbf{x}) = \frac{f(\mathbf{x})}{\int d\mathbf{x} f(\mathbf{x})} \quad \text{per } i > t \quad (2.20)$$

Nella sezione successiva verrà presentato l'algoritmo di Metropolis-Hastings, che permette di costruire un kernel π che soddisfa la condizione di bilancio dettagliato permettendo di campionare una distribuzione target $p(\mathbf{x})$, conoscendone anche soltanto la forma non normalizzata $f(\mathbf{x})$.

2.3.2 L'Algoritmo di Metropolis-Hastings

Il problema di costruire un opportuno kernel $\pi(\mathbf{x}, \mathbf{y})$ che garantisca la convergenza a una data distribuzione target $p(\mathbf{x})$ è stato studiato da Metropolis [7] e successivamente generalizzato da Hastings [8]. La soluzione generale esprime il kernel di transizione come prodotto di due termini:

$$\pi(\mathbf{x}, \mathbf{y}) = \Gamma(\mathbf{x} \rightarrow \mathbf{y}) \mathcal{A}(\mathbf{x}, \mathbf{y}) \quad (2.21)$$

dove:

- $\Gamma(\mathbf{x} \rightarrow \mathbf{y})$ è la *funzione di aggiornamento* (proposal distribution), che definisce la probabilità di proporre uno spostamento dallo stato $\mathbf{x}$ allo stato $\mathbf{y}$;
- $\mathcal{A}(\mathbf{x}, \mathbf{y})$ è il *tasso di accettazione* (acceptance ratio), definito come:

$$\mathcal{A}(\mathbf{x}, \mathbf{y}) = \min \left\{ 1, \frac{\Gamma(\mathbf{y} \rightarrow \mathbf{x}) f(\mathbf{y})}{\Gamma(\mathbf{x} \rightarrow \mathbf{y}) f(\mathbf{x})} \right\} \quad (2.22)$$

Assumendo che la distribuzione di proposta sia normalizzata e strettamente positiva:

$$\int \Gamma(\mathbf{x} \rightarrow \mathbf{y}) d\mathbf{y} = 1, \quad \Gamma(\mathbf{x} \rightarrow \mathbf{y}) > 0 \quad (2.23)$$

Si dimostra che il kernel così costruito soddisfa la condizione di bilancio dettagliato:

$$\pi(\mathbf{x}, \mathbf{y}) \frac{f(\mathbf{y})}{\int d\mathbf{x} f(\mathbf{x})} = \pi(\mathbf{y}, \mathbf{x}) \frac{f(\mathbf{x})}{\int d\mathbf{x} f(\mathbf{x})} \quad (2.24)$$

A livello computazionale, il procedimento per generare lo stato $\mathbf{x}_{i+1}$ a partire dallo stato corrente $\mathbf{x}_i$ segue la descritta nell'algoritmo 2.

Algorithm 2: Algoritmo di Metropolis-Hastings

Input: Stato corrente $\mathbf{x}_i$; distribuzione target non normalizzata $f(\mathbf{x})$;
distribuzione di proposta $\Gamma(\mathbf{x} \rightarrow \mathbf{y})$.

Genera un candidato $\mathbf{y} \sim \Gamma(\mathbf{x}_i \rightarrow \mathbf{y})$;

Genera $u \sim \mathcal{U}(0, 1)$;

Calcola il tasso di accettazione $\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left(1, \frac{\Gamma(\mathbf{y} \rightarrow \mathbf{x}_i) f(\mathbf{y})}{\Gamma(\mathbf{x}_i \rightarrow \mathbf{y}) f(\mathbf{x}_i)} \right)$;

if $u < \mathcal{A}(\mathbf{x}_i, \mathbf{y})$ **then**

 | Imposta $\mathbf{x}_{i+1} = \mathbf{y}$; // Proposta accettata

else

 | Imposta $\mathbf{x}_{i+1} = \mathbf{x}_i$; // Proposta rifiutata

end

Output: Nuovo stato $\mathbf{x}_{i+1}$.

L'iterazione di questa operazione permette di creare la catena di campioni distribuiti secondo la distribuzione target, questo procedimento è rappresentato graficamente in figura 2.2.




Figura 2.2

Un caso comune prevede l'uso di uno spostamento gaussiano simmetrico, in cui :

$$\mathbf{y} = \mathbf{x}_i + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2) \quad (2.25)$$

Poiché la proposta è simmetrica ($\Gamma(\mathbf{x} \rightarrow \mathbf{y}) = \Gamma(\mathbf{y} \rightarrow \mathbf{x})$), la percentuale di accettazione si semplifica nel rapporto diretto tra le densità di target:

$$\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left\{ 1, \frac{f(\mathbf{y})}{f(\mathbf{x}_i)} \right\} \quad (2.26)$$

E' possibile notare che gli elementi i valori di π in questo caso simmetrico dipendono esclusivamente dal rapporto della probabilità target nelle due configurazioni considerate (attuale e proposta), dunque sono indipendenti dalla costante di normalizzazione della distribuzione target. Come già espresso nel capitolo precedente, questo è un aspetto cruciale per il campionamento della distribuzione di Boltzmann, in quanto la costante di normalizzazione della distribuzione è proprio la funzione di partizione, di cui non è sempre possibile calcolare analiticamente o numericamente. Sostituendo la distribuzione di Boltzmann come distribuzione target otteniamo un tasso di accettazione della forma:

$$\mathcal{A}(\mathbf{x}_i, \mathbf{y}) = \min \left\{ 1, \frac{e^{-\beta \mathcal{H}(\mathbf{y})}}{e^{-\beta \mathcal{H}(\mathbf{x}_i)}} \right\}. \quad (2.27)$$

2.4 Campioni autocorrelati

2.4.1 Blocking Analysis

2.4.2 Metodo di Sokal

CAPITOLO 3

Normalizing Flows

3.1 Cambio di variabili e funzioni invertibili

3.2 Normalizing Flows

3.2.1 Espressività del Flow

3.2.2 Campionamento e inferenza

3.2.3 Addestramento del Flow

3.3 Costruire un Flow: composizione finita

3.3.1 Coupling Flow

3.3.2 Trasformazione affine

3.3.3 Coupling layers

3.3.4 Real NVP

3.4 Flow Markov Chain Monte Carlo

CAPITOLO 4

Studio del campionamento

4.1 Il potenziale doppio pozzo

4.2 Limiti di Markov Chain Monte Carlo

4.2.1 Dettagli implementativi




Figura 4.1

4.2.2 Risultati




Figura 4.2




Figura 4.3




Figura 4.4




Figura 4.5

4.3 Confronto dei metodi di campionamento

4.3.1 Dettagli implementativi

4.3.2 Confronto al variare di T




Figura 4.6




Figura 4.7




Figura 4.8




Figura 4.9






Figura 4.10


4.3.3 Confronto al variare di N



(a) Prima




(b) Seconda




(c) Terza


Figura 4.11



(a) Prima




(b) Seconda



(c) Terza


Figura 4.12

4.3.4 Distribuzioni e traiettorie del camminatore




(a) Prima

(b) Seconda




(c) Terza

Figura 4.13



(a) Prima

(b) Seconda



(c) Terza

Figura 4.14

Conclusione

APPENDICE A

Derivazione della distribuzione di Boltzmann

Il comportamento del sistema a fissata T è descritto da una distribuzione di probabilità $p(\mathbf{x}, T)$ ottenibile attraverso il principio di massima entropia.

$$\mathcal{S} = - \int_{\mathbb{R}^D} p(\mathbf{x}, T) \ln(p(\mathbf{x}, T)) d\mathbf{x} \quad (\text{A.1})$$

Per massimizzare l'entropia si utilizza il teorema dei moltiplicatori di Lagrange:

$$\mathcal{L}[p] = - \int_{\mathbb{R}^D} p \ln p d\mathbf{x} - \alpha \left(\int_{\mathbb{R}^D} p d\mathbf{x} - 1 \right) - \beta \left(\int_{\mathbb{R}^D} p \mathcal{H} d\mathbf{x} - \langle E \rangle \right), \quad (\text{A.2})$$

dove α e β sono i moltiplicatori di Lagrange associati rispettivamente al vincolo di normalizzazione

$$\int_{\mathbb{R}^D} p(\mathbf{x}, T) d\mathbf{x} = 1, \quad (\text{A.3})$$

e al vincolo sul valore medio dell'energia

$$\int_{\mathbb{R}^D} p(\mathbf{x}, T) \mathcal{H}(\mathbf{x}) d\mathbf{x} = \langle E \rangle. \quad (\text{A.4})$$

La massimizzazione impone $\delta \mathcal{L} / \delta p = 0$ restituendo:

$$-\ln p(\mathbf{x}, T) - 1 - \alpha - \beta \mathcal{H}(\mathbf{x}) = 0 \quad (\text{A.5})$$

che permette di determinare $p(\mathbf{x}, T)$:

$$p(\mathbf{x}, T) = e^{-1-\alpha} e^{-\beta \mathcal{H}(\mathbf{x})}. \quad (\text{A.6})$$

Il moltiplicatore α è fissato dalla condizione di normalizzazione: definendo la **funzione di partizione**

$$Z(\beta) = \int_{\mathbb{R}^D} e^{-\beta \mathcal{H}(\mathbf{x})} d\mathbf{x}, \quad (\text{A.7})$$

si ha $e^{-1-\alpha} = 1/Z(\beta)$, da cui **la distribuzione di Boltzmann**:

$$p(\mathbf{x}, T) = \frac{1}{Z(\beta)} e^{-\beta \mathcal{H}(\mathbf{x})}. \quad (\text{A.8})$$

Dove $\beta = 1/(k_B T)$.

Bibliografia

- [1] B. Timothy. *Monte Carlo Techniques*. Radboud University, Nijmegen, The Netherlands, 2025. Lecture notes for the course NWI-NM042B Monte Carlo Techniques.
- [2] L. Leuzzi E. Marinari, G. Parisi. *Calcolo delle probabilità. Un trattatello per principianti volenterosi*. Zanichelli, 2023.
- [3] M. P. Kennett. *Essential Statistical Physics*. Cambridge University Press, 2020.
- [4] N. Metropolis. The beginning of the monte carlo method. *Los Alamos Science*, Special Issue, 1987.
- [5] P. Werner J. E. Gubernatis, N. Kawashima. *Quantum Monte Carlo Methods*. Cambridge University Press, 2016.
- [6] L. Leoni. Enhancing diagrammatic monte carlo via machine learning. Master's thesis, University of Bologna, Department of Physics and Astronomy, Bologna, Italy, 2023. Supervisor: Prof. Cesare Franchini. Academic Year 2022/2023.
- [7] N. Metropolis et al. Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6), 1953.
- [8] W. K. Hastings. Monte carlo sampling methods using Markov chains and their applications. *Biometrika*, 57(1), 1970.

Ringraziamenti